

Universidad de Alcalá Escuela Politécnica Superior

Grado en Ingeniería Informática

Trabajo Fin de Grado

Algoritmos de detección de objetos 3D basados en LiDAR:
comparación entre técnicas PCL clásicas y Deep Learning

ESCUELA POLITECNICA

Autor: Javier de la Peña García

Tutores: Luis Miguel Bergasa Pascual y Carlos Gómez Huélamo

2021

UNIVERSIDAD DE ALCALÁ

ESCUELA POLITÉCNICA SUPERIOR

Grado en Ingeniería Informática

Trabajo Fin de Grado

**Algoritmos de detección de objetos 3D basados en LiDAR:
comparación entre técnicas PCL clásicas y Deep Learning**

Autor: Javier de la Peña García

Directores: Luis Miguel Bergasa Pascual y Carlos Gómez Huélamo

Tribunal:

Presidente: Felipe Espinosa Zapata

Vocal 1º: Rafael Barea Navarro

Vocal 2º: Luis Miguel Bergasa Pascual

Calificación:

Fecha:

*“Cualquiera que deje de aprender es viejo, ya sea a los veinte u ochenta.
Cualquier persona que sigue aprendiendo se mantiene joven.”*

Henry Ford

Agradecimientos

*Juntarse es un comienzo. Seguir juntos es un progreso.
Trabajar juntos es un éxito.*

Henry Ford

Este Trabajo Fin de Grado representa la finalización del trabajo realizado estos últimos 4 años de estudio y esfuerzo para aprender lo máximo posible en el tránsito de la carrera.

En primer lugar quería dar las gracias a mi familia por el apoyo en la realización de la carrera y el TFG, pero sobre todo a mi madre por aguantarme todas las explicaciones del trabajo que iba completando. Quiero dar las gracias a todos los amigos que me han estado apoyando este año, juntándonos por Discord todos los días con muchos de ellos y sintiendo que tenía un apoyo detrás.

Y por último dar las gracias a Luis Miguel Bergasa por introducirme al mundo de la conducción autónoma y visión artificial, a Carlos Gómez Huélamo por su ayuda en el desarrollo de este trabajo además de la motivación que da, empujándonos a mejorar cada día, y de nuevo a un gran amigo y compañero en este TFG, Miguel Antunes por todos los ratos que hemos pasado juntos animándonos, ayudándonos y trabajando para conseguir los mejores resultados posibles en nuestros trabajos.

Resumen

Los sistemas de percepción en los vehículos autónomos, son aquellos que permiten comprender lo que sucede en el entorno. Este trabajo se centra en el estudio de técnicas de percepción utilizando tecnologías LiDAR, tanto técnicas clásicas como técnicas basadas en Deep Learning. Con dicho estudio se presentan las implementaciones diseñadas para el vehículo del proyecto Techs4AgeCar.

Junto con la implementación basada en un solo sensor, se presenta también un modelo de fusión sensorial entre cámara y LiDAR basado en el sistema de detección explicado en este TFG y el trabajo basado en cámara realizado por Miguel Antunes, un compañero del grupo de investigación RobeSafe.

Por último para la evaluación de sistemas de conducción autónomos sobre el simulador CARLA, se explica el proyecto AD DevKit, sobre el que se realiza la capa de percepción para la evaluación de sistemas de detección 2D y 3D en dicho simulador.

Palabras clave: LiDAR, Deep Learning, Fusión sensorial, Conducción autónoma, KITTI, nuScenes, CARLA, ROS.

Abstract

Perception systems in autonomous vehicles are those that allow to understand what is happening in the environment. This work focuses on the study of perception techniques using LiDAR technologies, both classical techniques and techniques based on Deep Learning. This study presents the implementations designed for the Techs4AgeCar project vehicle.

Along with the implementation based on a single sensor, a sensor fusion model between camera and LiDAR is also presented based on the detection system explained in this TFG and the camera-based work done by Miguel Antunes, a colleague of the RobeSafe research group.

Finally, for the evaluation of autonomous driving systems on the CARLA simulator, the AD DevKit project is explained, on which the perception layer for the evaluation of 2D and 3D detection systems on this simulator is performed.

Keywords: LiDAR, Deep Learning, Sensor Fusion, Autonomous driving, KITTI, nuScenes, CARLA, ROS.

Resumen extendido

Desde hace unos años la industria automovilística se encuentra en una carrera para el desarrollo de vehículos con la capacidad de conducción autónoma. La introducción de estos sistemas en las carreteras supondrá un cambio en el funcionamiento de muchos sectores, principalmente el sector transporte que se verá afectado al no tener necesidad de contratar a conductores, al igual que muchos otros aspectos de la sociedad que se verán afectados por la automatización de los vehículos. Estos sistemas pretenden aumentar la seguridad al volante ofreciendo un sistema de conducción con más fiabilidad que un conductor humano, disminuyendo la cantidad de atascos y accidentes producidos en las carreteras.

Este trabajo ubicado dentro del marco de los sistemas de conducción autónoma, estudia los sistemas de detección utilizados en la industria, basados en múltiples sensores como: cámaras, LiDAR, Radar, GPS, IMU, etc. Todo ello para obtener la mayor información del entorno para así tratar de comprenderlo con la mayor precisión posible. Para ello se usan sistemas de detección, seguimiento y predicción de los objetos del entorno que se basan en los diferentes sensores que posee el vehículo.

En este TFG se estudia la detección de objetos 3D dentro de la capa de percepción, para ello, se utilizan tecnologías LiDAR que permiten obtener la distancia del sensor a los objetos en un entorno tridimensional, con lo que se consiguen nubes de puntos las cuales se procesan a posteriori. Para el procesamiento de las nubes de puntos se estudian tanto técnicas clásicas como técnicas basadas en Deep Learning para inferir los objetos del entorno. Como técnicas clásicas se estudia la voxelización, el algoritmo RANSAC-3D y la estructura de datos KD-tree, con todo ello se presenta una implementación sobre el simulador CARLA de un modelo basado en las técnicas clásicas estudiadas. El estudio de técnicas basadas en Deep Learning consiste en un estudio de diferentes datasets como KITTI, Waymo o nuScenes y de los modelos del estado del arte para la detección de los objetos 3D del entorno. A partir de ello se presenta una implementación basada en el modelo CBGS que mejora la detección del sistema de percepción del proyecto Techs4AgeCar.

Basado en el sistema de detección 3D que incluye el modelo CBGS, el sistema de detección con cámara basado en YOLO v5 y una red volumétrica implementada por Miguel Antunes en su TFG, se presenta un sistema de fusión sensorial a partir de las detecciones finales de ambos sistemas, donde las flaquesas de ambos modelos se ven reducidos y se obtienen unas detecciones más robustas.

Actualmente los sistemas de conducción autónoma no tienen forma de evaluar la arquitectura completa desarrollada, por ello se trabaja en colaboración con el Karlsruhe Institute of Technology para el desarrollo de un sistema de evaluación completo sobre el simulador CARLA. En conjunto con Miguel Antunes se ha desarrollado una primera versión del sistema de evaluación de la capa de percepción. Para que el rendimiento de las diferentes capas del vehículo no afecten al resto, es necesario crear un sistema de evaluación en tiempo real. En este trabajo se presenta la creación de groundtruth en tiempo real junto con un sistema de evaluación de detecciones 2D y 3D a posteriori que permitan cuantificar la precisión de los sistemas de percepción.

Por último los diferentes modelos estudiados son evaluados sobre sus respectivos datasets, los sistemas

de detección desarrollados son analizados en el simulador CARLA y el sistema final elegido es probado en el vehículo T4AC en un circuito urbano controlado en el campus de la Universidad de Alcalá.

Índice general

Resumen	ix
Abstract	xi
Resumen extendido	xiii
Índice general	xv
Índice de figuras	xix
Índice de tablas	xxiii
Índice de listados de código fuente	xxv
Índice de algoritmos	xxvii
Lista de acrónimos	xxx
1 Introducción	1
1.1 Sistemas de conducción autónomos	1
1.2 Sistemas de percepción	2
1.2.1 Principales sensores para la percepción en vehículos autónomos	3
1.2.1.1 Cámara	3
1.2.1.2 Radar	4
1.2.1.3 LiDAR	4
1.2.2 Sistemas de detección	5
1.2.3 Sistemas de seguimiento	6
1.2.4 Fusión sensorial	7
1.3 Deep Learning	8
2 Propuesta de trabajo	9

3 Sistemas clásicos de percepción con LiDAR	11
3.1 Voxelización	11
3.2 RANSAC-3D	12
3.3 KD-tree	14
3.4 Filtrado previo y posterior a la detección	18
4 Sistemas de percepción con LiDAR basados en Deep Learning	19
4.1 Principales datasets	19
4.1.1 KITTI	19
4.1.1.1 Análisis de la estructura del GT y las PCLs de KITTI	21
4.1.2 Waymo	23
4.1.3 nuScenes	25
4.1.3.1 NuScenes devkit	27
4.1.4 Comparativa entre los diferentes datasets	28
4.2 Estado del arte en técnicas de detección utilizando LiDAR	29
4.2.1 SECOND	30
4.2.2 PointPillars	31
4.2.3 PointRCNN	32
4.2.4 PV-RCNN	34
4.2.5 CBGS	35
4.3 OpenPCDet	36
5 Desarrollo realizado	39
5.1 Estado del proyecto Techs4AgeCar	39
5.1.1 Robot Operating System	39
5.1.2 Docker	41
5.1.3 CARLA	42
5.1.4 Desarrollo en el proyecto Techs4AgeCar	44
5.1.5 Arquitectura del proyecto Techs4AgeCar	46
5.2 Implementación en CARLA	47
5.2.1 Funcionamiento del LiDAR en CARLA	47
5.2.2 Implementación del sistema clásico utilizando LiDAR	48
5.2.3 Implementación del sistema basado en Deep Learning utilizando LiDAR	50
5.3 Fusión sensorial	52
5.4 Vehículo del proyecto Techs4AgeCar	52
5.5 Implementación sobre el vehículo Techs4AgeCar	53

6 AD DevKit	55
6.1 Motivación para la creación del AD DevKit	55
6.2 Obtención del groundtruth	56
6.2.1 Calculo de la visibilidad de los objetos	57
6.2.2 Geometría de la cámara	58
6.2.3 Formato del groundtruth obtenido	60
6.2.4 Funcionamiento del generador de groundtruth	61
6.3 Evaluación de los modelos	61
7 Resultados obtenidos	65
7.1 Análisis sobre datasets	65
7.1.1 Análisis cuantitativo en Kitti	65
7.1.2 Análisis cuantitativo en nuScenes	68
7.1.3 Análisis adicionales	71
7.1.3.1 Transferencia de modelos basados en Kitti a nuScenes	71
7.1.3.2 Número de nubes de puntos de entrada en modelos evaluados sobre nuScenes	72
7.1.3.3 Tamaño del voxel en modelos basados en redes neuronales	74
7.2 Análisis sobre el simulador CARLA	75
7.2.1 Análisis cualitativo del modelo clásico en CARLA	75
7.2.2 Análisis cualitativo de Pointpillars Multihead en CARLA	76
7.2.2.1 Comparativa con PointPillars en CARLA	77
7.2.3 Análisis cuantitativo de Pointpillars Multihead en CARLA	77
7.3 Análisis sobre el vehículo T4AC	78
7.3.1 Análisis cualitativo de Pointpillars Multihead sobre el vehículo T4AC	78
7.3.1.1 Comparativa con PointPillars sobre el vehículo T4AC	79
7.3.2 Análisis cualitativo del sistema de fusión sensorial sobre el vehículo T4AC	80
8 Conclusiones y trabajos futuros	83
8.1 Conclusiones	83
8.2 Trabajos futuros	84
Bibliografía	85
A Manual de usuario	91
A.1 Sistema de detecciones basado en técnicas clásicas	91
A.2 Muestra de nubes de puntos en KITTI	91
A.3 Modelo de detecciones basado en Deep Learning	92
A.4 Sistema de detecciones mediante fusión sensorial	92
A.5 Uso del AD Devkit para la evaluación de la capa de percepción	92

B Pliego de condiciones	95
B.1 Recursos hardware	95
B.2 Recursos software	95
C Presupuesto	97
C.1 Coste de hardware y software	97
C.2 Coste de personal	97
C.3 Coste total	98

Índice de figuras

1.1	Arquitectura de un sistema de conducción autonóma.	1
1.2	Niveles de autonomía.	2
1.3	Cámara utilizada en vehículos autónomos.	3
1.4	Uso de cámara con lluvia.	3
1.5	Radar utilizado en vehículos autónomos.	4
1.6	LiDAR utilizado en vehículos autónomos.	5
1.7	Detecciones 2D utilizando cámara.	5
1.8	Detecciones 3D utilizando LiDAR.	6
1.9	Tracking como vista de pájaro sobre una nube de puntos.	7
1.10	Fusión sensorial utilizando cámara y LiDAR.	7
1.11	Convolutional Neural Network.	8
3.1	Entorno 3D voxelizado.	11
3.2	Aplicación de RANSAC para detección de outliers.	12
3.3	Aplicación de RANSAC-3D.	14
3.4	Árbol binario ordenado.	15
3.5	Espacio bidimensional dividido por un KD-tree.	16
3.6	Estructura de un KD-tree de dos dimensiones.	16
4.1	Estructura del dataset de KITTI.	20
4.2	Vehículo utilizado en KITTI.	21
4.3	Medidas del vehículo utilizado en KITTI.	21
4.4	Estructura del archivo tracklet_labels.xml.	22
4.5	Visualización de una nube de puntos de KITTI junto con su groundtruth.	23
4.6	Vehículo utilizado en Waymo.	23
4.7	Nube de puntos con las diferentes clases del dataset de Waymo.	24
4.8	Vehículo utilizado en el dataset de nuScenes.	25
4.9	Estructura del dataset nuScenes.	26
4.10	Esquema de nuScenes.	27

4.11	Esquema de nuImages	27
4.12	Transformación mundo a imagen de la nube de puntos segmentada en el devkit de nuScenes.	28
4.13	Arquitectura propuesta del detector SECOND.	30
4.14	Algoritmo de convolución disperso propuesto en SECOND.	31
4.15	Arquitectura propuesta del detector PointPillars.	32
4.16	Arquitectura propuesta del detector PointRCNN.	33
4.17	Agrupación de regiones de la nube de puntos en el modelo PointRCNN.	33
4.18	Arquitectura propuesta del detector PV-RCNN.	34
4.19	Módulo Predicted Keypoint Weighting del modelo PV-RCNN.	34
4.20	Arquitectura propuesta del detector CBGS.	35
4.21	Diseño de OpenPCDet.	36
5.1	Logo de ROS.	40
5.2	Ejemplo de uso de ROS	40
5.3	Funcionamiento principal de ROS.	41
5.4	Arquitectura de Docker.	41
5.5	Unreal Engine 5.	43
5.6	Modo de uso principal de CARLA.	43
5.7	Estructura principal del proyecto Techs4AgeCar en Docker.	44
5.8	Modo de uso en el proyecto Techs4AgeCar.	45
5.9	Arquitectura T4AC.	46
5.10	Estructura del repositorio para la detección con LiDAR en el proyecto refactorizado.	50
5.11	Nueva estructura del repositorio para la detección con LiDAR en el proyecto.	51
5.12	Chasis con el hardware necesario para la conducción autónoma.	53
5.13	Vehículo T4AC.	53
5.14	Arquitectura de la capa de percepción.	54
6.1	Arquitectura del AD DevKit.	55
6.2	Métricas de control en el AD DevKit.	56
6.3	Transformaciones mundo a cámara.	58
6.4	Ángulos alpha y rotation_z del groundtruth del AD DevKit.	60
6.5	Archivo CSV con los datos del groundtruth obtenidos.	61
6.6	Estructura del generador de groundtruth del AD DevKit.	61
6.7	Visualización del IoU 2D y 3D.	62
6.8	Ejemplo de curva de precision-recall.	63
7.1	Modelo PointPillars sobre KITTI.	71
7.2	Modelo PointPillars sobre KITTI con detección 360°.	71

7.3	Modelo PointPillars sobre nuScenes con detección 360°	72
7.4	Análisis del rendimiento de los modelos basados en CBGS según el número de barridos.	73
7.5	Modelo clásico en CARLA.	75
7.6	PointPillars Multihead en CARLA.	76
7.7	PointPillars en CARLA.	77
7.8	Curvas de precision-recall para la clase coche de PointPillars Multihead en CARLA.	78
7.9	PointPillars Multihead en el vehículo T4AC.	79
7.10	PointPillars en el vehículo T4AC.	80
7.11	Fusión sensorial en el vehículo T4AC.	81

Índice de tablas

4.1 Comparativa entre los principales datasets.	29
5.1 Estructura del LiDAR en el CARLA-ROS bridge.	48
5.2 Parámetros del modelo clásico de detección con LiDAR.	49
6.1 Formato de la lista de objetos de CARLA	57
6.2 Formato objeto de CARLA	57
6.3 Formato de la lista de detecciones en ROS	60
6.4 Formato de una detección en ROS	60
7.1 Análisis por clase de SECOND en KITTI.	66
7.2 Análisis por clase de PointPillars en KITTI.	66
7.3 Análisis por clase de PointRCNN en KITTI.	67
7.4 Análisis por clase de PV-RCNN en KITTI.	67
7.5 Comparativa de los modelos entrenados sobre KITTI.	68
7.6 Análisis por clase de CBGS SECOND Multihead en nuScenes.	69
7.7 Análisis por clase de CBGS PointPillars Multihead en nuScenes.	69
7.8 Análisis por clase de PointPillars en nuScenes.	70
7.9 Comparativa de los modelos entrenados sobre nuScenes.	70
7.10 Análisis de la precisión de SECOND Multihead según el número de barridos.	73
7.11 Análisis de la precisión de PointPillars Multihead según el número de barridos.	74
7.12 Análisis de la precisión de PointPillars Multihead según el tamaño del voxel.	74
7.13 Parámetros del LiDAR en CARLA.	75
7.14 Métricas para la clase coche de PointPillars Multihead en CARLA.	78
C.1 Coste del hardware y software utilizado.	97
C.2 Coste del trabajo personal realizado.	98
C.3 Coste total del TFG.	98

Índice de listados de código fuente

4.1	Obtención de una nube de puntos segmentada sobre una imagen utilizando nuScenes devkit	28
5.1	Estructura de los nodos utilizados en el KD-tree implementado	49
6.1	Filtrado en función de la visibilidad de los objetos en el AD DevKit	57

Índice de algoritmos

3.1	Algoritmo RANSAC	13
3.2	Búsqueda en árbol binario ordenado	15
3.3	Inserción en KD-tree	16
3.4	Cluster por distancia en KD-tree	17

Lista de acrónimos

AAE	Average Attribute Error.
AB4COGT	A Baseline for CARLA Online Ground-Truth Generation.
AD DevKit	Autonomous Driving Development Kit.
ADAS	Advanced Driver Assistance System.
ADS	Automated Driving System.
AHRS	Attitude and Heading Reference System.
AOE	Average Orientation Error.
AOS	Average Orientation Similarity.
AP	Average Precision.
API	Application Programming Interface.
ASE	Average Scale Error.
ATE	Average Translation Error.
AVE	Average Velocity Error.
BEV	Bird's Eye View.
CLI	Command Line Interface.
CNN	Convolutional Neural Network.
EKF	Extended Kalman Filter.
FC	Fully Connected.
FCN	Fully Connected Network.
FPS	Frames per Second.
GNSS	Global Navigation Satellite System.
GPS	Global Positioning System.
GPU	Graphics Processing Unit.
HMI	Human-Machine Interface.
IMU	Inertial Measurement Unit.
IoU	Intersection over Union.

KF	Kalman Filter.
KIT	Karlsruhe Institute of Technology.
KNN	K Nearest Neighbors.
LiDAR	Light Detection and Ranging.
NDS	nuScenes Detección Score.
NMS	Non Maximum Suppression.
OOP	Object-Oriented Programming.
PCL	Point Cloud Library.
Radar	Radio Detection and Ranging.
RANSAC	Random Sampling and Consensus.
ReLU	Rectified Linear Unit.
RoI	Region of Interest.
ROS	Robot Operating System.
RPN	Region Proposal Network.
RTK	Real Time Kinematic.
SLAM	Simultaneous Localization and Mapping.
Sonar	Sound Navigation and Ranging.
SOTA	State of the Art.
SSD	Single Shot Detector.
TTIC	Toyota Technological Institute at Chicago.
UKF	Unscented Kalman Filter.
VFE	Voxel Feature Encoding.
XML	Extensible Markup Language.
YOLO	You Only Look Once.

Capítulo 1

Introducción

No te conformes con el mundo que has heredado. Nunca se ha resuelto un desafío sin personas que pensasen diferente.

Tim Cook

Para el pleno entendimiento del trabajo desarrollado se explica el funcionamiento de los sistemas de conducción autónoma, para centrarse en la parte de percepción del vehículo y comprender que gracias al Deep Learning se consiguen los mejores resultados del estado del arte en este campo.

1.1 Sistemas de conducción autónomos

En los últimos años gracias a una mejora en los sensores, la capacidad de computo principalmente por la aceleración por hardware, la visión por computador, el Deep Learning 1.3 y el desarrollo de técnicas de comunicación, ha propiciado que nos encontremos en una carrera por la creación de sistemas de conducción autónomos. Empresas de sectores de la automoción y la tecnológicas como ArgoAI, Audi, Baidu, Cruise, Mercedes-Benz, Tesla, Uber o Waymo entre otras, invierten enormes cantidades de dinero para el desarrollo de estas tecnologías [1].

Para la obtención de sistemas de conducción autónoma es necesario tener un buen entendimiento del entorno y hacer uso de un buen control en tiempo real, para ello se utilizan sensores que puedan aportar información al vehículo como son cámaras, [LiDAR](#), [Radar](#), [IMU](#), [GPS](#) o incluso [Sonar](#).

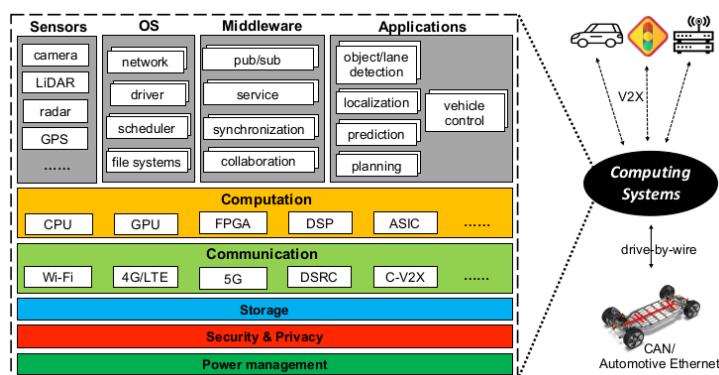


Figura 1.1: Arquitectura de un sistema de conducción autónoma.

En adición a los sensores también es necesaria la utilización de sistemas de localización tanto global como local, mapeado del entorno, toma de decisiones y control del vehículo. Un esquema de una arquitectura de conducción autónoma se muestra en la figura 1.1.

La evolución continua de estos sistemas trata de ofrecer un mayor nivel de seguridad al volante mediante el desarrollo de los Advanced Driver Assistance System (ADAS), para que en un futuro puedan ser remplazados por Automated Driving System (ADS).

Para analizar el avance de estos sistemas y para poder compararlos, se han dividido según su nivel de autonomía, por lo que se tiene desde un nivel 0 a un nivel 5. El nivel 0 indica que el coche no tiene ningún tipo de autonomía (conducción manual), en el nivel 1 el vehículo sigue siendo controlado por el conductor pero se añaden ciertas características de ayuda a la conducción. En el siguiente nivel el vehículo es capaz de acelerar, frenar y hasta dirigir el vehículo pero con el conductor siempre atento, en el nivel 3 el conductor es necesario pero no es requerimiento la atención al entorno, pero el conductor debe de estar listo para tomar el control en todo momento. El nivel 4 permite un nivel de autonomía donde el vehículo no requiere la atención del conductor, pero únicamente en ciertos escenarios, y el último nivel (nivel 5) es el que habilita la conducción autónoma completa [2].

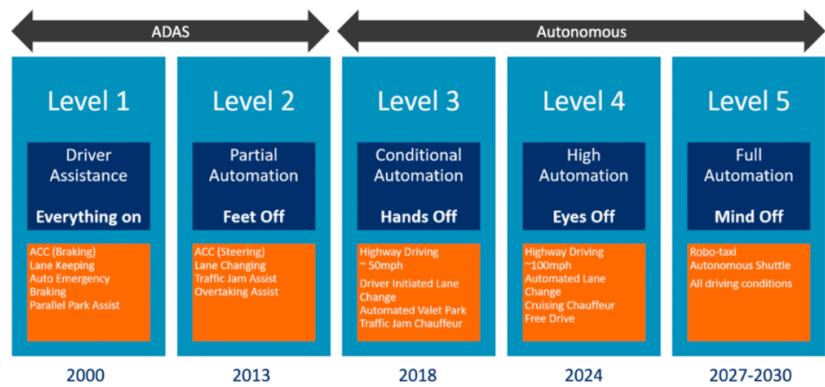


Figura 1.2: Niveles de autonomía.

El desarrollo de este tipo de sistemas no es una tarea sencilla, múltiples empresas involucradas en el desarrollo de vehículos autónomos pretendían tener vehículos en el nivel 4 de autonomía en poco tiempo, pero como se ha visto esto no es posible, actualmente nos encontramos en el mercado con sistemas que se encuentran entre el nivel 2 y el 3, pero aún queda un largo camino antes de llegar a una conducción autónoma completa.

1.2 Sistemas de percepción

Los sistemas de [ADS/ADAS](#) requieren de un entendimiento del entorno para poder funcionar correctamente, para ello es necesario añadir diversos sensores a los largo del vehículo que nos permitan obtener la mayor información del exterior posible. A partir de este conocimiento es posible la toma de decisiones y la planificación, por lo que en este apartado se va a explicar de que manera se puede configurar un sistema de percepción, cuales son los principales sensores utilizados y que información se puede obtener de cada uno de ellos.

1.2.1 Principales sensores para la percepción en vehículos autónomos

Para la creación de un sistema de percepción robusto es necesario el uso de diversos tipos de sensores que ofrezcan una información de relevancia de manera diferente al resto, por ello se utilizan sensores como cámaras, [Radar](#), [LiDAR](#), ultrasonidos, [GPS](#), [GNSS](#), [IMU](#) etc.

Estos ofrecen información de localización, velocidad, distancia de objetos en el entorno, e incluso información del propio vehículo, como su propia localización, o la velocidad lineal y angular que este tiene.

También es necesario tener en cuenta que no todos los sensores funcionan de la misma manera en distintos escenarios por lo que en situaciones donde un sensor es incapaz de obtener buenos datos otro sensor puede suplir esta carencia, por lo que la redundancia de sensores aporta otro nivel de seguridad al vehículo ya no solo un nivel mayor de detección del entorno.

1.2.1.1 Cámara

Uno de los sensores más utilizados es la cámara, este es el más extendido debido a la gran riqueza de información que ofrece del entorno. Actualmente se pueden encontrar cámaras que generen imágenes a una gran resolución y a una alta tasa de [FPS](#) por un precio bastante asequible, este es uno de los sensores más baratos.



Figura 1.3: Cámara utilizada en vehículos autónomos.

El problema de este sensor recae en el computo que es necesario para obtener información a partir de las imágenes, ya que estas no son más que píxeles en escala de grises o con un sistema de colores como el RGB. Por ello no solo es necesario tener en cuenta el coste del sensor, sino que también hay que aumentar la capacidad de computo del ordenador de abordo para que pueda analizar en tiempo real las imágenes.



Figura 1.4: Uso de cámara con lluvia.

Por último es necesario conocer las limitaciones de la cámara, funciona de forma correcta en situaciones de buena luminosidad y sin reflejos, pero en situaciones con lluvia [1.4](#), niebla, durante la noche

y otros escenarios climatológicos adversos, no es capaz de obtener toda la información que se obtendría en situaciones más favorables, lo cual hace que otros sensores sean usados en estas condiciones adversas para lidiar con estas limitaciones.

Aún conociendo las desventajas de estos sensores, la gran mayoría de enfoques incluyen cámaras para la obtención de los objetos del entorno tanto en 2D como en 3D, pudiendo utilizar para lo segundo un sistema de cámaras estéreo que obtienen también información de la profundidad.

1.2.1.2 Radar

Los [Radar](#) son utilizados en múltiples aplicaciones como la previsión meteorológica, la astronomía, las comunicaciones, la navegación oceánica y la conducción autónoma entre otras.

Este sensor emite ondas de radio, las cuales son reflejadas devuelta a este, lo cual da una información de donde se hayan los objetos en un espacio tridimensional, lo que implica la distancia a estos junto con los dos ángulos necesarios utilizando un sistema de coordenadas esféricas. Además gracias al efecto Doppler se puede inferir la velocidad de los objetos a partir de un fenómeno que hace variar la frecuencia de la onda enviada si hay algún tipo de movimiento local relativo respecto del propio [Radar](#) [3, 4].



Figura 1.5: Radar utilizado en vehículos autónomos.

Como se ha visto, este sensor, al contrario que la cámara, obtiene directamente información utilizable para el entendimiento del entorno de forma directa, el problema radica en la escasa cantidad de datos que provee. Aunque se obtenga información de localización 3D y de velocidad, la cantidad de la nube de puntos producida es muy pequeña, por lo que se necesitan otros sensores para obtener una información completa del entorno.

Por otra parte, una de las principales ventajas del [Radar](#) es que se puede utilizar en cualquier situación meteorológica, únicamente podría verse afectado por lluvias muy intensas. Por lo que es un sensor muy completo y supone una buena elección para obtener información adicional de posición 3D y velocidad a un precio inferior a un [LiDAR](#). Por ello es adoptado por gran cantidad de sistemas [ADAS](#) en conjunto con sistemas de cámaras 360 alrededor del vehículo.

1.2.1.3 LiDAR

De forma similar al [Radar](#), los sistemas [LiDAR](#) basan su funcionamiento en el escaneo del entorno a partir de el envío de láseres y el cálculo del tiempo desde su envío hasta su retorno. Con esta información de distancia y el ángulo de inclinación del haz que envió esa señal, se construye una nube de puntos que consta de valores x, y, z de posición y otro valor que es el coeficiente de reflectividad del rayo de luz con el objeto incidido [3].

Actualmente los **LiDAR** más utilizados son de 64 canales, lo cual indica que se tienen 64 láseres funcionando al mismo tiempo, lo que da una gran resolución del entorno. Además la nube de puntos generada es de hasta 120 metros alrededor del vehículo, lo que permite detectar objetos a una distancia considerable y saber de manera casi perfecta su distancia en un entorno tridimensional gracias a los alrededor de 2.000.000 de puntos que se generan por segundo del entorno [5].



Figura 1.6: LiDAR utilizado en vehículos autónomos.

Los sistemas **LiDAR** tienen la ventaja de ser un sensor que aporta mucha información del entorno, pero tienen el mismo problema que las cámaras, en condiciones de lluvia, nieve, granizo o niebla, la efectividad de este sensor decae aunque se puede minimizar ajustando la longitud de onda del láser utilizado [6].

Aún siendo un sensor muy útil, que puede aumentar el nivel de redundancia del sistema, además de su seguridad, múltiples compañías como Tesla tratan de evitar su uso utilizando únicamente cámaras y **Radar**. Esto es debido a que un **LiDAR** suele costar entre 8.000 y 100.000 dólares si se requiere de una resolución similar al estado del arte entre 16 y 128 haces [1].

1.2.2 Sistemas de detección

Unicamente con un sistema de sensores no es posible la comprensión del entorno, también es necesario de un procesamiento de los datos. Mientras que la cámara no da ninguna información de forma directa, el **LiDAR** y el **Radar** son capaces de obtener la posición de obstáculos alrededor del vehículo, y además el **Radar** es capaz de inferir la velocidad de los objetos sin necesidad de un seguimiento.

Principalmente, en los sistemas de detección para conducción autónoma se trata de obtener las posiciones de los diferentes objetos de interés del entorno. Estas detecciones pueden ser tanto en 2D como en 3D, pero el problema radica en como obtener un rectángulo u ortoedro que identifique dónde se encuentran dichos objetos del entorno.

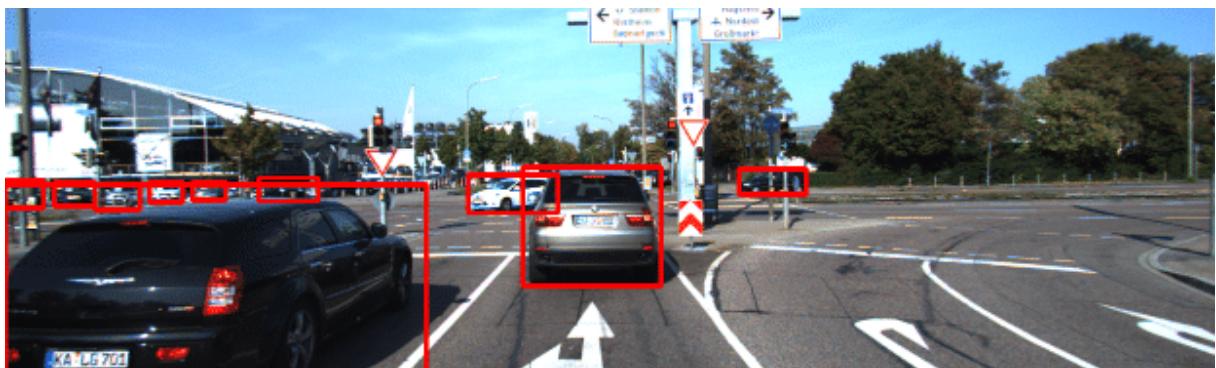


Figura 1.7: Detecciones 2D utilizando cámara.

Una de las formas de detección del entorno es a partir de cámaras, esto se consigue con un sistema de una cámara o de un sistema multicámara que abarque los 360 grados alrededor del coche, con este sistema instalado en el coche se pueden generar rectángulos sobre las imágenes de los objetos del entorno como coches, peatones, bicicletas, motocicletas... Con ello se obtendría un listado de objetos detectados en 2D, lo cual es obtenible con un modelo basado en redes neuronales como [YOLO](#) [7] que es capaz de hacerlo en tiempo real, y que funciona tal y como se ve en la figura 1.7.

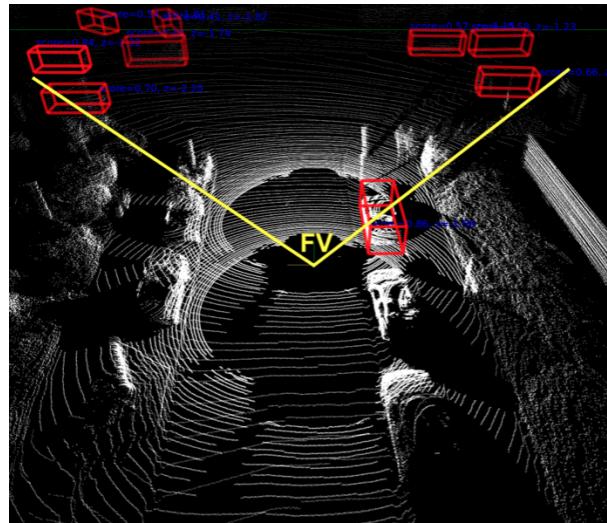


Figura 1.8: Detecciones 3D utilizando LiDAR.

Unicamente con detecciones 2D no se puede obtener la distancia a los vehículos, como mucho una aproximación a partir del tamaño de la bounding box 2D, aparte de la dirección en la que se encuentran respecto del coche. Es por ello que se termina trabajando con detecciones 3D, las cuales pueden tener como paso intermedio una detección 2D o ser obtenidas directamente con un sistema estéreo de cámaras o a partir de las nubes de puntos del [Radar](#) o del [LiDAR](#).

Las técnicas que realizan detecciones en un sistema tridimensional tienen un coste computacional mayor al trabajar con una dimensión añadida, por lo que es necesaria la utilización de técnicas que permitan realizar estas detecciones en tiempo real, como es el caso de PointPillars [8], modelo que se explicará más adelante en la sección 4.2.2, y que como se ve en el punto 1.8 es capaz de realizar las detecciones en un entorno tridimensional utilizando únicamente el [LiDAR](#).

1.2.3 Sistemas de seguimiento

Mientras que en los sistemas de detección se suele utilizar un único estado discretizado del entorno percibido por los sensores, el seguimiento o tracking utiliza múltiples estados para el reconocimiento de los objetos en múltiples escenas, con su posterior asociación y el cálculo de la trayectoria de los mismos.

En este campo se pueden tomar diversos acercamientos al problema, utilizando técnicas clásicas como Kalman Filter (KF), Extended Kalman Filter (EKF) o Unscented Kalman Filter (UKF), modelos neuronales como en [9], modelos end-to-end que incorporan detección y tracking en un mismo modelo neuronal como es el caso de PointTrackNet [10] o modelos que realizan tracking de forma implícita como CBGS [11] que calculan la velocidad de los objetos sin devolver identificadores de estos (como se verá en el punto 4.2.5).

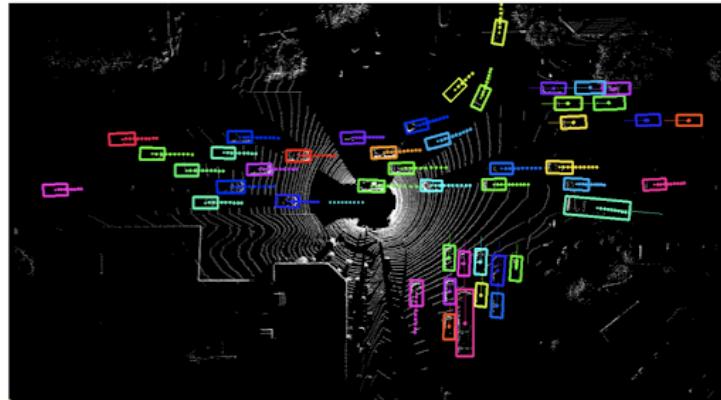


Figura 1.9: Tracking como vista de pájaro sobre una nube de puntos.

Los sistemas de detección suelen trabajar a partir de modelos en dos dimensiones que trabajan en vista de pájaro lo cual evita lidiar con movimientos verticales. En estos se detecta la posición actual, velocidad lineal, velocidad angular y se puede definir el movimiento todo lo complejo que se desee. Tras la detección también se predice el futuro estado de los objetos, manteniendo un identificador asociado a los objetos a lo largo de los frames analizados.

1.2.4 Fusión sensorial

Los sistemas de fusión sensorial son necesarios para el aumento de la precisión en los sistemas de detección y tracking, como se ha visto en el apartado 1.2.1, los sensores ofrecen información diferente al resto, por lo que el aumento de precisión se produce por el aumento en la cantidad de datos proveniente de todos los sensores. La complejidad de estas técnicas radica en el uso eficiente de todos los sensores.

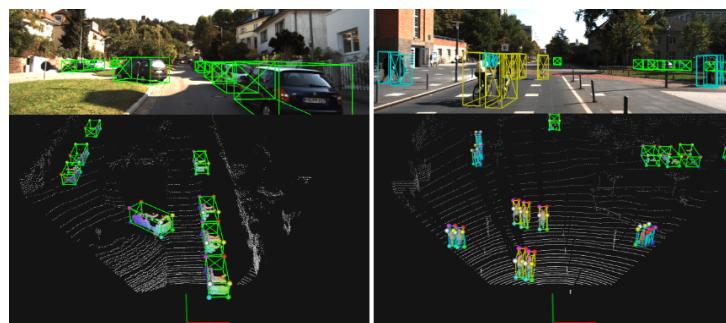


Figura 1.10: Fusión sensorial utilizando cámara y LiDAR.

Para la realización de un sistema de fusión sensorial se pueden tomar diversos acercamientos, en una early fusion se tratan todos los datos en crudo de los sensores para obtener un mejor sistema de percepción, si se trabaja con sensores tratados pero no con las detecciones finales se trata de una middle fusion, en el caso de utilizar las detecciones finales estaríamos ante una late fusion.

Entre las técnicas más utilizadas para sistemas de fusión sensorial encontramos los KF, EKF y UKF [12], pero también se comienzan a utilizar técnicas más complejas que radican en el uso de redes neuronales para la fusión.

1.3 Deep Learning

Gracias al aumento en capacidad de computo, la mejora en el procesamiento de grandes volúmenes de datos y el desarrollo de nuevos algoritmos que aprendan con estos datos, se ha producido un estallido en el uso de técnicas basadas en redes neuronales. Desde 1958 con la creación del Perceptrón se conoce de este tipo de técnicas, pero a principios del siglo XXI es cuando realmente se ve su potencial.

Las redes neuronales profundas o Deep Learning son aquellas redes neuronales con múltiples capas intermedias que permiten la extracción del conocimiento. Estas son utilizadas en ámbitos como el análisis de datos tabulares, modelos del lenguaje o sistemas de visión que es donde se centrará este estudio.

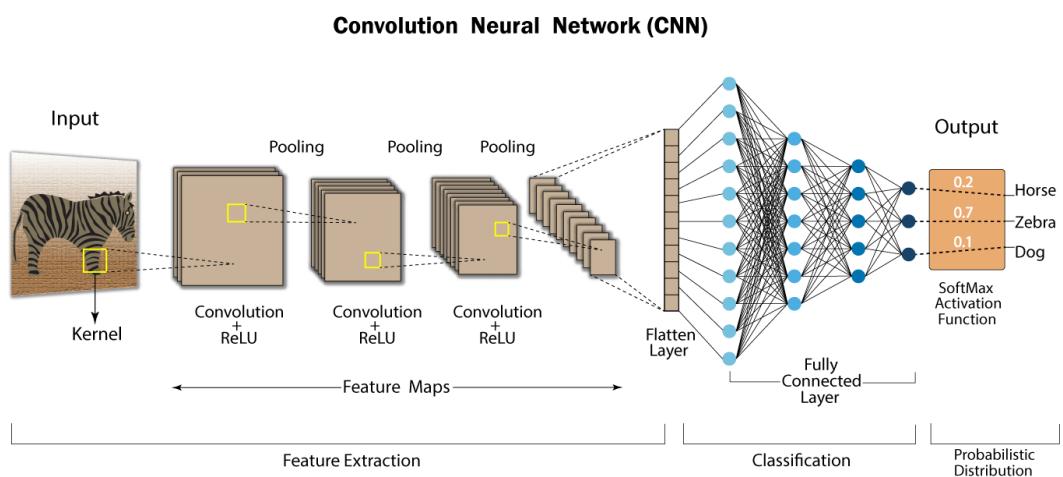


Figura 1.11: Convolutional Neural Network.

En el campo de la visión artificial las Redes Neuronales Convolucionales o Convolutional Neural Network (CNN) han conseguido una mejora importante en la precisión de los modelos. Estas redes son utilizadas principalmente para su uso con cámaras ya que su estructura tridimensional funciona de forma muy buena con las CNN. Un modelo típico para uso con imágenes sería [1.11](#).

Para los sistemas de detección con LiDAR basados en Deep Learning se utilizan principalmente las CNN junto con capas Fully Connected (FC), ya que son las que obtienen un mejor rendimiento como se verá en el capítulo 4.

Capítulo 2

Propuesta de trabajo

La educación científica de los jóvenes es al menos tan importante, quizá incluso más, que la propia investigación.

Glenn Theodore Seaborg

Este trabajo se encuentra ubicado dentro del proyecto Tech4AgeCars desarrollado en el grupo RobeSafe. En este se pretende realizar un estudio de diferentes técnicas de detección utilizando [LiDAR](#), tanto con métodos clásicos como basados en Deep Learning para el análisis en datasets reales, en el simulador CARLA y en el coche real del grupo.

En la arquitectura del proyecto se tiene implementado un procesamiento basado en PointPillars a partir de una nube de puntos proporcionada por el [LiDAR](#), para una ejecución en tiempo real sobre una plataforma NVIDIA Jetson AGX Xavier [13], por lo que se pretende mejorar el sistema de percepción que hace uso del [LiDAR](#), utilizando para ello otro modelo perteneciente al [SOTA](#).

Para ello se pretende mejorar el modelo de detección con [LiDAR](#) mediante la aplicación de un modelo del algoritmo PointPillars Multihead, y se realiza una fusión sensorial entre cámara y [LiDAR](#) junto con un compañero del grupo RobeSafe que se encuentra realizando un TFG de detección 3D utilizando únicamente una cámara [14].

Tras una fusión y sin la posibilidad de analizar el sistema de percepción creado, se trabajará por último en un proyecto junto con el Karlsruhe Institute of Technology (KIT) llamado Autonomous Driving Development Kit (AD DevKit) que tratará de analizar un [Automated Driving System](#), en concreto se trabajará en el apartado de percepción del kit de desarrollo, todo ello esperando que este proyecto no solo sea útil para los compañeros del proyecto sino para cualquier desarrollador que utilice el simulador CARLA, ya que se tiene previsto proporcionar el [AD DevKit](#) de forma Open-Source.

Capítulo 3

Sistemas clásicos de percepción con LiDAR

El placer más noble es el júbilo de comprender.

Leonardo da Vinci

Mientras que se tienen múltiples tipos de técnicas de percepción tanto clásicas como basadas en Deep Learning, el uso de técnicas clásicas utilizando únicamente **LiDAR** no abundan, por lo que se presentan las técnicas estudiadas e implementadas en el simulador CARLA para la detección de los objetos del entorno.

3.1 Voxelización

Las nubes de puntos generadas por el **LiDAR** pueden ser de hasta 1.300.000 puntos por segundo en un **LiDAR** de 64 haces [5] lo que implicaría el análisis de una gran cantidad de datos en tiempo real lo que puede no ser muy viable ya que se tiene una capacidad de computo limitada en un vehículo.

Para ello se utiliza la voxelización, esta no solo se utiliza en sistemas de percepción, sino que también es utilizada en imágenes volumétricas de ámbito médico, para la representación del terreno o en el pipeline gráfico de un ordenador. Esta técnica trata de reducir la cantidad de datos en memoria a la vez que reduce el computo al reducir la resolución de la escena. Por lo que se puede entender como un proceso de discretización del entorno.

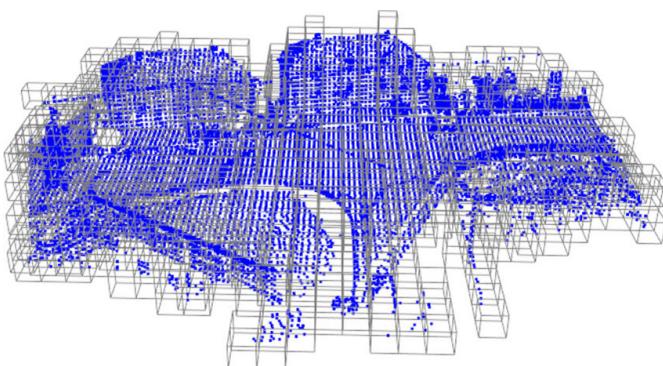


Figura 3.1: Entorno 3D voxelizado.

Trabajando con nubes de puntos, la voxelización sigue los siguientes pasos:

1. Definición del tamaño del vóxel, lo que sería un vector tridimensional.
2. A partir del tamaño del vóxel se divide la escena en un conjunto de ortoedros u vóxeles.
3. Si se encuentra un punto del Light Detection and Ranging (LiDAR) dentro de un vóxel este de activa

Esta técnica como se verá en el capítulo 4, también se utiliza en diversos modelos basados en Deep Learning, esto se hace para trabajar de forma similar a lo que sería la estructura de una imagen que se encuentra compuesta por píxeles en vez de por vóxeles.

3.2 RANSAC-3D

Para la detección de los objetos del entorno no es necesaria la información de los puntos que inciden en el suelo, por lo que una de las técnicas utilizadas para la selección del plano perteneciente al suelo es Random Sampling and Consensus (RANSAC)-3D.

El algoritmo **RANSAC** [15] tiene una funcionalidad similar a la regresión lineal, ambos algoritmos a partir de un conjunto de datos hayan la relación lineal entre dos características. La creación de este algoritmo tenía como finalidad el ajuste de datos experimentales, el uso en el análisis de escenas y la generación automática de mapas.

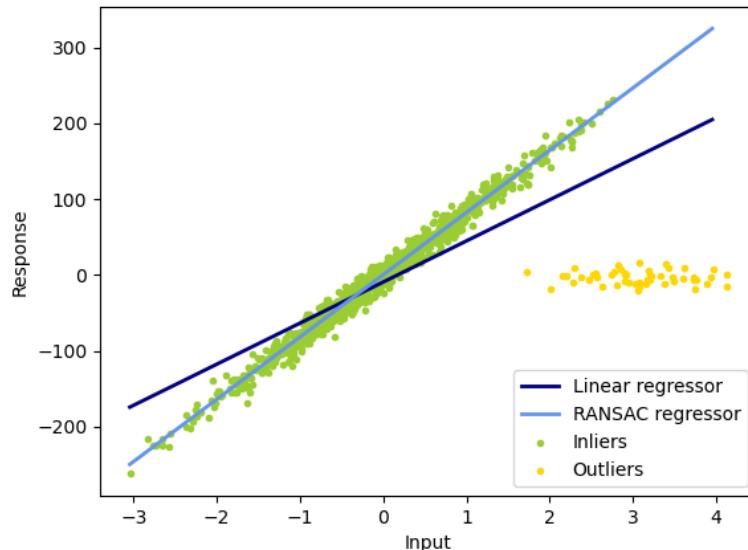


Figura 3.2: Aplicación de RANSAC para detección de outliers.

La idea principal del algoritmo **RANSAC** es la generación de rectas a partir de 2 o más puntos para aceptar como la mejor recta aquella que contenga más puntos entre un límite seleccionado, y esto es repetido un número arbitrario de veces. Esta recta será la que contenga los puntos asumidos como normales o inliers, y el resto de puntos son asumidos como anómalos o outliers. La función completa utiliza el siguiente algoritmo 3.1.

Input

data Conjunto de observaciones
 model Modelo que explica las observaciones
 n Mínimo número de puntos necesarios para estimar un modelo
 k Número de iteraciones del algoritmo
 t Valor límite que indica que puntos se encuentran bien estimados
 d Número de puntos cercanos que asegura que el modelo sea válido

Output

```

bestFit Parámetros del modelo que ajustan de mejor manera a los datos

iterations ← 0
bestFit ← null
bestError ← ∞

while iterations < k do
  maybeInliers ← n puntos seleccionados aleatoriamente
  maybeModel ← modelo que se ajusta a maybeInliers
  alsoInliers ← set vacío
  for cada punto que no se encuentre en maybeInliers do
    if error de ajustar el punto a maybeModel < t then
      | añadir punto a alsoInliers
    end
  end
  if número de puntos en alsoInliers > d then
    betterModel ← parámetros del modelo sobre el que han sido ajustados los puntos de
    maybeInliers y alsoInliers
    thisErr ← medida de como de bien han sido ajustado los puntos;
    if thisErr < bestErr then
      | bestFit ← betterModel
      | bestErr ← thisErr
    end
  end
  iterations ← iterations+ 1;
end

```

Algoritmo 3.1: Algoritmo RANSAC

En el caso de las nubes de puntos que devuelve el [LiDAR](#), se trabaja en un entorno tridimensional, por lo que no funciona de la misma manera dicho algoritmo, se utiliza una variación, [RANSAC](#)-3D como se ve en la figura 3.3, que en vez de trabajar con datos en 2D se trabajan en 3D, por lo que se pasa de ajustar una recta a ajustar un plano, se necesitan al menos tres puntos para generar un posible modelo, ya que es el mínimo número de puntos para generar un plano, el resto funciona de forma similar definiendo el límite de distancia, iteraciones, etc.

Como se ha explicado, los resultados suelen ser similares a una regresión lineal en un entorno bidimensional, pero en este caso no sería del todo cierto, ya que el plano que abarca más puntos suele ser en la mayoría de los casos el correspondiente al suelo. Esto implica una modificación de la regresión lineal a las tres dimensiones, esto es una regresión ajustada como un plano, lo que generará en la mayoría de las situaciones un plano que se encuentra por encima del suelo, ya que trataría de minimizar una métrica de error al plano (distancia euclídea, manhattan, minkowski, hamming, etc.), por lo que los objetos de la escena levantarían el plano para minimizar el error de este a los puntos correspondientes a los objetos.

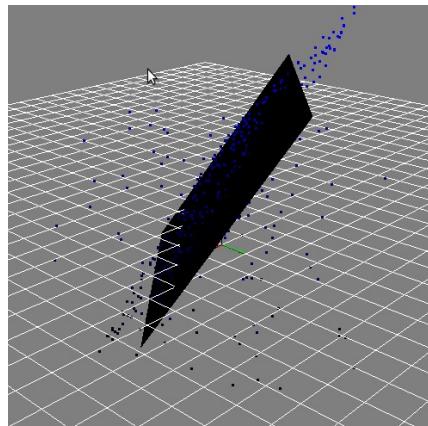


Figura 3.3: Aplicación de RANSAC-3D.

De forma comparativa al algoritmo **RANSAC**-3D, se genera un plano ajustándose a la mayoría de los puntos de la escena, anotando como inliers aquellos puntos pertenecientes al suelo y dejando el resto de puntos que colisionan con el entorno como outliers, por lo que dicho algoritmo **RANSAC** es el utilizado para la tarea de filtrado de la sección de la nube de puntos que colisiona con el suelo de la escena.

3.3 KD-tree

Tras la eliminación del suelo en la nube de puntos podemos encontrarnos con que los diferentes objetos del entorno se encuentran separados, ya que el suelo era el elemento unificador de la mayoría de puntos de la escena. Teniendo en cuenta esto, es necesario el uso de una técnica que sea capaz de agrupar los puntos más cercanos por distancia, ya que si se hace comprobando cada punto con el resto se obtendría una complejidad de $O(n^2)$.

Teniendo en cuenta el coste computacional de los algoritmos de clustering y al trabajar con tantos puntos, alrededor de 1.000.000 por segundo y sabiendo que un **LiDAR** suele trabajar a 10 Hz, es muy recomendable aplicar una voxelización si no se aplicó previamente en la eliminación de los puntos incidentes en el suelo.

Para el clustering, se podría utilizar el algoritmo K Nearest Neighbors (KNN), pero esto produciría clústeres no válidos al encontrarse objetos con pocos véxeles o con demasiados, lo que produciría clústeres incompletos y otros mal formados sino se tiene en cuenta una distancia máxima entre véxeles.

El KD-tree [16] es una estructura de datos que con un eficiente uso de memoria, es capaz de hacer búsquedas en un entorno K dimensional con una complejidad media de $O(\log n)$, esto lo convierte en una gran estructura para trabajar con datos en un entorno tridimensional, como es el caso de las nubes de puntos o de véxeles. Un KD-tree tiene una estructura similar a un árbol binario, la eficiencia de la estructura radica en la ordenación del mismo, donde en cada altura del árbol se ordena según una dimensión iterativamente.

Antes de analizar en profundidad la estructura KD-tree, es necesario comprender los árboles binarios, tanto su uso, como su utilidad. Los árboles binarios son una estructura de datos donde cada nodo tiene otros dos nodos hijos, referidos como hijo izquierdo e hijo derecho. La utilidad de la estructura radica en la forma en la que se pueden guardar los datos, mientras que para buscar un valor en una lista, es necesario iterar por todos ellos o hasta que se encuentre con una complejidad máxima de $O(n)$, lo que hace que un KD-tree tenga una complejidad máxima de $O(\log_2 n)$.

Input

tree Árbol binario ordenado
key Clave del nodo buscado

Output

node Nodo buscado

```

node ← null;
currentNode ← nodo raíz de tree
while currentNode ≠ null do
    if clave de currentNode = key then
        | node ← currentNode
        | break;
    end
    if clave de currentNode < key then
        | currentNode ← hijo derecho de currentNode
    else
        | currentNode ← hijo izquierdo de currentNode
    end
end

```

Algoritmo 3.2: Búsqueda en árbol binario ordenado

En el caso del árbol de la figura 3.4 para buscar el número 7 se utiliza el siguiente procedimiento:

1. Se empieza por el nodo con valor 8
2. Al ser $7 < 8$ se pasa al hijo de la izquierda
3. Como $7 > 3$ se salta al hijo de la derecha
4. Teniendo el nodo con valor 6, siendo menor que 7 se coge el hijo de la derecha
5. Por último, se llega al nodo con valor 7 requerido

Teniendo 9 nodos solo ha sido necesario analizar 4 nodos que es la peor situación con este árbol.

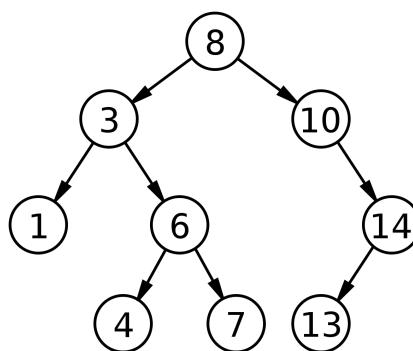


Figura 3.4: Árbol binario ordenado.

Al contrario que los árboles binarios, un KD-tree es capaz de localizar un número de K dimensiones, por lo que hay una diferencia principal que es la rotación entre la dimensión sobre la que se ordena en cada altura del árbol. Esto produce que la forma de inserción del algoritmo 3.3 y búsqueda sea modificada.

Input

tree KD-tree
 node Nodo a introducir
 k Número de dimensiones del árbol

Output

tree KD-tree con el nodo introducido
 $currentNode \leftarrow$ nodo raíz de tree
 $depth \leftarrow 0$
while $currentNode \neq null$ **do**
 | $x \leftarrow depth \bmod k$
 | **if** valor de $currentNode$ en la dimensión $x <$ valor de $node$ en la dimensión x **then**
 | | $currentNode \leftarrow$ hijo derecho de $currentNode$
 | **else**
 | | $currentNode \leftarrow$ hijo izquierdo de $currentNode$
 | **end**
 | $depth \leftarrow depth + 1$
end
 $currentNode \leftarrow node$

Algoritmo 3.3: Inserción en KD-tree

Lo que produce esta forma de guardar los datos en el árbol, es que según se aumenta la profundidad en el árbol, la región de los nodos hijos es cada vez menor, lo que permite una más sencilla agrupación y estudio de los datos por regiones en un entorno K dimensional. Como se ve en la figura 3.5 el espacio bidimensional va siendo dividido por regiones, esto es gracias a que cada nodo divide en dos el espacio sobre el que se encuentran sus hijos, lo cual es una perfecta manera de agrupar los puntos en clústeres utilizando esta estructura, tal y como se detalla en el algoritmo 3.4




Figura 3.5: Espacio bidimensional dividido por un KD-tree.




Figura 3.6: Estructura de un KD-tree de dos dimensiones.

Input

points Nube de puntos del LiDAR
 id_node Id del punto sobre el que se va a comenzar el clúster
 node Nodo sobre el que buscar un clúster
 processed Vector de booleanos de tamaño igual al número de puntos
 tree KD-tree
 distance Distancia máxima a los puntos del clúster
 k Número de dimensiones del árbol

Output

cluster Conjunto de los puntos perteneciente al clúster

```

Function proximity (points, id_node, node, cluster, processed, tree, distance, k):
  processed[id_node] ← true
  añadir a cluster points[id_node]
  indexList ← search (points[id_node], tree, distance, k) for index en indexList do
    if processed[index] = false then
      | proximity (points, index, cluster, processed, tree, distance, k)
    end
  end

Function search (node, tree, distance, k):
  indexList ← lista vacía
  searchNodes (node, tree, 0, distance, indexList, k)
  return indexList

Function searchNodes (node, tree, distance, depth, indexList, k):
  if tree ≠ null then
    if distancia entre el nodo raíz de tree y node < distance then
      | añadir índice del nodo raíz de tree a indexList
    end
  end
  x ← depth mod k
  if valor de node en la dimensión x – distance < valor del nodo raíz de tree en la dimensión
  x then
    | searchNodes (node, árbol izquierdo de tree, depth+1, distance, indexList, k)
  end
  if valor de node en la dimensión x + distance > valor del nodo raíz de tree en la dimensión
  x then
    | searchNodes (node, árbol derecho de tree, depth+1, distance, indexList, k)
  end

```

Algoritmo 3.4: Cluster por distancia en KD-tree

Gracias a la estructura KD-tree, se puede reducir la cantidad de nodos o puntos analizados, ya que cada punto no tiene que ser estudiado con el resto sino que solo se estudian los puntos que están en una región cercana dentro del radio máximo de distancia definido. Lo que produce una complejidad de $O(n * \log n)$ para la construcción de la estructura más la complejidad $O(n * \log n)$ de la función de clustering por distancia, por lo que en total se tendría una mejora de complejidad de $O(n^2)$ a $O(n * \log n)$.

La eficiencia de esta estructura en ciertas tareas, ha producido que a pesar de ser una técnica del año 1975, se siga estudiando para su utilización junto a KNN [17], aumentando su rendimiento con datos preordenados [18] o la paralelización de su construcción en técnicas como KNN [19].

3.4 Filtrado previo y posterior a la detección

Tras la obtención de las detecciones por parte de los diversos algoritmos clásicos podemos encontrarnos ante diferentes problemas con dichas detecciones.

Estas pueden generar clústeres con pocos o demasiados puntos, lo que puede resultar en clústeres incorrectos. Aquellos con pocos puntos pueden identificar objetos lejanos u objetos que no son necesarios para el entendimiento de la escena, por otra parte, aquellas detecciones con muchos puntos pueden identificar camiones, vehículos de construcción o simplemente objetos muy cercanos, pero también es muy normal que las construcciones sean detectadas por lo que hay que filtrar tanto por un número máximo como mínimo de puntos para obtener mejores detecciones.

Otra práctica para el filtrado, es el ajuste a unos tamaños prefijados en todas las dimensiones, lo cual elimina aquellos objetos que no son similares a los vehículos que se desean detectar.

Estas técnicas de filtrado no solo se pueden utilizar tras la obtención de las detecciones, sino que la nube de puntos obtenida del [LiDAR](#) es posible filtrarla, para que así solo se trabaje con una Region of Interest (RoI), ya que a partir de cierta distancia las detecciones no van a ser muy precisas, para ello se puede filtrar también por distancia al vehículo. Además, un filtrado que permita trabajar únicamente con la parte delantera y trasera del coche, aporta una reducción en el computo de los algoritmos, a la vez que se reducen las falsas detecciones.

Capítulo 4

Sistemas de percepción con LiDAR basados en Deep Learning

Si no conozco una cosa, la investigaré.

Louis Pasteur

Los sistemas de percepción actuales del estado del arte o State of the Art (SOTA) se basan en Deep Learning. Esto no es diferente en los sistemas de percepción basados en LiDAR, por lo que en este capítulo se presentan los datasets disponibles para el entrenamiento y evaluación de los modelos, las diferentes arquitecturas SOTA para detección con LiDAR y la herramienta utilizada para la evaluación, entrenamiento y pruebas realizadas sobre los modelos.

4.1 Principales datasets

Para el desarrollo de un modelo de percepción basado en Deep Learning, es siempre necesario un conjunto de datos anotados o dataset sobre el que un modelo pueda aprender. En los últimos años muchas compañías han lanzado datasets para poder entrenar y validar sus modelos, además de que muchos de estos datasets han sido publicados de manera Open-Source para fomentar el desarrollo de nuevas técnicas.

Entre los datasets para conducción autónoma encontramos: A2D2 Dataset [20], Argoverse Dataset [21], CityScapes Dataset [22], KITTI Vision Benchmark Suite [23], Level 5 Open Data [24], nuScenes Dataset [25] o Waymo Open Dataset [26] entre otros.

En este apartado se van a presentar tres de los datasets más importantes en la industria del automóvil, como son KITTI, nuScenes y Waymo dataset.

4.1.1 KITTI

La suite de evaluación de KITTI [23] es un sistema de evaluación para vehículos autónomos, donde se ha desarrollado una plataforma de referencia para tareas de visión estereoscópica, flujo óptico, odometría visual/SLAM y detección de objetos 3D.

Este dataset fue presentado en 2012 en conjunto por el KIT y el TTIC, iniciando lo que años después despertaría un interés en la creación de datasets Open-Source para sistemas ADAS/ADS. Al ser el

primer dataset con reconocimiento internacional, fijó las bases de lo que sería el futuro de los sistemas de evaluación, además que ha sido desde su salida uno de los sistemas de evaluación más estandarizados en el desarrollo de técnicas de conducción autónoma, como se puede ver en sus más de 7.000 citas.




Figura 4.1: Estructura del dataset de KITTI.

El sistema de percepción del vehículo utilizado para la grabación de los datos se encuentra compuesto de:

- 2 sistemas de cámaras estéreo de una resolución de 1240 x 376 píxeles.
- 1 LiDAR Velodyne HDL-64E capaz de generar más de un millón de puntos por segundo gracias a sus 64 haces láser.
- 1 sistema de localización SOTA compuesto por GPS, GNSS, IMU y corrección de señales RTK.

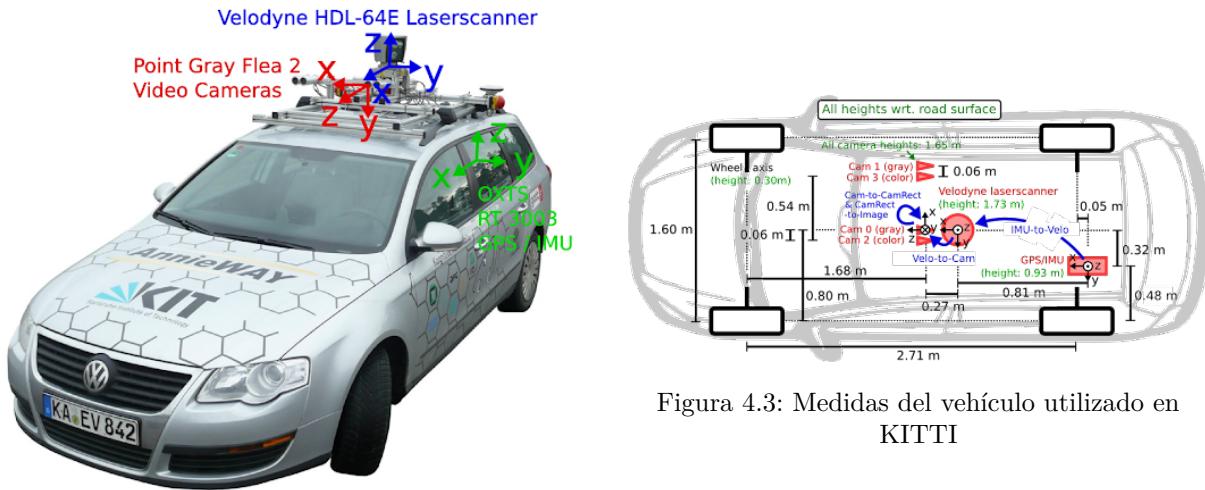


Figura 4.2: Vehículo utilizado en KITTI.

La estructura del dataset es tal y como se muestra en la figura 4.1. Dentro de este dataset los datos se dividen según el día de grabación y la escena, y dentro de cada escena se tienen las imágenes de la cámara estéreo monocromática (image_00, image_01) y RGB (image_02, image_03), información de todo el sistema de localización del vehículo (oxts) y las nubes de puntos provenientes del LiDAR (velodyne_points).

En 2020 tras el éxito de este dataset se anuncia y se lanza KITTI-360 [27], la evolución del dataset KITTI, el cual trae mejoras añadiendo dos cámaras de ojo de pez para una obtención de visión 2D en todos los ángulos del vehículo, y una unidad láser adicional SICK. Además se incluyen en el dataset bounding boxes 3D de todo el entorno, anotaciones de instancia a partir de la información del LiDAR y anotaciones de confianza sobre el vídeo tomado por las cámaras, entre otras.

4.1.1.1 Análisis de la estructura del GT y las PCLs de KITTI

Al estar basado este trabajo en la detección utilizando LiDAR, se estudia la forma en la que se guardan los datos de las nubes de puntos junto con la representación del groundtruth, para ello se analiza tanto la carpeta de velodyne_points como el archivo tracklets.xml.

Para el trabajo con bounding boxes 3D, es posible utilizar únicamente el kit de detecciones 3D que contiene un conjunto de txt con la información de los objetos por cada barrido. Estos archivos contienen la información de: tipo, truncado, ocluido, bounding box 2D, dimensiones y localización. Todas estas características acerca de los objetos se encuentran de la misma manera en el archivo tracklets.xml, pero la información de rotación se encuentra dividida en un ángulo alpha y otro rotation_y, en vez de rotación por cada uno de los tres ejes, los cuales se estudiarán más en profundidad en el capítulo 6.

Se utiliza el archivo *tracklets.xml* ya que define el groundtruth de la escena pero no por cada barrido del [LiDAR](#), sino que se guarda por cada escenario, lo que se traduce en un estructura que se puede utilizar tanto para detección como para seguimiento de los objetos, todo ello como un archivo con formato [XML](#).

Se ha decidido crear un programa que lea la nube de puntos indicada y que marque en un entorno 3D la posición de los objetos de la escena. Esto podría ser realizado mediante el devkit que KITTI ofrece, pero se encuentra únicamente de forma oficial en Matlab, por lo que como los modelos de Deep Learning a utilizar se encuentran en Pytorch, se ha decidido analizar los datos utilizando Python.

La figura 4.4 muestra la estructura de los principales atributos del archivo *tracklet_labels.xml* analizado. Encontramos el número de los diferentes objetos del escenario, a continuación se analiza cada objeto a través de los diferentes barridos, mostrando primero las características de los objetos que se mantienen en el tiempo, como las dimensiones o el tipo de objeto y después se guarda la información de posición, rotación, etc.




Figura 4.4: Estructura del archivo *tracklet_labels.xml*.

Tras dicho análisis, utilizando la librería MayaVi para la visualización del entorno 3D, NumPy para las transformaciones en el espacio y Beautiful Soup para la lectura del [XML](#), se visualizan múltiples escenas del dataset.

Cabe destacar que como KITTI está realizado para que la parte de percepción se trabaje principalmente con las cámaras frontales del vehículo, aún teniendo información por los laterales y la parte trasera gracias al LiDAR, esta no se tiene en cuenta en el groundtruth, razón por la que en la imagen 4.5 los vehículos de la parte trasera no se muestran.

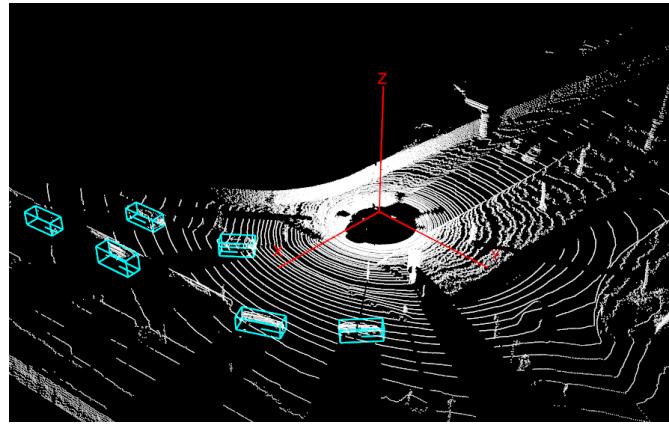


Figura 4.5: Visualización de una nube de puntos de KITTI junto con su groundtruth.

Todo el código utilizado para la visualización de los objetos junto con unos escenarios de ejemplo es accesible públicamente en el siguiente enlace: https://github.com/Javier-DlaP/Display_kitti_pcl_annotations

4.1.2 Waymo

Waymo Open Dataset [26] es el dataset liberado de forma Open-Source por parte de Waymo y Google para la aceleración del desarrollo de tecnologías de conducción autónoma.

La propuesta de este dataset es la oferta de un gran número de anotaciones de alta calidad tanto 2D como 3D, que además contienen información de seguimiento. Se han utilizado múltiples ciudades para sus escenarios grabados, como son: San Francisco, Mountain View, Los Angeles, Detroit, Seattle y Phoenix. Además se trabaja con multitud de entornos y condiciones ambientales como son: construcciones, atardeceres, noches, días lluviosos, etc.

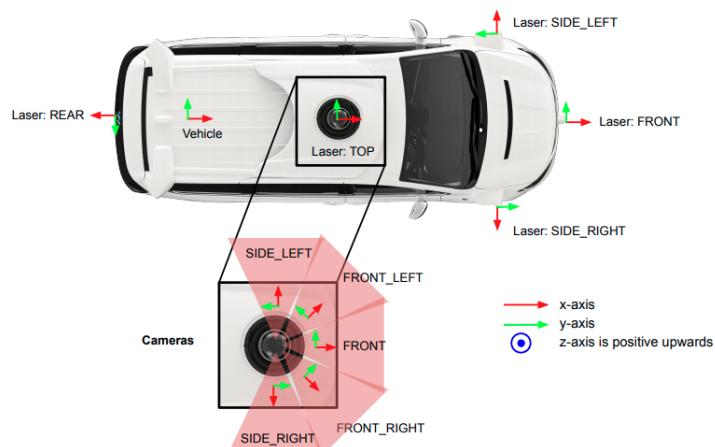


Figura 4.6: Vehículo utilizado en Waymo.

Actualmente el dataset ofrece 1.950 escenas [28] que fueron aumentadas de las 1150 escenas en la salida de la primera revisión del paper de referencia, de 20 segundos cada una, con información recogida a 10 Hz proveniente de los sensores, lo que implican 390.000 frames. Toda esta información es recabada de:

- 1 LiDAR de medio alcance.
- 4 LiDAR de corto alcance.
- 5 cámaras alrededor del vehículo.

Como se ve en la figura 4.6, el acercamiento de la compañía entorno a la construcción del vehículo no utiliza Radar, depende únicamente de cámaras y LiDAR para el apartado de percepción. Por lo que no se puede trabajar con Radar en el dataset, además de que no se tiene información de ningún sistema de localización, ya que dicho dataset se encuentra especializado en tareas de percepción y seguimiento de los objetos de la escena.

Es importante tener en cuenta que en este dataset, la nube de puntos procedente del LiDAR no utiliza un sistema de coordenadas cartesiano, sino un sistema de coordenadas esférico, donde las coordenadas (x, y, z) son reemplazadas por (distancia, azimuth, inclinación).

$$\text{distancia} = \sqrt{x^2 + y^2 + z^2}$$

$$\text{azimuth} = \text{atan2}(y, x)$$

$$\text{inclinación} = \text{atan2}(z, \sqrt{x^2 + y^2})$$

Mientras que en otros datasets se tienen multitud de clases, muchas de ellas indistinguibles unas de otras, Waymo utiliza únicamente 4 tipos de objetos diferentes. En las 11,8 millones de bounding boxes 2D se encuentran vehículos, peatones y ciclistas, mientras que en las 12,6 millones de bounding boxes 3D se añaden además la detección y seguimiento de señales.

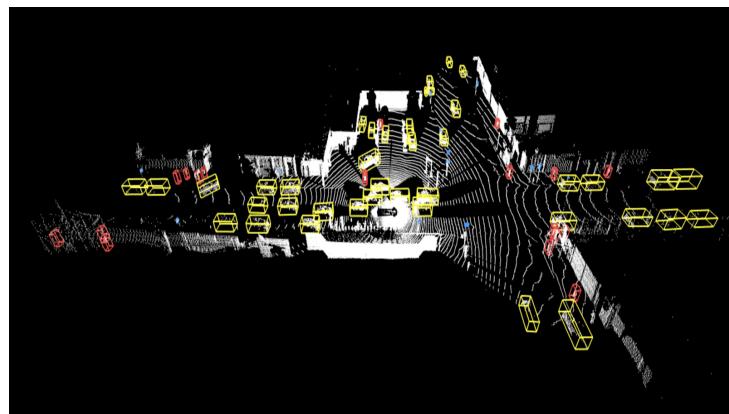


Figura 4.7: Nube de puntos con las diferentes clases del dataset de Waymo.

En la figura 4.7 encontramos las diferentes clases a detectar y seguir en el dataset, teniendo en amarillo los coches, rojo los peatones, azul las señales y rosa los ciclistas.

Waymo ofrece un dataset muy completo si solo se desea trabajar con tareas de percepción, compitiendo cara a cara con los datasets más importantes como son KITTI, nuScenes y Argoverse, teniendo además uno de los sistemas de evaluación para tareas de percepción orientadas a vehículos autónomos, más grandes y con más anotaciones que se pueden encontrar de forma Open-Source.

4.1.3 nuScenes

NuScenes Dataset [25] se presenta como una mejora al dataset KITTI lanzado en 2012. Esta mejora no solo radica en la calidad de los datos sino en el número de diferentes situaciones disponibles, de la misma manera que Waymo, ofreciendo situaciones nocturnas y días lluviosos.

En comparación con otros datasets, se incluye un set más completo de sensores como son:

- Sistema de 6 cámaras para tener una percepción visual de 360° con una resolución de 1600 x 900 por cámara.
- LiDAR de 32 haces con una frecuencia de 20 Hz, capaz de generar hasta 1,4 millones de puntos por segundo.
- Sistema de 5 Radar con una distancia máxima de 250 metros y una frecuencia de 13 Hz.
- Sistema de localización compuesto por GPS, IMU, AHRS y un sistema de posicionamiento RTK.




Figura 4.8: Vehículo utilizado en el dataset de nuScenes.

NuScenes tiene 23 clases diferentes a detectar, entre ellas se encuentran como en el resto de datasets: coches, ciclistas, peatones, etc. Pero en este se encuentran además animales, diferenciación por el tipo de los peatones, como serían policías o personas en silla de ruedas, además de barreras entre otras. Esto permite agrupar las clases para detectar únicamente las más simples o servir como un sistema de evaluación con toda la información necesaria para la implementación en un sistema ADS.

El sistema de evaluación de nuScenes permite evaluación de múltiples sistemas a diferentes niveles. Las diferentes tareas a evaluar son:

- Detección de objetos 3D (10 tipos de objetos diferentes) utilizando cámara, LiDAR, Radar y la información de los mapas.
- Seguimiento de objetos 3D (7 tipos de objetos diferentes) utilizando cámara, LiDAR, Radar y la información de los mapas.
- Predicción del movimiento y de la posición de los objetos.
- Segmentación semántica de la nube de puntos del LiDAR.

El dataset completo de nuScenes ocupa medio terabyte, esto es debido a la cantidad de información que tiene, la cual se encuentra dividida en: mapas, información de los sensores en los frames que se tienen

anotaciones, información de los sensores sin anotaciones y una carpeta v1.0-trainval que contiene todos los archivos json que relacionan todo el dataset además del groundtruth, como se muestra en la figura 4.9.

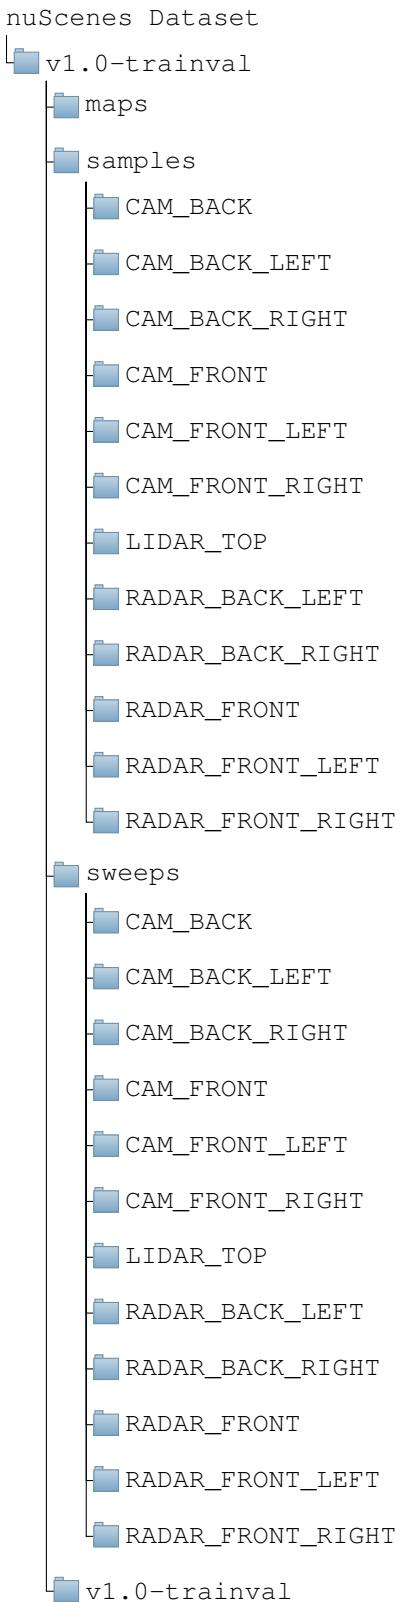


Figura 4.9: Estructura del dataset nuScenes.

Dicha estructura es para el uso de todos los sensores del dataset y los mapas, pero en el caso de que se requieran únicamente la información proveniente de las cámaras, nuScenes ofrece nuImages, un dataset de nuScenes reducido, que además cambia la estructura interna de este.

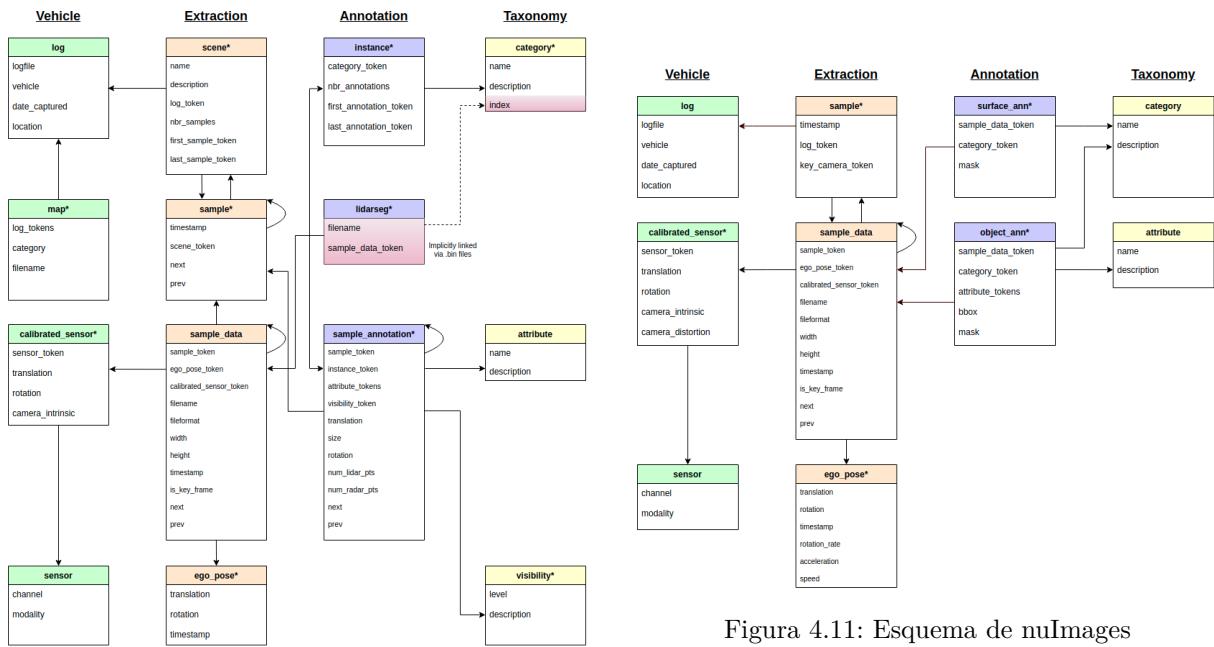


Figura 4.10: Esquema de nuScenes.

Las estructuras de estas versiones del dataset, no son sencillas de trabajar con los datos directamente, por lo que nuScenes ha desarrollado un devkit con el que sea más sencillo el desarrollo y evaluación de modelos sobre ambas versiones del dataset.

4.1.3.1 NuScenes devkit

Promover el uso de un dataset es importante en la medida que si no ofrece características nuevas en este o es difícil de utilizar, no destacará y desaparecerá entre la gran cantidad de datasets disponibles hoy en día. Para ello, nuScenes desarrolla y lanza la herramienta Open-Source nuScenes devkit.


NuScenes devkit, ofrece un uso muy simplificado del dataset de nuScenes y nuImages. Ambos datasets incorporan a partir de archivos json una estructura similar a la de una base de datos relacional en la que a partir de claves primarias, externas e índices se consigue tener un conjunto de datos normalizado, para así minimizar al máximo la redundancia de datos.

Al ofrecer una gran cantidad de datos no solo de los sensores sino de la escenas, configuraciones de calibración, visibilidad, categorías, etc., se ha estructurado en diferentes archivos json para no tener que repetir datos por cada imagen o nube de puntos. El devkit ha sido programado para su uso en Python 3 y los tutoriales para aprender a utilizar dicho devkit se encuentran en Jupyter Notebooks, aunque también se recomienda su uso en Google Colab.

Para el aprendizaje del devkit de nuScenes se descarga la versión mini del dataset, el cual tiene la misma estructura que el dataset completo. Junto con Jupyter se estudia todo el dataset siguiendo los diferentes tutoriales que ofrece. Tras trabajar con la herramienta y acostumbrarse al uso de los tokens que relacionan los diferentes archivos json, es muy sencillo obtener todos los datos requeridos.

A partir del devkit es muy sencillo realizar tareas como filtrado de clases, agrupaciones, transformaciones mundo a cámara, seguimiento de objetos individualizado, etc. De esta manera se ahorra mucho

Figura 4.11: Esquema de nuImages



tiempo en la construcción de complejas funciones ya que se encuentran insertadas en el kit de desarrollo, además de que permite ver de forma analítica el comportamiento del dataset.

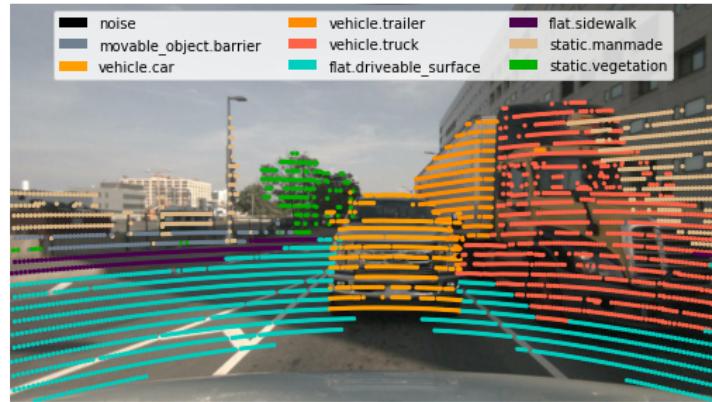


Figura 4.12: Transformación mundo a imagen de la nube de puntos segmentada en el devkit de nuScenes.

Con código tan simple como el mostrado en el listado 4.1 es muy fácil obtener la imagen de una cámara con la nube de puntos segmentada tras realizar una transformación de mundo a cámara tal y como se ve en la figura 4.12. Dichas transformaciones, como se verá en el capítulo 6.2.2, no es algo inmediato, por lo es necesario cierto conocimiento del funcionamiento de las cámaras y de transformaciones geométricas.

Listado 4.1: Obtención de una nube de puntos segmentada sobre una imagen utilizando nuScenes devkit

```
from nuscenes import NuScenes

nusc = NuScenes(version='v1.0-mini',
                 dataroot='/home/javier/nuScenes-dataset-mini-v1.0',
                 verbose=True)
my_sample = nusc.sample[87]

nusc.render_pointcloud_in_image(my_sample['token'],
                                pointsensor_channel='LIDAR_TOP',
                                camera_channel='CAM_BACK',
                                render_intensity=False,
                                show_lidarseg=True,
                                filter_lidarseg_labels=[22, 23],
                                show_lidarseg_legend=True)
```

4.1.4 Comparativa entre los diferentes datasets

Tras el estudio y análisis de los datasets de KITTI, Waymo y nuScenes se obtiene un conocimiento de las arquitecturas hardware utilizadas en el estado de arte del campo de los datasets de conducción autónoma, además de los sistemas de evaluación utilizados.

Mientras que KITTI fue el primer dataset desarrollado para conducción autónoma con reconocimiento internacional, hasta hace muy poco, era utilizado en exclusiva para la comparativa de modelos aplicables a conducción autónoma. Waymo y nuScenes aparecieron años más tarde con una apuesta clara en el uso

de más sensores, además del estudio de los 360° del entorno y no solo de la parte frontal del vehículo como realiza KITTI.

En la parte del hardware, se ha visto que el acercamiento por parte de KITTI de tener 4 cámaras frontales es un enfoque equivocado para un coche real, ya que se necesita tener un rango de visión mayor en el sistema de cámaras. Por parte del uso del [LiDAR](#), nos encontramos con que KITTI solo usa la parte frontal de la nube de puntos, mientras que Waymo y nuScenes utilizan toda la nube de puntos para generar las detecciones. Entre estos dos datasets encontramos diferencias en el número de [LiDAR](#) utilizados, ya que mientras nuScenes utiliza solo uno, Waymo utiliza cinco, lo que le permite obtener mucha más información del entorno y una nube de puntos más densa, pero aumenta en mayor medida el precio de un prototipo con estas características. El [Radar](#) es un sensor desaparecido tanto en KITTI como en Waymo pero que se encuentra en nuScenes ofreciendo una nube de puntos de 360° que es capaz de inferir la velocidad de los objetos, pero con una menor cantidad de puntos que una proveniente del [LiDAR](#).

Dataset	Año	Situaciones	Horas	Cámaras	LiDAR	RADAR	Clases	Devkit
KITTI	2012	22	1,5	4	1	0	8	Sí
Waymo	2019	1000	5,5	5	5	0	4	No
nuScenes	2019	1150	5,5	6	1	5	23	Sí

Tabla 4.1: Comparativa entre los principales datasets.

En relación a la cantidad de situaciones y de datos, Waymo y nuScenes se encuentran en un estado similar con una gran cantidad de datos del entorno, mientras que KITTI se queda más atrás debido a la longevidad del dataset.

Unicamente KITTI y nuScenes cuentan con un devkit, este es utilizado para un uso más simplificado del dataset, aunque en el caso de nuScenes es casi obligatorio su uso. El problema de KITTI en este aspecto es el uso de Matlab para el devkit ya que la mayoría de la comunidad investigadora no utiliza este lenguaje para la creación de los modelos de detección, aunque se pueden encontrar de forma no oficial, repositorios Open-Source que ofrecen variantes del devkit de KITTI en otros lenguajes, tal y como ocurre con pykitti [29].

En conclusión, KITTI ha sido una gran base para el desarrollo de la siguiente generación de datasets, aunque para sistemas de percepción algo más complejos se puede quedar corto, lo cual se ha ido mejorando con el tiempo y por esto mismo se ha desarrollado KITII-360. Por otra parte, Waymo y nuScenes ofrecen un dataset más completo, aunque nuScenes ofrece información de un sensor más y contiene la información de los mapas. Debido a ello se ha decidido estudiar más en profundidad y trabajar con los dataset de KITTI y nuScenes.

4.2 Estado del arte en técnicas de detección utilizando LiDAR

Las técnicas basadas en Deep Learning que hacen uso de [CNN](#) llevan unos años siendo las mejores del [SOTA](#) en el campo de la detección utilizando únicamente [LiDAR](#). En este apartado se van a estudiar los principales modelos de detección en este campo que hacen uso de estas técnicas.

4.2.1 SECOND

SECOND (Sparsely Embedded CONvolutional Detector) [30] se publica en 2018 para superar los modelos de detección 3D, utilizando únicamente LiDAR. Para ello propone una arquitectura basada en tres componentes principales: extractor de características a nivel de voxel, CNN dispersa y Region Proposal Network (RPN). Precedido todo ello de una fase de preprocesamiento de la nube de puntos y con una obtención a posteriori de las salidas del modelo.

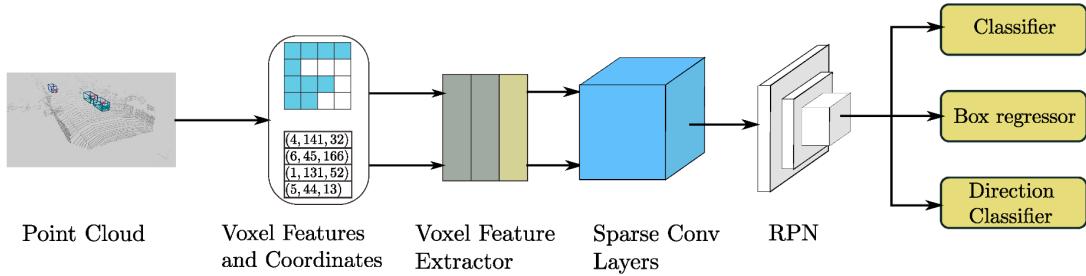


Figura 4.13: Arquitectura propuesta del detector SECOND.

Las diferentes fases del modelo que son utilizadas son las siguientes:

1. Preprocesamiento de la nube de puntos

Se comienza con la voxelización de la nube de puntos haciendo uso de una tabla hash, para su rápido acceso en memoria. Al tener que definir un tamaño de voxel fijo en función de lo que se desee detectar, se ajusta el tamaño de la ROI, ya que como se trabajar con KITTI solo se utiliza la parte frontal del LiDAR. Para la detección de coches y otros vehículos se usa $[-3, 1] \times [-40, 40] \times [0, 70.4]$ m y para el modelo más pequeño se utiliza $[-3, 1] \times [-32, 32] \times [0, 52.8]$ m para no tener que computar tantos véxeles como el modelo completo. Todas las versiones del modelo utilizan un tamaño de voxel fijo de $[0.4, 0.2, 0.2]$ m y por cada uno de ellos se guarda un máximo de 35 puntos.

2. Extractor de características a nivel de voxel

Se utiliza una capa Voxel Feature Encoding (VFE) tal como se presenta en el detector VoxelNet [31] para extraer las características. Para ello se utiliza una Fully Connected Network (FCN) compuesta de capas FC, una capa que aplica batch normalization y una Rectified Linear Unit (ReLU) de salida para extraer las características a nivel de punto y se aplica max pooling para la obtención de las características a nivel de voxel.

3. Extractor convolucional disperso

El uso de Sparse Convolutional Networks ofrece una mejora en rendimiento al no computar una salida si no hay una entrada dada. Al trabajar con una nube de puntos voxelizada se consigue una mejora en el rendimiento al no utilizar aquellos véxeles que no contienen ningún punto. Para poder aplicar este tipo de redes es necesario hallar qué índices del kernel van a ser utilizados, y para ello se necesita un algoritmo que contenga las reglas para indicar qué parte del kernel es utilizado.

Para ello se construye una tabla de matrices de reglas para guardar los índices utilizados. Con esto en cuenta, hace falta el algoritmo que genere las reglas, SparseConvNet [32] es el modelo original que ofrece la implementación del Submanifold Convolution, una técnica dentro del campo de las Sparse Convolutional Networks que realiza la generación de reglas en CPU.

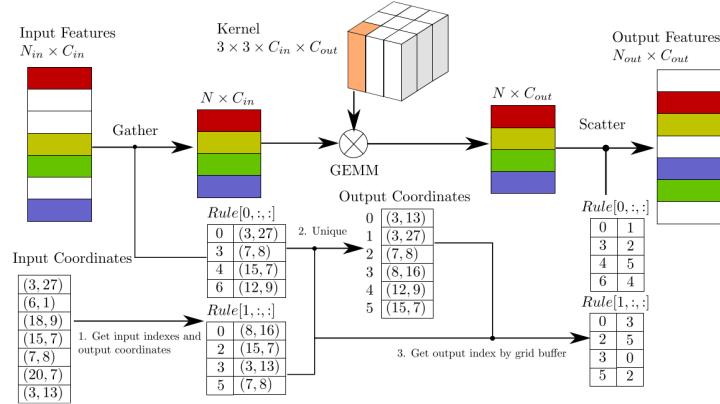


Figura 4.14: Algoritmo de convolución disperso propuesto en SECONd.

En este trabajo se implementa un generador de reglas en GPU aprovechando la aceleración por hardware y el procesamiento paralelo para conseguir una generación de reglas en la mitad de tiempo que SparseConvNet. Este extractor se utiliza para convertir la información 3D en un formato similar a una imagen Bird's Eye View (BEV).

4. Region Proposal Network

Las [RPN](#) fueron presentadas junto con el detector Fast R-CNN [33] y son utilizadas en este modelo para que a partir del mapa de características extraído de la fase anterior, obtenga las predicciones del modelo.

5. Obtención de las detecciones

En la salida se utilizan unos tamaños fijados para las diferentes clases que se ajustan a las detecciones, a partir del centro del objeto detectado. Por cada objeto se fija un one-hot vector para el ajuste de las cajas y otro para el ajuste de la dirección. Tras esto se aplica un límite de precisión por clase para minimizar los falsos positivos.

Este método tras su publicación consiguió convertirse en el mejor del [SOTA](#) en el benchmark KITTI en su evaluador de detección utilizando [LiDAR](#), además de ejecutarse en tiempo real, con tiempos de computo de 20 Hz en su modelo completo y 40 Hz en su modelo reducido.

4.2.2 PointPillars

PointPillars se publica meses después de SECONd y no solo consigue una mejora en la precisión para la detección de objetos 3D sino que lo consigue a una velocidad de inferencia de hasta 62 Hz o hasta 105 Hz con su modelo reducido. Esto no solo permite la utilización de nubes de puntos mayores sin disminuir apenas el rendimiento sino que permite la integración de este modelo en sistemas embebidos.

Para la obtención de esta velocidad de inferencia, PointPillars elimina el uso de las capas convolucionales 3D, convirtiendo las nubes de puntos en imágenes [BEV](#) de la escena. Los principales componentes de la red que consiguen este funcionamiento son los siguientes:

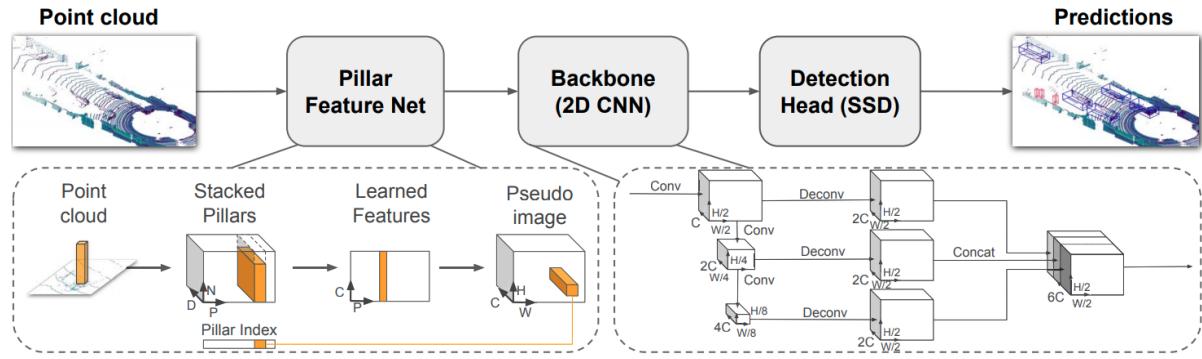


Figura 4.15: Arquitectura propuesta del detector PointPillars.

1. Nube de puntos a pseudo imágenes

Se comienza voxelizando la nube de puntos formando diferentes pilares, esto quiere decir que cada vóxel tiene un tamaño x e y fijo pero en z se tiene un tamaño infinito. Por cada punto en los vóxeles se les añade junto a las tres dimensiones con la información de posición: el grado de reflectividad, la distancia aritmética a la media de los puntos del vóxel en las tres dimensiones y el desplazamiento en x e y al centro del vóxel, por lo que se tiene un espacio de nueve dimensiones por pilar. Para limitar el cómputo, se define un tamaño máximo por pilar de [9, número de pilares no vacíos, número de puntos por pilar], de esta manera se fija un máximo de números de puntos por pilar y se aplica zero padding si el pilar se encuentra con muy poca información.

Tras esto se aplica una capa linear con batch normalization y una [ReLU](#) seguido de una operación de máximo por cada uno de los puntos del pilar para obtener un tensor de tamaño [X, número de pilares no vacíos], lo cual se transfiere a una pseudo imagen pasando el número de pilares no vacíos a la altura y anchura de la imagen en función de la posición de dichos pilares. Con lo que se consigue una estructura similar a la de una imagen [BEV](#).

2. Backbone

Se utiliza un backbone similar al de VoxelNet [31], este backbone tiene dos subcapas, una que aumenta el número de características a nivel espacial y otra que aumenta y relaciona las características de los pilares.

3. Cabeza detectora

En la salida se utiliza una Single Shot Detector (SSD) para obtener las salidas de las detecciones 3D.

Este enfoque de uso de [CNN](#) sobre nubes de puntos de la misma manera que se analizaría para imágenes, se ha visto, que es muy útil para acelerar la inferencia del modelo, además que se consigue un muy buen rendimiento para tareas de detección 3D y detección [BEV](#) 2D.

4.2.3 PointRCNN

PointRCNN [34] propone un modelo basado en dos fases para la detección de objetos 3D. Consiste en una primera fase de generación de las detecciones 3D y otra de refinamiento de las bounding boxes 3D.

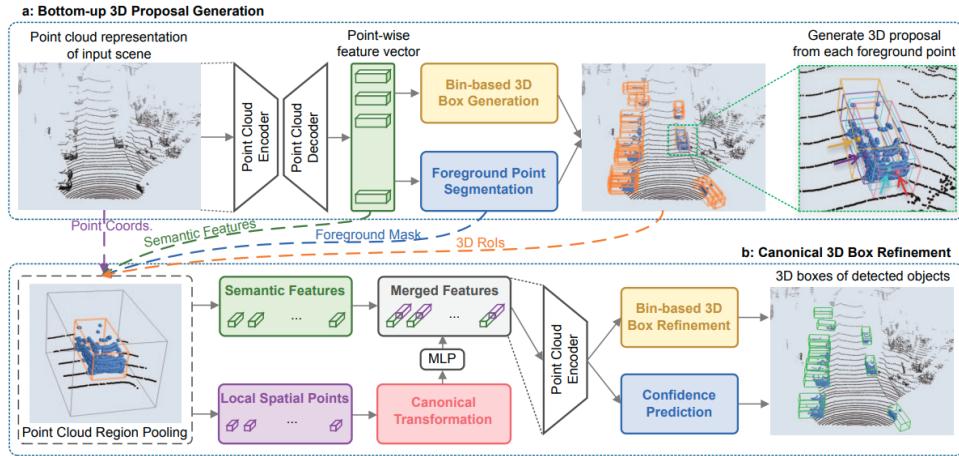


Figura 4.16: Arquitectura propuesta del detector PointRCNN.

El funcionamiento de las dos fases del modelo es el siguiente:

1. Generación de propuestas de detección 3D vía segmentación de la nube de puntos

La primera fase del modelo se basa en el backbone de PointNet++ [35] para extraer las características a nivel de punto de la nube de puntos utilizando una agrupación multiescala. Con dicho modelo junto con un método propio basado en la discretización 2D en BEV (bin-based) se han las múltiples detecciones 3D, pero se reducen por cada objeto aplicando Non Maximum Suppression (NMS) basado en el Intersection over Union (IoU) como BEV con un límite de 0,8 y solo las 100 mejores detecciones son mantenidas para la siguiente fase de ajuste de las detecciones 3D.

2. Refinamiento de las bounding boxes 3D

Tras la obtención de las bounding boxes 3D, se trata de mejorar el centro y la orientación de éstas. Por cada una de dichas detecciones se aumenta su tamaño por un valor constante incluyendo además una mascara que diferencia aquellos puntos de la detección original al espacio aumentado. Cada una de dichas detecciones aumentadas pasan a utilizar el sistema de coordenadas propio de cada detección.

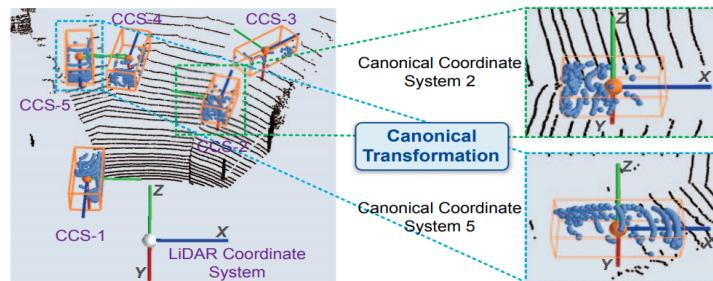


Figura 4.17: Agrupación de regiones de la nube de puntos en el modelo PointRCNN.

A partir de los puntos de cada agrupación de las características extraídas de la primera fase y de un parámetro que agrega información de la distancia al sensor para aquellas agrupaciones con menos puntos, calculado como $\sqrt{x^2 + y^2 + z^2}$, se introducen en múltiples capas FC para obtener las características locales. Tras esto se vuelve a utilizar el modelo bin-based utilizado en la primera fase con lo que se obtienen las bounding boxes 3D aplicando nuevamente NMS sobre un IoU en BEV con un límite de 0,01 para eliminar solapamientos.

Al estar basado este método en dos subredes, sufre de un tiempo de computo mayor, lo que se traduce en una velocidad de 12 Hz [36], pero suficiente para aplicarse en tiempo real, al obtener típicamente las nubes de puntos a 10 Hz.

4.2.4 PV-RCNN

PV-RCNN [37] unifica los beneficios de las dos principales técnicas de detección de objetos utilizando LiDAR, como son: el uso de técnicas de voxelización junto con Sparse Convolutional Networks y el uso de backbones como el de PointNet [38] o métodos similares. Para ello se construye un modelo basado en tres pasos:




Figura 4.18: Arquitectura propuesta del detector PV-RCNN.

1. 3D Voxel CNN para la extracción de características y generación de detecciones

Se utiliza una Voxel CNN con 3D sparse convolution junto con una RPN, la cual es una elección popular en el SOTA gracias a su eficiencia, por lo que es el backbone utilizado en este modelo. Este método obtiene de forma interna características semánticas de los véxeles además de conseguir las detecciones de los objetos a partir de los tamaños prefijados o anchors.

2. Codificación de escenas de véxel a puntos clave

Primero se agregan las características de los véxeles en un conjunto de puntos clave que sirven de conexión entre la fase anterior y el refinamiento de las detecciones. Para la obtención de los puntos clave se adopta el algoritmo Furthest Point Sampling y se aplica sobre la nube de puntos, lo cual elige puntos de forma uniformemente distribuida sobre los véxeles no vacíos. Tras esto se propone el módulo Voxel Set Abstraction para codificar características semánticas de la primera fase en los puntos clave. Basándose en la premisa de que los puntos más cercanos tienen que contribuir más a la propuesta de detección se propone el módulo Predicted Keypoint Weighting.

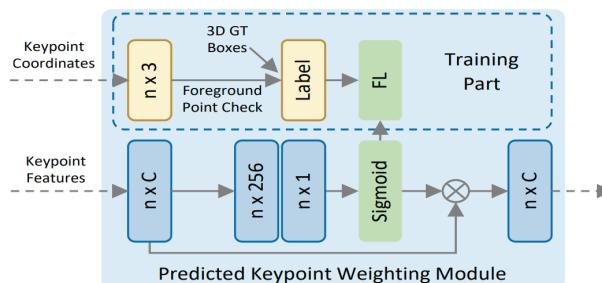


Figura 4.19: Módulo Predicted Keypoint Weighting del modelo PV-RCNN.

En dicho módulo se introducen los puntos clave codificados previamente para dar un peso a cada uno en función de su importancia para las detecciones.

3. Abstracción de características de **RoI** de puntos clave a cuadrícula para el refinamiento de la detección

Para el refinamiento de las detecciones se utiliza un método de abstracción de características **RoI** de puntos clave a rejilla. Dadas las detecciones junto con los puntos codificados y sus pesos, se agregan entorno a diferentes puntos de rejilla con un radio determinado. Tras esto se obtienen las características de las rejillas y a partir de estas, con una pequeña red de dos capas se ajusta la detección.

De la misma manera que ocurría en PointRCNN, PV-RCNN tiene una velocidad de inferencia baja de 10 Hz [36] debido a la fase de refinamiento y el procesamiento adicional de las características del backbone.

4.2.5 CBGS

Class-balanced Grouping and Sampling (CBGS) [11] propone un modelo compuesto principalmente de 4 partes: módulo de entrada, extractor de características 3D, **RPN** y una red con múltiples cabeceras en función del grupo. Con esto se consigue un funcionamiento en detección 3D, predicción de la velocidad y de la clase, todo ello sobre las 10 clases diferentes que utiliza nuScenes.

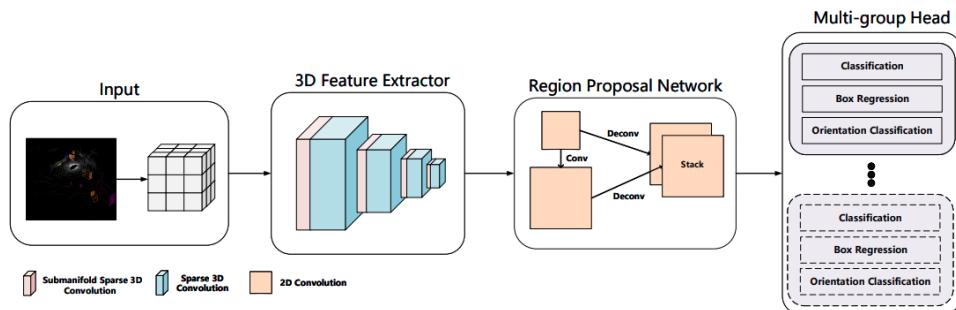


Figura 4.20: Arquitectura propuesta del detector CBGS.

Parte del funcionamiento del modelo proviene de la fase de entrenamiento, en la que se aplica una técnica de muestreo que trata de mejorar la media de uso de las diferentes clases para reducir la irregularidad del dataset de nuScenes, lo que aumenta el conjunto de entrenamiento de 28.130 a 128.100 muestras.

Para realizar la inferencia en el modelo se siguen los siguientes pasos:

1. Entrada de la red

Debido al método de validación de las detecciones en nuScenes es necesaria la inferencia de la velocidad, por lo que siguiendo el método oficial del dataset, se utilizan diez barridos de **LiDAR** para la obtención del dato de la velocidad. En la entrada del modelo es necesario entonces alguna medida de tiempo, por lo que cada punto se encuentra codificado como $[x, y, z, intensity, \Delta t]$, siendo Δt la diferencia de tiempo entre el barrido inicial y el barrido del que proviene el punto. Tras esto se voxeliza la nube de puntos con un tamaño de voxel de $[0.1, 0.1, 0.2]$ m para la reducción del tiempo de computo. Dentro de cada voxel se mantiene únicamente la media de todos los puntos de dicho voxel.

2. Backbone utilizado

En la red principal se utiliza un modelo basado en sparse 3D convolution y un extractor de características. Tras esto se aplica un [RPN](#), lo que termina en una red similar a la de VoxelNet [31] para extraer más características pero con capas convolucionales 2D.

3. Class-balance Grouping

Al tener una aparición de las diferentes clases muy irregular, con casi un 45 % de los objetos siendo coches, es muy difícil para objetos con formas diferentes extraer las diferencias entre ellos. Por ejemplo una bicicleta y una motocicleta tienen una forma muy similar en lo que respecta a la nube de puntos, al igual que ocurren con un camión y un camión de construcción. Para solucionar este problema se propone la agrupación de clases en función de su similitud, teniendo en cuenta el tamaño de los objetos y un balanceo del tamaño de los grupos en función del número de clases. Lo cual acaba generando 6 grupos diferentes: (Coche), (Camión, Camión de construcción), (Bus, Tráiler), (Barrera), (Motocicleta, Bicicleta), (Peatón, Cono de tráfico). Por lo que tras la elección del grupo, se obtiene su cabecera y se hayan la posición, tamaño, rotación y velocidad.

Este método consigue por tanto una detección de objetos 3D además de un pseudo tracking para inferir la velocidad de los objetos, todo ello trabajando con 10 clases diferentes y obteniendo una velocidad de 9 Hz.

4.3 OpenPCDet

OpenPCDet [39] es un proyecto Open-Source para realizar detecciones de objetos 3D utilizando [LiDAR](#). Esta herramienta ha sido utilizada para la evaluación, entrenamiento e implementación de diversos modelos debido a la diversidad de modelos y de datasets que son soportados.

OpenPCDet es un repositorio en Pytorch [40] que soporta múltiples modelos [SOTA](#) en detección de objetos 3D, con un código altamente refactorizado para las arquitecturas basadas en una o dos etapas. Este repositorio de código abierto es activamente actualizado con nuevos datasets soportados y modelos. Basado en OpenPCDet se ha conseguido ganar el año 2020 el Waymo Open Dataset en detección 3D, seguimiento 3D y adaptación del entorno utilizando únicamente las nubes de puntos del [LiDAR](#).

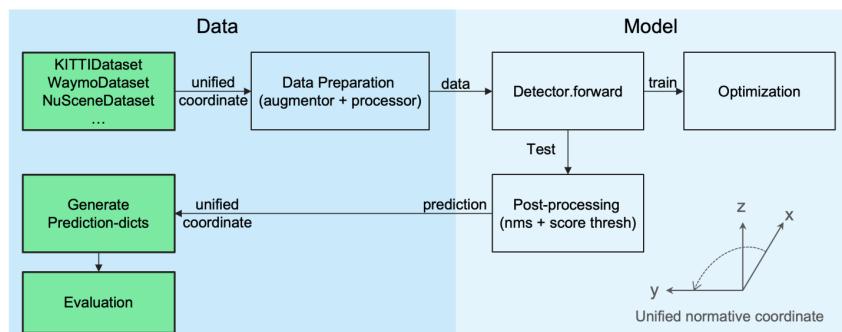


Figura 4.21: Diseño de OpenPCDet.

El patrón de diseño de OpenPCDet se encuentra basado en: la separación de datos a modelo unificando el sistema de coordenadas, la definición única de las bounding boxes 3D $[x, y, z, dx, dy, dz, heading]$, y la definición de la estructura de los modelos clara y flexible permitiendo fácilmente el soporte de múltiples modelos. Esta herramienta incluye diversos modelos en diferentes datasets, estos son:

- KITTI [23]
 - PointPillars [8]
 - SECOND [30]
 - PointRCNN [34]
 - Part-A² [41]
 - PV-RCNN [37]
 - Voxel R-CNN [42]
 - CaDDN [43]
- nuScenes [25]
 - CBGS [11]
- Waymo [26]
 - SECOND [30]
 - Part-A² [41]
 - PV-RCNN [37]

Para el uso principal de la herramienta se utilizan los ficheros *train.py* y *test.py*, con éstos a partir de diferentes flags es posible entrenar y evaluar los diferentes modelos que se deseen, sin necesidad de limitarse a los modelos que se tienen implementados, sino que dentro de *OpenPCDet/tools/cfgs* es posible modificar los ya existentes o también es posible crear nuevos modelos a partir de objetos en Python que utilicen toda la flexibilidad que OpenPCDet ofrece para reutilizar módulos de otros modelos.

Todo esto convierte a OpenPCDet en una gran herramienta para el desarrollo de modelos que utilicen técnicas pertenecientes al **SOTA**, como herramienta de evaluación o para la implementación de modelos ya diseñados y entrenados.

Capítulo 5

Desarrollo realizado

La persistencia es muy importante. No debes renunciar al menos que te veas obligado a renunciar.

Elon Musk

Tras el estudio teórico de los métodos clásicos y basados en Deep Learning se procede a explicar el desarrollo realizado en el contexto del proyecto Techs4AgeCar dentro del grupo Robesafe para la mejora del sistema de percepción existente basado en el modelo Pointpillars, tanto utilizando únicamente las nubes de puntos proporcionadas por el LiDAR como en base a una fusión sensorial entre cámara y LiDAR.

5.1 Estado del proyecto Techs4AgeCar

El proyecto Techs4AgeCar trata de construir un sistema de conducción autónoma, con una arquitectura basada en múltiples capas como son: localización, planificación, control, mapeado, decisión y percepción. Para el desarrollo del software del vehículo se trabaja con ROS para comunicación con los sensores y entre capas, Docker para tener un entorno cerrado con todas las dependencias y software necesario para correr el proyecto y CARLA como entorno de simulación para las pruebas de los múltiples sistemas del vehículo.

5.1.1 Robot Operating System

Robot Operating System (ROS) [44] es un conjunto de librerías software y herramientas Open-Source que ayudan con la construcción de aplicaciones en robots. Aunque el nombre sugiere que se trata de un sistema operativo, no lo es, sino que es un software middleware que provee de abstracción del hardware, control de dispositivos a bajo nivel, implementación de funcionalidades comúnmente utilizadas, paso de mensajes entre procesos y gestión de paquetes. Además de esto se proporcionan herramientas y librerías para obtener, construir, escribir y correr código en diferentes ordenadores.

La meta principal de ROS es la reutilización de código en la investigación y desarrollo de sistemas robóticos. ROS utiliza un marco distribuido de procesos que permite la ejecución de cada uno de forma individual.



Figura 5.1: Logo de ROS.




Figura 5.2: Ejemplo de uso de ROS

La forma de comunicación de **ROS** es mediante un modelo peer-to-peer de procesos que se encuentran débilmente acoplados. Los principales conceptos del grafo de computo de **ROS** son los siguientes:

- Nodos

Los nodos suelen ser los típicos procesos que realizan el computo. Dichos nodos son escritos mediante la librería del cliente de **ROS** utilizando roscpp para C++ o rospy para Python.

- Maestro

El maestro permite que los nodos se puedan encontrar, intercambiar mensajes y permite invocar los servicios.

- Servidor de parámetros

El servidor de parámetros permite almacenar los datos por clave, encontrándose dentro del maestro.

- Mensajes

Los mensajes son estructuras de datos con ciertos atributos. Dichas estructuras son utilizadas para la comunicación entre nodos, y aún teniendo mensajes estándares es posible crear nuevos que se adapten a las necesidades de cada problema.

- Topics

Mientras que un mensaje es únicamente la estructura de datos, los topics identifican los mensajes en función de un nombre. Estos topics son accedidos mediante suscripciones para la lectura de mensajes y publicaciones para la escritura de mensajes, todo ello a través de topics. Por lo que son utilizados por los nodos para trabajar con los mensajes.

- Servicios

El modelo de publicación y suscripción se utiliza para la comunicación bajo un modelo many-to-many, en el caso de usar un modelo en una dirección no es recomendable, por ello en ese caso se utilizan servicios. Los servicios se basan en cambio en un modelo de solicitud y respuesta, por lo que mientras un nodo ofrece un servicio bajo un nombre, otro nodo puede acceder a dicho servicio.

- Bags

Los bags son el formato utilizado por **ROS** para guardar y recrear de nuevo los mensajes grabados. Son utilizados para la recreación, comparativa o evaluación a partir de los datos grabados.




Figura 5.3: Funcionamiento principal de ROS.

De esta manera ROS consigue ser un sistema distribuido con múltiples aplicaciones. Solo es necesario tener en cuenta que se encuentra disponible en sistemas basados en Unix como Ubuntu y MacOS, aunque es sencillo encontrar soporte para otras distribuciones basadas en Linux [45].

5.1.2 Docker

Docker [46] es un proyecto Open-Source que automatiza el despliegue de aplicaciones dentro de contenedores de software, proporcionando una capa de abstracción y automatización de la virtualización de aplicaciones en múltiples sistemas operativos [47].

El aislamiento y la seguridad son elementos principales de la herramienta, la cual permite la ejecución de múltiples contenedores en un único host. Dichos contenedores son ligeros y contienen todo lo necesario para la ejecución de las aplicaciones, por lo que no hay ninguna dependencia del host en el que se esté ejecutando. Además, se pueden compartir los contenedores de forma muy sencilla haciendo uso de Docker Hub con un funcionamiento basado en push/pull.

Docker se usa para agilizar el ciclo de desarrollo de software, permitiendo trabajar en entornos estandarizados utilizando contenedores locales que proporcionan las aplicaciones y servicios. Por lo tanto los contenedores de Docker son una gran herramienta para los flujos de trabajo de integración y entrega continua.




Figura 5.4: Arquitectura de Docker.

Docker utiliza una arquitectura cliente-servidor. El cliente habla con el daemon, el cual hace el trabajo de construir ejecutar y distribuir los contenedores. Tanto el cliente como el daemon suelen encontrarse en el mismo sistema, pero también se puede trabajar con un daemon de forma remota, para ello se utiliza una comunicación basada en una REST API sobre sockets UNIX u otra interfaz de red.

Los principales componentes de la arquitectura de Docker son los siguientes:

- Daemon

El daemon escucha a las peticiones de la [API](#) de Docker y gestiona los objetos de Docker como imágenes, contenedores, redes y volúmenes. Además, los daemons pueden comunicarse a otros daemons para controlar servicios.

- Cliente

El cliente es el principal método de uso de Docker por muchos usuarios para trabajar con imágenes o contenedores. El cliente se conecta a un daemon pero también es posible su conexión a múltiples daemon diferentes.

- Registros

Los registros se utilizan para guardar las imágenes de Docker. Un caso de registro público sería Docker Hub donde se pueden guardar y descargar las imágenes creadas.

- Imágenes

Una imagen es una plantilla de solo lectura que se utiliza para crear un contenedor. A partir de una imagen se descarga e instala todo el software necesario para que el contenedor funcione correctamente, y en el caso de tener que crear una imagen propia se utilizan *Dockerfiles*, que son archivos con una sintaxis sencilla que definen los pasos necesarios para crear la imagen y correrla.

- Contenedores

Un contenedor es una instancia ejecutable de una imagen. Sobre un contenedor se pueden aplicar las opciones de crear, ejecutar, pausa, mover y borrar utilizando la [API](#) de Docker o [CLI](#). Es posible la conexión a un contenedor en otra red o incluso crear imágenes de forma automática a partir del estado de un contenedor.

Docker se encuentra escrito en lenguaje Go y utiliza múltiples características del kernel de Linux para ofrecer sus funcionalidades. Docker utiliza un sistema de *namespaces* que proveen de una capa de aislamiento al contenedor respecto del host, por lo que los contenedores corren de forma separada a fuera de ese *namespace* y su acceso se encuentra limitado al interior de este [48].

5.1.3 CARLA

CARLA [49] es un simulador de conducción autónoma Open-Source. Este simulador sirve como un entorno en el que probar diversas técnicas necesarias para la conducción autónoma mediante el uso de la [API](#) que se ofrece en Python y C++. CARLA se basa en el motor de videojuegos Unreal Engine [50] para correr el mundo y utiliza el estándar OpenDRIVE [51] para la definición de carreteras y el entorno.

Unreal Engine 4 es la versión utilizada por CARLA, este motor de videojuegos es desarrollado por Epic Games. Inicialmente para videojuegos, Unreal Engine se ha extendido en otras industrias como la televisión y el mercado cinematográfico. Escrito en C++, Unreal Engine ofrece gran portabilidad en una gran cantidad de dispositivos, con un modelo Open-Source pero con royalties en el uso comercial. Con el éxito de Fortnite, muchos juegos están utilizando este motor gráfico, lo que ha aumentado el desarrollo de la siguiente versión de Unreal Engine, la cual se espera en 2022 con una gran mejora gráfica.



Figura 5.5: Unreal Engine 5.

OpenDRIVE es un formato abierto para la creación de redes de carreteras que trata de convertirse en el estándar para la creación de mapas y sistemas de carreteras para facilitar el uso de diferentes mapas y simuladores. Los mapas creados con OpenDRIVE utilizan la extensión `.xodr` y dichos archivos utilizan un formato similar al [XML](#) para su uso simplificado con herramientas ya creadas.

Para la aceleración del proceso de desarrollo, entrenamiento y validación de los [ADS](#), CARLA ha creado un ecosistema de proyectos a partir del simulador en conjunto con la comunidad que utiliza CARLA.

CARLA utiliza un modelo cliente-servidor como arquitectura. El servidor es responsable de toda la simulación: renderización de los sensores, cálculo de las físicas, actualización del mundo, etc. Con todos estos cálculos es recomendado el uso de una [GPU](#), sobre todo si se utilizan técnicas basadas en Deep Learning. Por otra parte, el cliente es aquel que controla la lógica de los actores en la escena y cambia las opciones del mundo, de esta manera se pueden tener múltiples clientes trabajando al mismo tiempo. La comunicación al servidor se realiza mediante la [API](#) que provee CARLA, pero también es posible utilizar el CARLA-ROS bridge para utilizar los topics de [ROS](#) para la comunicación [52].

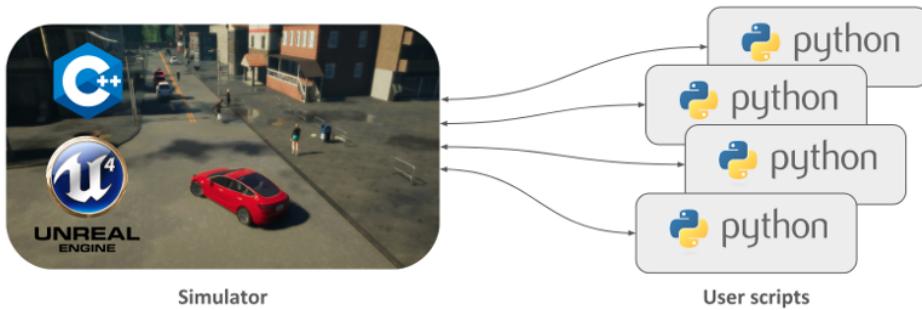


Figura 5.6: Modo de uso principal de CARLA.

CARLA ofrece una comunicación con ROS, a través del CARLA-ROS bridge. Su funcionamiento se basa en el paso de la información que sería accesible a partir de la [API](#) de CARLA mediante mensajes publicados en diversos topics en ROS. Dicho CARLA-ROS bridge funciona en ambas versiones de [ROS](#) y publica de forma continua:

- Información de diversos sensores del coche controlado como son: cámara (profundidad, segmentación a nivel de píxel y RGB), [LiDAR](#), [Radar](#), [GNSS](#) e [IMU](#)

- Información de los objetos del entorno como: estado de los semáforos, indicadores de colisión, invasión de carril, etc.
- Control del vehículo autónomo como: dirección, aceleración y freno
- Control de los ajustes generales del simulador

CARLA ofrece por tanto un simulador Open-Source, con una gran comunidad de desarrolladores aportando código, por lo que es una herramienta perfecta para la evaluación de los sistemas de conducción autónoma a desarrollar.

5.1.4 Desarrollo en el proyecto Techs4AgeCar

El proyecto Techs4AgeCar trata de construir un vehículo autónomo que consiga una mejora para la seguridad de los conductores. Aún teniendo un gran desarrollo en la parte hardware del proyecto para la construcción del vehículo, el desarrollo de este TFG es software, por lo que se explica el uso de las diferentes herramientas utilizadas para el trabajo con un entorno estandarizado para todos los compañeros, y cómo se ha trabajado en el desarrollo de las diversas técnicas implementadas.




Figura 5.7: Estructura principal del proyecto Techs4AgeCar en Docker.

Para uso de un entorno estandarizado para todos los usuarios se utiliza un contenedor Docker alojado en Docker Hub, que contiene todas las dependencias necesarias para correr el proyecto o sus componentes individuales. La única herramienta utilizada en el proyecto que se debe de encontrar fuera del contenedor es el simulador CARLA, que es necesario descargarlo fuera de este.

La figura 5.7 muestra de manera simplificada la estructura del docker del proyecto. En dicho contenedor se tiene instalado de base Ubuntu 18.04 LTS para trabajar sobre este sistema operativo. La estructura del contenedor consta del simulador CARLA, las librerías o repositorios necesarios, los modelos de las redes neuronales utilizadas y la estructura principal de los diferentes módulos del proyecto. Por una parte se encuentra la carpeta *t4ac_architecture*, la cual contiene los repositorios de las diferentes capas del vehículo junto con los ajustes de configuración de todas estas. En la carpeta *t4ac_carla_simulator* se encuentran los ajustes de carla, el Carla-ROS bridge ajustado al proyecto y un proyecto basado en CARLA llamado *ad_devkit* para la evaluación de arquitecturas de conducción autónoma del que se hablará más en el capítulo 6.

Las diferentes capas del proyecto contenidas en *t4ac_architecture* se construyen como repositorios Git alojados en GitHub y en un servidor propio del grupo RobeSafe. Cada uno de estos repositorios se encuentran divididos en diferentes repositorios, por ejemplo, en la capa de control se dividen según el uso de técnicas clásica o basadas en Deep Learning, o en la capa de percepción se divide según el uso de técnicas de detección o seguimiento y en función de los diferentes sensores.

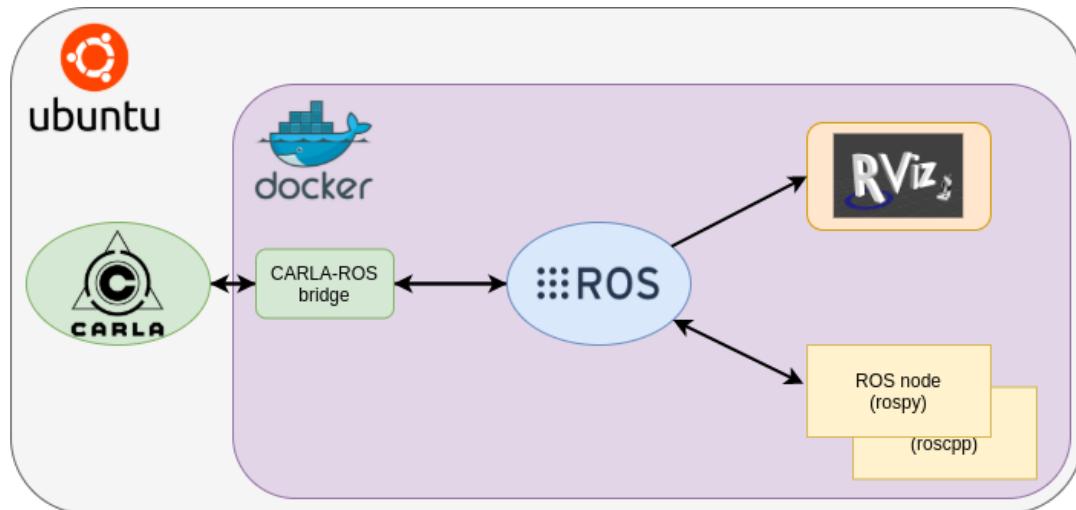


Figura 5.8: Modo de uso en el proyecto Techs4AgeCar.

Los repositorios de las diferentes capas se encuentran planteados como nodos de [ROS](#), para dividir el trabajo en tareas más simples, de esta manera, con el vehículo del grupo RobeSafe se obtiene la información de los sensores a partir de [ROS](#). Con este sistema solo es necesario un cambio en el nombre del topic para que funcione de simulación al vehículo real. En la figura 5.8 se puede ver el principal modo de uso del proyecto, donde CARLA se corre en el host y el resto del proyecto se lanza en el contenedor Docker. Dentro del contenedor se pasa la información de CARLA a ROS, dicha información es visualizada con rviz y los nodos de las diferentes capas en Python o C++ se ejecutan trabajando con el modelo publisher/subscriber de ROS.

5.1.5 Arquitectura del proyecto Techs4AgeCar

El grupo RobeSafe comienza a trabajar en la construcción de un vehículo autónomo en 2016 con el proyecto SmartElderlyCar con finalización en 2018, tras éste se continua con el proyecto Techs4AgeCar con una duración del 2019 a 2021, y que pretende mejorar las técnicas de conducción autónoma que se consiguieron con el proyecto anterior.

Las líneas de investigación del grupo son por tanto: [Advanced Driver Assistance System](#), comprensión de la escena, comprensión del comportamiento del conductor, desarrollo de técnicas de percepción, localización, navegación y mapeado.

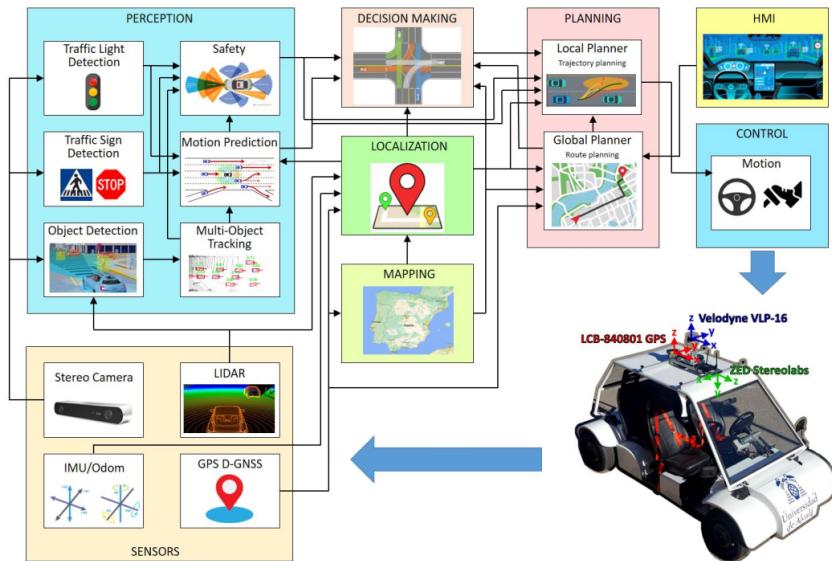


Figura 5.9: Arquitectura T4AC.

La arquitectura definida en el proyecto consta de diferentes capas en la que cada una realiza una función diferente para el funcionamiento autónomo del vehículo:

- Control

El control del vehículo consiste en un sistema Drive-by-Wire, con parte del control hardware y parte software haciendo uso de ROS. Para el control del seguimiento de la ruta se utiliza una interpolación de splines y un perfilador de velocidad para la obtención de una trayectoria suave y continua a partir de un modelo basado en puntos de referencia (waypoints).

- Mapeado y planificación

En la generación de mapas se utiliza el estándar OpenDRIVE junto con el programa RoadRunner para generar además un entorno tridimensional con el que trabajar en CARLA. La planificación global se basa en el algoritmo A* sobre un grafo dirigido de las carreteras a partir de un mapa con formato OpenDRIVE.

- Toma de decisiones

La toma de decisiones se basa en redes de Petri para diferentes casos de uso: mantenimiento de carril, control de crucero adaptativo, y en casos de uso como: pasos de peatones, ceda el paso, stops y adelantamientos. Todo ello en conjunto con procesos de decisión de Markov parcialmente observables.

- Percepción

El sistema de percepción se basa en la fusión sensorial de las detecciones de objetos provenientes de las cámaras, utilizando para ello la [CNN YOLO X](#), y el [LiDAR](#) mediante el modelo Pointpillars. Dichas detecciones son la entrada del módulo SmartMOT [53], un sistema de seguimiento para predicción en sistemas multiagente y entornos dinámicos, todo ello para obtener identificadores, el estado y la velocidad de los diferentes objetos del entorno en [BEV](#).

- Human-Machine Interface (HMI)

El sistema [HMI](#) se basa en la creación de un sistema de visualización que permita entender el estado del vehículo y de un sistema de atención del conductor para la detección de la fatiga y el cambio automático de la conducción manual a la automática.

Tras la comprensión de la utilidad de las diferentes capas del vehículo, se presenta el flujo de funcionamiento del sistema completo, tal y como se ve en la figura 5.9:

1. Se obtiene la información de los diferentes sensores del vehículo
2. Con la capa de percepción se analizan los datos y se trata de comprender el entorno del vehículo
3. A partir del mapa, la información de los sensores y los objetos detectados del entorno se localiza el vehículo.
4. Con la información de los pasos anteriores el sistema decide qué acción tomar.
5. Junto con la información del entorno y la acción a tomar se planifica de forma global y local la trayectoria del vehículo
6. Finalmente, la capa de control es la que se realiza las acciones pertinentes sobre el coche en función de la trayectoria decidida.

Esta es la arquitectura sobre la que se van a diseñar las diferentes técnicas de detección de objetos con [LiDAR](#), para así mejorar la capa de percepción con una fusión sensorial junto con cámara y utilizar ésta como entrada para el sistema de seguimiento SmartMOT.

5.2 Implementación en CARLA

Antes de la puesta a punto de los diferentes algoritmos de detección en el coche del grupo RobeSafe, se comienza por implementar diversas técnicas en el simulador, comenzando por un acercamiento más clásico y tras esto se implementa un modelo basado en Deep Learning.

5.2.1 Funcionamiento del LiDAR en CARLA

Antes de comenzar a trabajar con el [LiDAR](#) que ofrece CARLA, es necesario comprender cómo funciona. Dado que la comunicación con CARLA se realiza mediante el CARLA-ROS bridge, la información de dicho sensor proviene del topic `/carla/ego_vehicle/lidar/lidar1/point_cloud`, que contiene un mensaje del tipo `sensor_msgs/PointCloud2`. Dicho mensaje se utiliza para guardar información de una colección de puntos en N dimensiones.

Nombre	Tipo
header	Header
heighth	uint32
width	uint32
fields	PointField[]
is_bigendian	bool
point_step	uint32
row_step	uint32
data	uint8[]
is_dense	bool

Tabla 5.1: Estructura del LiDAR en el CARLA-ROS bridge.

La nube de puntos viene definida como un array de bytes en formato little endian, en la que cada 32 bits se obtiene un número, dichos números siguen la estructura: $x, y, z, intensity$. La nube de puntos por tanto se encuentra definida como un vector de 4 dimensiones, con un sistema de coordenadas cartesiano que además incluye información de lo que sería el grado de reflectividad del láser con los objetos del entorno, pero todo ello de forma simulada.

La colisión de los haces del [LiDAR](#) con los objetos del entorno ha mejorado en gran medida con el avance en las versiones de CARLA, ya que los puntos generados no colisionan directamente con los modelos de los objetos del entorno, sino que colisionan con un modelo simplificado de estos.

Lo mismo ocurre con el campo *intensity*, el cual es simulado en CARLA, para ello se guarda un valor proporcional a la distancia respecto del vehículo (d) y a un coeficiente de atenuación (a).

$$I/I_0 = e^{-a*d}$$

Al no tener una relación con el tipo de material con el que se colisiona, este campo es inútil en relación al funcionamiento que se tendría con un [LiDAR](#) real, por lo que dicho campo no se utiliza en las diferentes implementaciones realizadas.

5.2.2 Implementación del sistema clásico utilizando LiDAR

Tras el estudio de diversas técnicas clásicas en el capítulo 3, se presenta una aplicación de detección en tiempo real sobre el simulador CARLA que detecta los objetos de importancia del entorno.

En dicha implementación se usa el lenguaje C++ debido a su gran eficiencia y su Object-Oriented Programming (OOP), por lo que para su comunicación con [ROS](#) es necesario el uso de roscpp. Para ello se crea un repositorio Git y se desarrolla de tal manera que el programa sea un nodo que se pueda suscribir y publicar en ROS. Dicho nodo tendrá que suscribirse al topic con la información del [LiDAR](#) y generar un topic para la visualización de las bounding boxes 3D de los objetos del entorno detectados.

Con los métodos clásicos estudiados teóricamente, el flujo de trabajo implementado es el siguiente:

1. Transformación del mensaje con la nube de puntos proveniente de [ROS](#) a una estructura en C++ de la librería Point Cloud Library (PCL), que guarda la información de las coordenadas cartesianas y la intensidad
2. Voxelización de la nube de puntos

3. Filtrado de la nube de puntos voxelizada en función de la región de interés
4. Aplicación del algoritmo RANSAC para la eliminación de los véxeles pertenecientes al suelo
5. Creación de un KD-tree con la nube de puntos, e introducción de los puntos en función de las coordenadas por lo que se construye un KD-tree tridimensional
6. A partir del KD-tree se aplica el algoritmo [3.4](#) para clusterizar de forma eficiente los véxeles, fijando además una distancia máxima entre los véxeles
7. Filtrado de los clústeres en función del número de véxeles en su interior, tamaño y volumen
8. Creación de las bounding boxes 3D correspondientes a las detecciones

Listado 5.1: Estructura de los nodos utilizados en el KD-tree implementado

```
struct Node{
    std :: vector<float> point;
    int id;
    Node* left;
    Node* right;

    Node( std :: vector<float> arr , int setId ){
        point = arr;
        id = setId;
        left = NULL;
        right = NULL;
    }
};
```

Tipo	Nombre
Tamaño de los véxeles	[0.3, 0.3, 0.3] m
Máximo punto de la región de interés	[50, 17, 10] m
Mínimo punto de la región de interés	[-40, -5, -10] m
Número de iteraciones del algoritmo RANSAC	50
Distancia máxima para el algoritmo RANSAC	0.3 m
Distancia máxima entre véxeles al clusterizar	1.4 m
Máximo número de véxeles por clúster	150
Mínimo número de véxeles por clúster	20
Máximo volumen de un clúster	10 m ³
Mínimo volumen de un clúster	1 m ³
Máxima largura de los clústeres	6 m
Máxima anchura de los clústeres	6 m
Máxima altura de los clústeres	4 m

Tabla 5.2: Parámetros del modelo clásico de detección con LiDAR.

Mientras que gran parte de las funciones han sido tomadas de la librería [PCL](#), la estructura KD-tree ha sido creada de cero para una mejor comprensión de su funcionamiento, además de para la construcción de la función mostrada en el listado 3.4. En dicha estructura los nodos del árbol se definen tal y como se muestra en el listado 5.1.

De esta manera, al no utilizar las cuatro dimensiones de la nube de puntos, se consigue una mejora en su complejidad, ya que al aplicar el algoritmo de clusterización no se utiliza la intensidad y la complejidad del algoritmo se reduce.

Los parámetros de ajuste manual utilizados en el flujo de ejecución, se han fijado para obtener un mejor rendimiento, en este caso, para su uso en CARLA con un [LiDAR](#) de 32 haces, dichos parámetros son los que se pueden ver en la tabla 5.2.

Todo este desarrollo es accesible en GitHub de forma pública a través del siguiente enlace https://github.com/Javier-Dlap/3D_lidar_based_clustering, los resultados de dicho algoritmo se muestran más adelante en el capítulo 7.2.1.

5.2.3 Implementación del sistema basado en Deep Learning utilizando LiDAR

Mientras que el desarrollo del modelo clásico se ha hecho de cero, el desarrollo del modelo basado en Deep Learning se hace a partir de un repositorio creado por Carlos Gómez Huélamo a partir del Trabajo Fin de Grado de Javier del Egido Sierra [13]. Dicho repositorio funciona a partir de un archivo *launch* de [ROS](#) y un fichero en Python de casi 500 líneas, dicho fichero al ser tan grande no aplica unas buenas prácticas de programación, ya que es más difícil de mantener y no es reutilizable. La solución al repositorio antes de comenzar el desarrollo ha sido realizar una refactorización del código, para poder así tener una mayor calidad en su estructura.

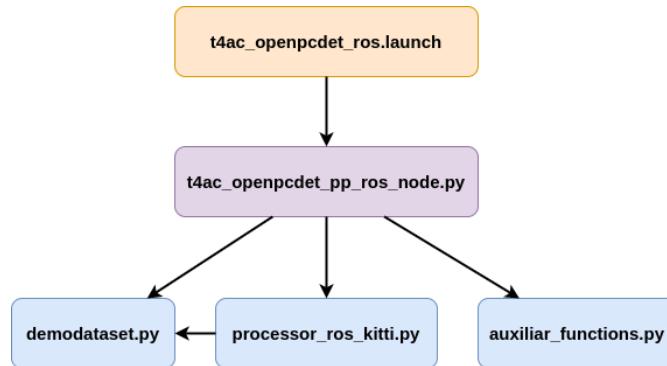


Figura 5.10: Estructura del repositorio para la detección con LiDAR en el proyecto refactorizado.

Dicho desarrollo se realiza sobre un repositorio previamente creado ya que se utiliza la misma herramienta, como es OpenPCDet, para implementar los modelos, pero en vez de utilizar únicamente PointPillars se pretende utilizar el modelo PointPillars Multihead, el cual es el modelo CBGS pero con el backbone de PointPillars para una mejora en su rendimiento. Aún siendo más complejo dicho modelo y requerir una capacidad de computo mayor, tiene una precisión mayor, diferencia entre una mayor cantidad de clases, infiere las velocidades de los vehículos y trabaja con una cantidad de puntos mayor ya que utiliza 10 barridos para realizar las detecciones. Esto último es especialmente útil para la puesta en funcionamiento en el coche del proyecto, ya que se utiliza un [LiDAR](#) que tiene únicamente 16 haces, lo que consigue una menor cantidad de puntos y por lo tanto se puede extraer menos información, por lo

que un aumento en la cantidad de puntos utilizados puede ser beneficioso al trabajar con un LiDAR de estas características.

La modularización del código es fundamental para el mantenimiento de dicho código, y el ajuste en otros entornos, por ello se sigue utilizando y mejorando el archivo *launch*, ya que permite no solo llamar desde un mismo archivo *launch* a todas las capas de forma simultánea, sino que cambiando el nombre de los topics referenciados es posible adaptar el repositorio a cualquier vehículo que trabaje con los mismos tipos de datos en ROS.

Utilizando la herramienta roslaunch se lanza el código fuente del repositorio mientras que se tiene funcionando CARLA, con el CARLA-ROS bridge y un vehículo que controlar. Una vez lanzados estos módulos el funcionamiento del sistema basado en Deep Learning es el siguiente:

1. Carga de la red neuronal utilizada junto con sus pesos en GPU
2. Preparación de los publishers y subscribers utilizados
3. Guardado de la información de la odometría del vehículo cada vez que el topic recibe un nuevo mensaje
4. Guardado de la nube de puntos del LiDAR en una cola de 10 posiciones tras la eliminación de los puntos que se encuentren sobre el propio vehículo junto con el tiempo en el que se ha obtenido dicha nube
5. Unión de las nubes de puntos guardadas con una dimensión adicional que contiene el tiempo desde la nube de puntos más antigua
6. Ejecución del modelo y obtención de las predicciones
7. Filtrado de las predicciones en función de cada clase
8. Transformación de la velocidad predicha relativa al coche a la velocidad absoluta a partir de la odometría guardada del vehículo
9. Creación de bounding boxes 3D, flechas para la velocidad y publicación de estas

Con todo este desarrollo terminado se obtiene una estructura bastante más compleja a la que se tenía tras la refactorización, como se ve en la figura 5.11. Tras este nuevo modo de funcionamiento se ha creado un parámetro en el launcher para seleccionar si se quiere utilizar el modelo PointPillars o PointPillars Multihead para un sencillo intercambio entre ambos modelos.

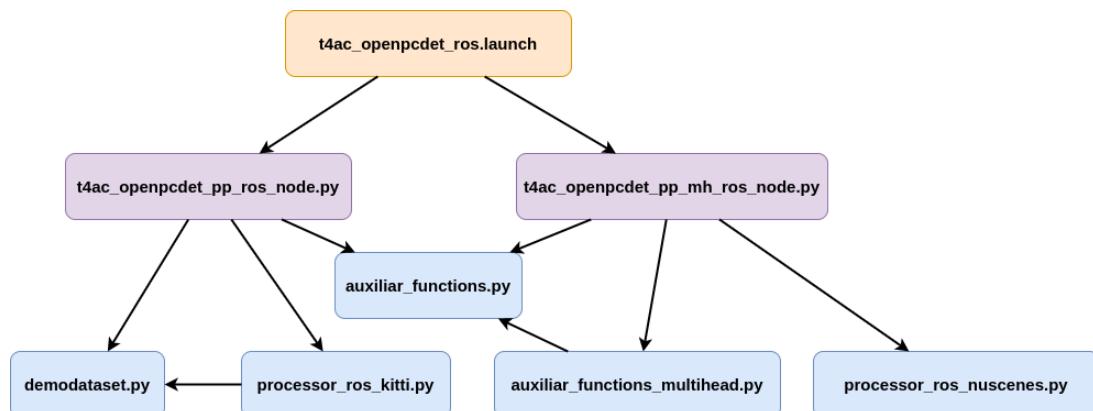


Figura 5.11: Nueva estructura del repositorio para la detección con LiDAR en el proyecto.

Todo el desarrollo implementado se encuentra presente en GitHub, actualmente de forma privada, ya que se está utilizando en el proyecto Tech4AgeCars, pero se puede pedir acceso al repositorio https://github.com/RobeSafe-UAH/t4ac_openpcdet_ros. El análisis del rendimiento de dicha implementación se presenta más adelante en el capítulo 7.2.3.

5.3 Fusión sensorial

La implementación del modelo PointPillars Multihead en el proyecto ha ocasionado mejoras sustanciales en la detección respecto al sistema anterior existente en el proyecto, basado en el modelo PointPillars. Con las mejoras obtenidas se aumenta la robustez y la precisión del sistema de detección de objetos 3D realizando una fusión sensorial, dicha late-fusion se basa en el sistema de detección con LiDAR presentado en este Trabajo Fin de Grado y un sistema de detección 3D basado en cámara que utiliza los modelos YOLO v5 [54] y una red volumétrica [55], presentado en el Trabajo Fin de Grado de Miguel Antunes [14].

Se realiza la implementación de la fusión sensorial a partir de las detecciones 3D de ambos métodos, todo ello realizado con un sencillo método de fusión como se muestra a continuación:

1. Suscripción a los topics de las detecciones provenientes de la cámara y del LiDAR
2. Sincronización de los mensajes de ambas detecciones
3. Cálculo del IoU 3D entre ambas detecciones
4. En el caso de tener un IoU 3D mayor a 0 se crea una detección a partir de la bounding box del LiDAR y el tipo de la cámara
5. Dicha bounding box se publica en un topic

De esta manera se consigue una detección de la parte frontal del vehículo mejorada a partir de las detecciones de ambos sensores, ya que se utiliza el mayor Average Precision (AP) del modelo del LiDAR para obtener las detecciones, y la mayor precisión de las detecciones del modelo basado en cámara, obteniendo un número menor de falsos positivos, además de una mejor detección del tipo de objeto.

Dicha implementación de fusión sensorial entre cámara y LiDAR se encuentra disponible en https://github.com/RobeSafe-UAH/t4ac_sensor_fusion_ros. Los resultados de la fusión sensorial se analizan en el capítulo 7.3.2.

5.4 Vehículo del proyecto Techs4AgeCar

El vehículo T4AC para el cual se están desarrollando las diferentes técnicas de percepción se basa en el chasis TABBY EVO, el cual es una plataforma Open-Source que permite la modificación de este como sea necesario. En el proyecto fueron añadidas baterías y un chasis que contiene el sistema sensorial necesario para la conducción autónoma 5.12.

Los sensores y sistemas de procesamiento añadidos al vehículo son:

- Sistema GNSS con aplicación de técnicas de posicionamiento diferencial y RTK
- Odometría basada en encoders en las ruedas traseras del vehículo

- LiDAR de la compañía Velodyne modelo VLP-16
- Sistema de Radares 360° de Huawei
- Sistema estéreo de cámaras modelo ZED de StereoLabs
- Sistema de computo distribuido con 5 CPUs compuesto por 3 Raspberry Pi 3, 1 NVIDIA Jetson AGX Xavier y un portátil con una tarjeta gráfica GTX 1070



Figura 5.12: Chasis con el hardware necesario para la conducción autónoma.

Con este sistema se procesa la localización, el sistema Drive-By-Wire y el HMI en las Raspberry Pi 3. Para el procesamiento de las imágenes o la nube de puntos se utiliza la NVIDIA Jetson AGX Xavier, mientras que el portátil es de uso general relegando a éste las aplicaciones del sistema computacionalmente más costosas haciendo uso de la aceleración por hardware de la GPU.



Figura 5.13: Vehículo T4AC.

Dicho vehículo y el sistema de Drive-By-Wire ha sido diseñado por Juan Felipe Arango Vargas en su Trabajo Fin de Master [56].

5.5 Implementación sobre el vehículo Techs4AgeCar

El aporte de este trabajo a la capa de percepción del sistema autónomo consta del estudio e implementación del modelo PointPillars Multihead y realización de la fusión sensorial con la cámara. Previamente en el vehículo se utilizaba un sistema donde se tenía el modelo PointPillars corriendo en la NVIDIA Jetson, pero debido a su baja precisión y alta tasa de falsos positivos, no se utilizaba debido en gran medida al

uso de únicamente los 16 haces del [LiDAR](#), mientras que dicho modelo suele ser entrenado con [LiDAR](#) de 32 o 64 haces. Actualmente con la mejora que ofrece el modelo PointPillars Multihead ya es utilizable en el vehículo T4AC con una precisión suficientemente buena.

En la arquitectura propuesta se utiliza el trabajo realizado en este Trabajo Fin de Grado junto con las mejoras de detección en cámara [14], para realizar una fusión sensorial entre ambos métodos. Tras la obtención de estas detecciones mejoradas, se introducen en el sistema SmartMOT [53] desarrollado en el grupo RobeSafe que realiza un seguimiento de los vehículos en [BEV](#), de tal manera que se obtienen la posición, velocidad lineal, velocidad angular y tipo de objeto, mejorando además las detecciones al utilizar dicho sistema de seguimiento de objetos.

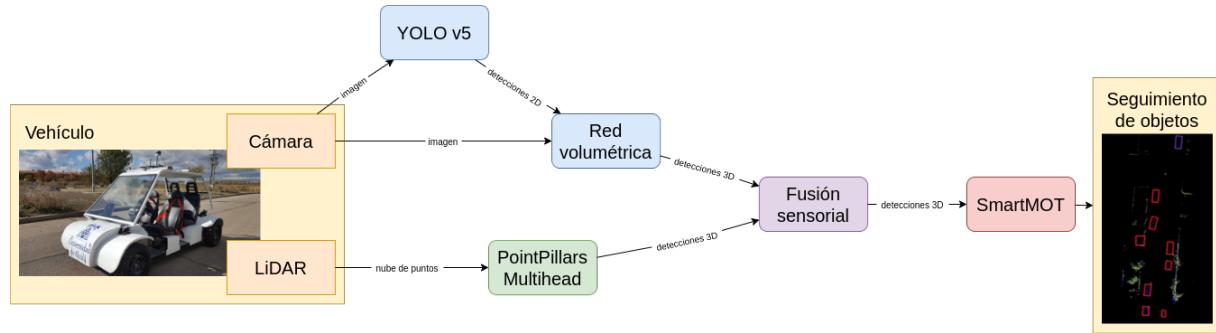


Figura 5.14: Arquitectura de la capa de percepción.

Dicha mejora en el sistema será pasada en [BEV](#) a las siguientes capas de la arquitectura del proyecto para mejorar así también su funcionamiento.

Capítulo 6

AD DevKit

La inspiración existe, pero tiene que encontrarte trabajando.

Picasso

En conjunto con el [KIT](#) se ha comenzado a desarrollar la herramienta el [AD DevKit](#), un evaluador de sistemas de conducción autónoma basado en el simulador CARLA. Este trabajo es complementario al desarrollo principal del TFG, ya que con dicha herramienta se pretende evaluar el sistema de detección con [LiDAR](#) implementado en CARLA, además de ofrecer al grupo RobeSafe una herramienta para la comparativa en el simulador CARLA de las diferentes técnicas de percepción implementadas y en un futuro lanzar dicha herramienta Open-Source para los investigadores que utilicen CARLA.

6.1 Motivación para la creación del AD DevKit

Durante el comienzo del desarrollo de este Trabajo Fin de Grado el cotutor Carlos Gómez Huélamo realiza un estancia en el [KIT](#) donde se propone la idea de creación de un sistema de evaluación de sistemas de conducción autónoma que no solo se reduzca a la parte de percepción sino que también afecte al control, planificación y al sistema de decisiones del vehículo.

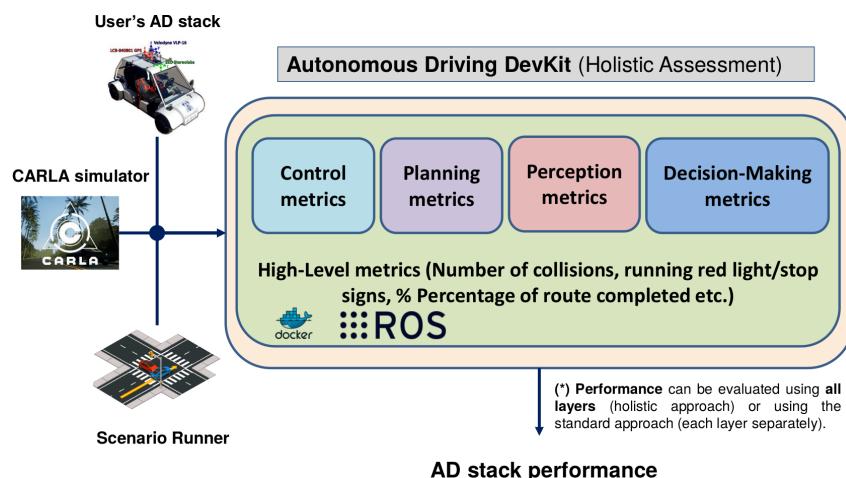


Figura 6.1: Arquitectura del AD DevKit.

Este acercamiento no ha sido visto nunca hasta ahora, por lo que el trabajo en este proyecto puede llegar a tener un gran impacto, ya no solo por el carácter multidisciplinar del evaluador sino por la creación de un evaluador en CARLA, aunque durante el desarrollo de este evaluador se han publicado desde un modelo entrenado sobre CARLA [57] a un evaluador de percepción para CARLA [58].

El diseño del evaluador se encuentra dividido en 4 partes, cada una evaluando un apartado del sistema de conducción autónomo. Mientras que el grupo RobeSafe se encarga de la evaluación de percepción y el control, en el KIT se encargan de la evaluación de la planificación y la toma de decisiones. Dentro del grupo RobeSafe, Carlos Gómez Huélamo, el cotutor del TFG, se ha encargado del evaluador de la capa de control, obteniendo el groundtruth necesario junto con métricas para puntuar a los modelos.

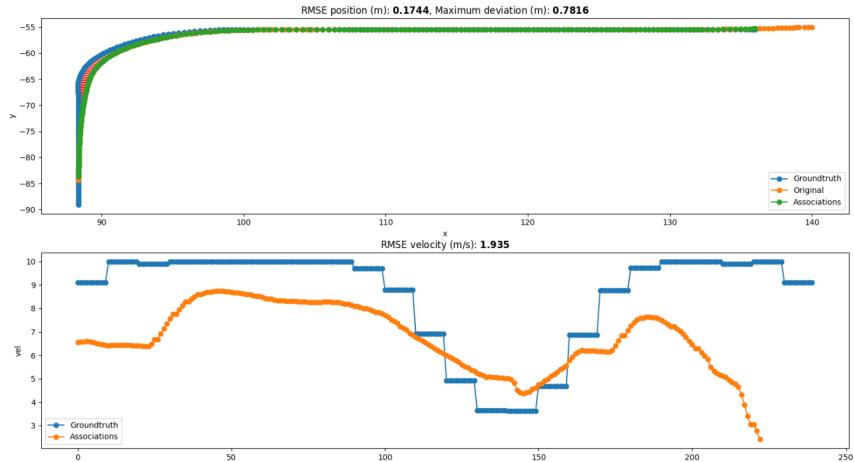


Figura 6.2: Métricas de control en el AD DevKit.

El apartado para la evaluación de la capa de percepción es la abordada en este trabajo, pero al ser un trabajo de gran complejidad se realiza de forma conjunta con Miguel Antunes García [14], ya que este desarrollo permite realizar en ambos TFGs el análisis de los métodos de percepción implementados en la arquitectura del proyecto Techs4AgeCar.

Un sistema de evaluación de múltiples capas puede sufrir una menor valoración que un método de una capa en concreto, ya que el problema puede provenir de otra capa. Por ejemplo, un fallo en la capa de planificación, puede resultar en una pobre valoración del sistema de control. Para solucionar esto, se propone un sistema de evaluación online por capas en la que a la vez que se corre el simulador CARLA se realiza la evaluación. El desarrollo propuesto para la realización dentro de este TFG, se encuentra compuesto de la generación de groundtruth en tiempo real, mientras que la evaluación se realiza a posteriori, para de esta manera obtener una primera versión funcional del sistema de evaluación.

6.2 Obtención del groundtruth

El simulador CARLA ofrece información a través de ROS de todo el entorno, esto quiere decir que se puede obtener la información del resto de objetos del entorno para crear un dataset de forma online u offline. Dicha información en ROS viene definida en el topic `/carla/objects` en con un formato basado en un array de objetos, teniendo cada objeto la información del tipo, posición, velocidad, etc.

Para el desarrollo de este apartado del AD DevKit se parte del trabajo 'A Baseline for CARLA Online Ground-Truth Generation (AB4COGT)' [59], pero al encontrar multitud de malas prácticas de programación que influirían en la ampliación y mantenimiento del código, se decide realizar una reingeniería del mismo para solucionar los problemas encontrados.

Tipo	Nombre
Header	header
Object[]	objects

Tabla 6.1: Formato de la lista de objetos de CARLA

Tipo	Nombre
Header	header
uint32	id
uint8	detection_level
bool	object_classified
geometry_msgs/Pose	pose
geometry_msgs/Twist	twist
geometry_msgs/Accel	accel
geometry_msgs/Polygon	polygon
shape_msgs/SolidPrimitive	shape
uint8	classification
uint8	classification_certainty
uint32	classification_age

Tabla 6.2: Formato objeto de CARLA

El repositorio del que se parte [59] genera un archivo de texto que contiene la información de posición 3D de todos los objetos del entorno, su orientación y tipo. Dicho groundtruth generado solo sería apto para un sistema LiDAR que tenga los objetos en su campo de visión. Para ello se propone un sistema de generación de groundtruth en tiempo real que publique las detecciones en ROS como un mensaje, analice la visibilidad de los objetos, genere las detecciones 2D para sistemas de cámara y guarde los resultados como un fichero CSV para comprender de mejor manera los datos guardados, todo ello junto con los datos provenientes de cámara, LiDAR y Radar. Este primer apartado se desarrolla principalmente de forma individual, por lo que es necesario el estudio de diversas técnicas para la obtención del groundtruth.

6.2.1 Calculo de la visibilidad de los objetos

El proyecto AB4COGT obtiene el groundtruth de los objetos cercanos al vehículo, pero en este no se calcula la visibilidad de dichos objetos. Es necesario realizar el cálculo de la visibilidad de los objetos desde el vehículo, ya que, en el caso contrario, al proceder a la evaluación se reduciría la precisión de los modelos por no poder detectar dichos objetos ocluidos o no visibles.

Listado 6.1: Filtrado en función de la visibilidad de los objetos en el AD DevKit

```
f_visible_bb = (lambda bb, points: np.logical_and( \
    np.logical_and(bb[0]-bb[3]/2 <= np.array(points[:,0]), \
                  np.array(points[:,0]) <= bb[0]+bb[3]/2, \
                  bb[1]-bb[4]/2 <= np.array(points[:,1])), \
    np.logical_and(np.array(points[:,1]) <= bb[1]+bb[4]/2, \
                  bb[2]-bb[5]/2 <= np.array(points[:,2]), \
                  np.array(points[:,2]) <= bb[2]+bb[5]/2))) \
n_points_in_bb = 0
if self.pointcloud is not None:
    points_in_bb = f_visible_bb((obj.position_x, obj.position_y, \
                                 obj.position_z, obj.l, obj.w, obj.h), \
                                 self.pointcloud)
    n_points_in_bb = np.add.reduce(points_in_bb)
```

Una de las partes más importantes y delicadas para el uso de esta aplicación en tiempo real es la eficiencia, por lo que hubo que analizar la manera en que se puede realizar un método similar al trazado de rayos, pero con un bajo coste computacional, por ello se decide utilizar la última nube de puntos obtenida de ROS para filtrar los objetos del entorno en función de si se encuentra algún punto de dicha nube dentro de la bounding box 3D del groundtruth de CARLA. Este método es similar al utilizado en nuScenes donde solo se añaden una bounding box si se encuentra algún punto del LiDAR sobre esta. Para la realización de esta operación es necesaria la vectorización de las operaciones, ya que es necesario un computo en un tiempo menor a 10^{-2} segundos.

6.2.2 Geometría de la cámara

La generación de bounding boxes 2D para los sistemas de cámara a evaluar no son obtenidas directamente de ROS, por lo que es necesario realizar una serie de transformaciones para pasar de las coordenadas del mundo a los píxeles que contienen ese objeto dentro de la imagen generada por la cámara. Se analiza por tanto el funcionamiento de la geometría de la cámara.

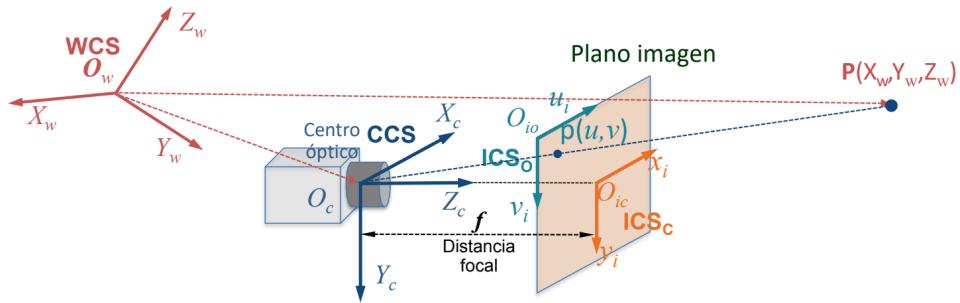


Figura 6.3: Transformaciones mundo a cámara.

En las diferentes transformaciones a realizar se trabaja con las coordenadas homogéneas, lo que quiere decir que se agrega un cuarto componente a las coordenadas cartesianas.

$$(x, y, z) \rightarrow (x', y', z', w)$$

$$(x, y, z) = (x'/w, y'/w, z'/w)$$

Se comienza realizando un cambio de referencia de cámara a imagen, por lo que es necesario realizar una traslación y una rotación del sistema de coordenadas, pero tiene que ser en este orden ya que la multiplicación de matrices no es conmutativa. Por lo que se aplica la traslación sobre las coordenadas.

$$\begin{bmatrix} wX_c \\ wY_c \\ wZ_c \\ w \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & TX \\ 0 & 1 & 0 & TY \\ 0 & 0 & 1 & TZ \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}$$

Tras aplicar la traslación se aplica la rotación en los ejes X, Y, Z.

$$R = R_X(\alpha)R_Y(\beta)R_Z(\gamma)$$

$$\begin{bmatrix} wX_c \\ wY_c \\ wZ_c \\ w \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos \alpha & -\sin \alpha & 0 \\ 0 & \sin \alpha & \cos \alpha & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \cos \beta & 0 & \sin \beta & 0 \\ 0 & 1 & 0 & 0 \\ -\sin \beta & 0 & \cos \beta & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \cos \gamma & -\sin \gamma & 0 & 0 \\ \sin \gamma & \cos \gamma & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}$$

Ambos pasos de traslación y rotación se pueden unir en una matriz de parámetros extrínsecos de la cámara que es independiente al tipo de cámara utilizada.

$$\begin{bmatrix} wX_c \\ wY_c \\ wZ_c \\ w \end{bmatrix} = \begin{bmatrix} \cos \gamma \cos \beta & -\sin \gamma \cos \beta & \sin \beta & T_X \\ \cos \gamma \sin \alpha \sin \beta + \sin \gamma \cos \alpha & \cos \gamma \cos \alpha - \sin \gamma \sin \alpha \sin \beta & -\sin \alpha \cos \beta & T_Y \\ \sin \gamma \sin \alpha - \cos \gamma \cos \alpha \sin \beta & \sin \gamma \cos \alpha \sin \beta + \cos \gamma \sin \alpha & \cos \alpha \cos \beta & T_Z \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}$$

$$M_{ext} = \begin{bmatrix} r_{11} & r_{12} & r_{13} & t_X \\ r_{21} & r_{22} & r_{23} & t_Y \\ r_{31} & r_{32} & r_{33} & t_Z \end{bmatrix}$$

Tras la trasformación de mundo a cámara se pasa de coordenadas tridimensionales de la cámara a bidimensionales de las imágenes, para ello se utiliza la distancia focal (f) entre el centro óptico de la lente y el punto focal.

$$\begin{bmatrix} wx \\ wy \\ w \end{bmatrix} = \begin{bmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} X_c \\ Y_c \\ Z_c \\ 1 \end{bmatrix}$$

Por último es necesario aplicar una transformación en la imagen, realizando una conversión de milímetros a píxeles y aplicando un offset para trasladar el centro de la imagen. Tras esta operación se pasa de las coordenadas de los ejes x e y (dx, dy) a las coordenadas pixélicas (u, v).

$$\begin{bmatrix} wu \\ wv \\ w \end{bmatrix} = \begin{bmatrix} 1/dx & 0 & u_0 \\ 0 & 1/dy & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} wx \\ wy \\ w \end{bmatrix}$$

De la misma forma que se puede obtener una matriz de parámetros extrínsecos, se obtiene una matriz de parámetros intrínsecos, la cual se encuentra compuesta de las transformaciones de cámara a imagen y de milímetros a píxeles.

$$M_{int} = \begin{bmatrix} 1/dx & 0 & u_0 \\ 0 & 1/dy & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} f & 0 & 0 \\ 0 & f & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} f/dx & 0 & u_0 \\ 0 & f/dy & v_0 \\ 0 & 0 & 1 \end{bmatrix}$$

Dicha matriz intrínseca no es necesario calcularla ya que es fija en función de las características de la cámara, por lo que CARLA ofrece esta matriz. Calculando únicamente la matriz extrínseca se hayan las coordenadas en pixélicas aplicando ambas matrices extrínseca e intrínseca sobre las coordenadas homogéneas.

$$\begin{bmatrix} wu \\ wv \\ w \end{bmatrix} = M_{int} M_{ext} \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}$$

Teniendo las bounding boxes 3D transformadas a bounding boxes 2D se marcan aquellas que son visibles desde la cámara y cuales no, para ello se define las bounding boxes 2D como (-1, -1, -1, -1) para identificar que hay un objeto visibles desde el vehículo pero no desde la posición de la cámara.

6.2.3 Formato del groundtruth obtenido

El groundtruth utilizado en la evaluación de los sistemas de percepción consta de múltiples atributos, como son: tiempo del groundtruth, tipo de objeto, bounding box 2D, posición, tamaño, rotación y velocidad. A partir de estos parámetros se crea el CSV necesario para la evaluación offline y los mensajes de ROS necesarios para la evaluación online.

Dos de estos atributos son los denominados en el dataset KITTI: *alpha* y *rotation_y*. Alpha identifica respecto de las coordenadas de cámara de KITTI el ángulo formado entre el eje X y la dirección del coche detectado, mientras que *rotation_y* es el ángulo entre el eje X y la recta que une el vehículo propio y el detectado. Este último ángulo es renombrado a *rotation_z* en el groundtruth para aludir al sistema de coordenadas de CARLA y no al de KITTI.

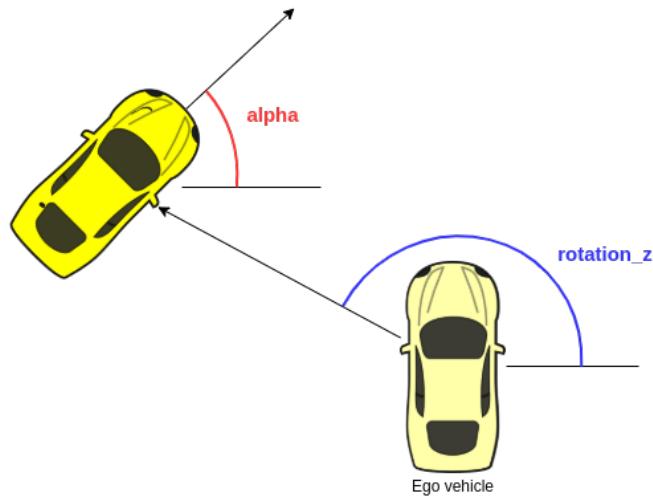


Figura 6.4: Ángulos alpha y rotation_z del groundtruth del AD DevKit.

El CSV contiene la información del groundtruth para la evaluación offline, mientras que para la evaluación de forma online se ha tenido que crear un nuevo tipo de mensaje haciendo uso de otros mensajes estandarizados por la comunidad de ROS.

Tipo	Nombre
Header	header
GT_3D_Object[]	gt_3d_object_list

Tabla 6.3: Formato de la lista de detecciones en ROS

Tipo	Nombre
string	type
uint32	object_id
float32	alpha
vision_msgs/BoundingBox2D	bounding_box_2D
geometry_msgs/Point	position
geometry_msgs/Vector3	dimensions
float32	rotation_z
geometry_msgs/Vector3	velocity

Tabla 6.4: Formato de una detección en ROS

6.2.4 Funcionamiento del generador de groundtruth

El funcionamiento del sistema de obtención del groundtruth se basa en un nodo que realiza todas las suscripciones necesarias para obtener dichos datos de la forma correcta y enviarlo como mensaje a ROS. Tras esto se suscribe al groundtruth recién publicado y se crea un archivo CSV con este. Por último se guarda la información proveniente de la cámara, **LiDAR** y **Radar** para poder ejecutar los modelos con los mismos datos más adelante y realizar así la evaluación online.

```
frame,timestamp,id,type,alpha,left,top,right,bottom,l,w,h,x,y,z,rotation_z,vx,vy,vz
2,94.442329881,94,Car,-0.29440239668,-1,-1,-1,4.48043600191,2.06931519508,2.03779101372,11.586334414,.36.8545920228,0.161239712244,3.10979,
2,94.442329881,95,Car,-0.03960180283,199,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.8399127235,9.84055040432,0.00486457370748,0.0
3,94.492329881,94,Car,-0.294316649437,-1,-1,-1,4.48043600191,2.06931519508,2.03779101372,11.5803293886,-36.8511868726,0.159888938197,3.1096
3,94.492329881,95,Car,-0.03960111276,199,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.8323419538,9.8405828648,0.00283542154772,0.0
4,94.542329882,95,Car,-0.03990769386,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.8252751741,9.840601019183,0.00142875618612,0.0
5,94.592329883,95,Car,-0.0400454998,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.8186565001,9.84061087589,0.000529616218918,0.0
6,94.642329884,94,Car,-0.29495799545,-1,-1,-1,4.48043600191,2.06931519508,2.03779101372,11.5881752807,-36.7920554856,0.155314192995,3.1085
6,94.642329884,95,Car,-0.040017591476,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.8124474991,9.84064353527,3.07104957226e-05,0
7,94.692329884,94,Car,-0.295519590378,-1,-1,-1,4.48043600191,2.06931519508,2.03779101372,11.5996042225,-36.7554511073,0.153871217113,3.1075
7,94.692329884,95,Car,-0.04029607773,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.8066824624,9.8406566379,-0.000186565823886,0
8,94.742329885,94,Car,-0.296286553144,-1,-1,-1,4.48043600191,2.06931519508,2.03779101372,11.6161228468,-36.7086356807,0.152375458974,3.1062
8,94.742329885,95,Car,-0.04040718079,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.801314009,9.84064657777,-0.000186553556924,0
9,94.792329886,95,Car,-0.04051363864,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.796328006,9.84068332388,-7.67941844408e-05,0
10,94.842329886,95,Car,-0.04061150551,198,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.7916438941,9.84071091164,0.000138782261702,0
11,94.892329887,95,Car,-0.0407025051,197,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.7873086236,9.8407284307,0.000414787872964,0
12,94.942329888,95,Car,-0.04078698158,197,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.7832918259,9.84074234159,0.00070523618991,0
13,94.992329889,95,Car,-0.0408308506,197,346,379,444,5.20383834839,2.61457228661,2.46744465828,19.7812619787,9.84078162454,-0.00330196597058,0
14,95.042329889,95,Car,-0.0408885479,197,345,378,443,5.20383834839,2.61457228661,2.46744465828,19.7784775256,9.84077187851,-0.000842735336442,0
15,95.09232989,95,Car,-0.04063153267,197,345,379,443,5.20383834839,2.61457228661,2.46744465828,19.7760121108,9.83326017244,0.00755065485613,0
```

Figura 6.5: Archivo CSV con los datos del groundtruth obtenidos.

Para reproducir la información de la cámara se adjuntan a las imágenes RGB, la matriz de parámetros intrínsecos y el listado de tiempos en el que han sido tomadas las imágenes. En el caso del **LiDAR** y el **Radar** se guardan las nubes de puntos como un archivo binario, el cual tiene explicado el formato en un fichero de texto adjunto junto con otro archivo que incluye los tiempos en los que han sido obtenidas las nubes de puntos.

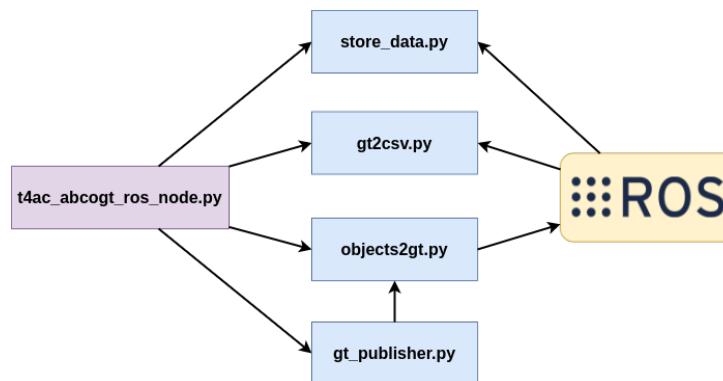


Figura 6.6: Estructura del generador de groundtruth del AD DevKit.

En el desarrollo de la herramienta se adopta un acercamiento basado en **OOP** y paralelismo en la ejecución de las funciones a partir del uso de los diferentes objetos de forma paralela para obtener una mayor eficiencia, al ser un requisito tan importante en el desarrollo. Todo este desarrollo es accesible en GitHub en https://github.com/RobeSafe-UAH/ad_devkit.

6.3 Evaluación de los modelos

Con la obtención de los objetos del entorno que tiene que ser detectados, se crea el apartado para la evaluación offline de los modelos. Dicho apartado es realizado de forma offline y no online debido a las

complicaciones que supone generar el groundtruth, correr los modelos y evaluarlos en tiempo real, por lo que se decide evaluarlos a posteriori de la ejecución. Esto se traduce en tres fases para la evaluación de un modelo: generación del groundtruth, ejecución del modelo para la obtención de las detecciones y evaluación de las detecciones respecto del groundtruth.

Para la generación del archivo CSV de las detecciones procedentes del modelo PointPillars Multi-head se ha añadido al repositorio https://github.com/RoboSafe-UAH/t4ac_openpcdet_ros que contiene el modelo implementado sobre CARLA, un script que a partir del desarrollo realizado reutiliza sus funciones para correr el modelo y guardar las detecciones en un fichero CSV. Dicho script aún funcionando sin ningún ajuste, puede ser utilizado en otras arquitecturas ajustando ciertos flags antes de la ejecución.

La evaluación de un modelo se realiza a partir de diferentes métricas utilizadas en datasets estudiados como son kitti y nuScenes para así tratar de estandarizar aún más esta herramienta. Las métricas calculadas en la evaluación son las siguientes:

- [Intersection over Union](#)

En la evaluación se utiliza el IoU 2D y 3D para hacer una relación entre las detecciones y el groundtruth, utilizando la versión bidimensional para relacionar las bounding boxes 2D y la versión tridimensional para relacionar las bounding boxes 3D.

$$IoU \text{ 2D} = \frac{\text{Área de la intersección}}{\text{Área de la unión}}$$

$$IoU \text{ 3D} = \frac{\text{Volumen de la intersección}}{\text{Volumen de la unión}}$$

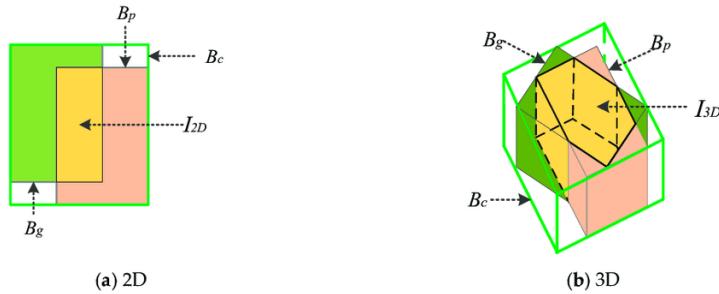


Figura 6.7: Visualización del IoU 2D y 3D.

- Curva precision-recall

La precision indica cuantas de las detecciones son verdaderas.

$$Precision = \frac{\text{Verdaderos positivos}}{\text{Verdaderos positivos} \cup \text{Falsos positivos}}$$

Mientras que el recall indica cuanto del groundtruth es detectado.

$$Precision = \frac{\text{Verdaderos positivos}}{\text{Verdaderos positivos} \cup \text{Falsos negativos}}$$

La curva de precision-recall por tanto representa la relación entre precision y recall.

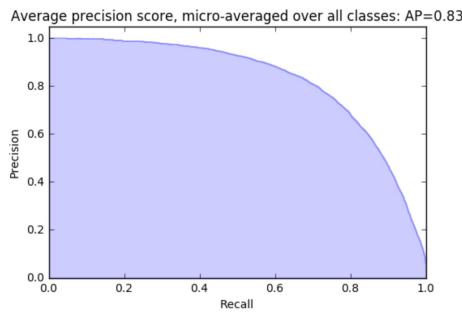


Figura 6.8: Ejemplo de curva de precision-recall.

- **Average Precision**

Esta es una métrica muy importante ya que relaciona tanto la precision como el recall para medir cómo de preciso es un modelo. Para ello se calcula el área por debajo de la curva de precisión, teniendo ésta un valor entre 0 y 1.

No solo se calcula el **AP** por cada clase sino que también se calcula el **mAP** que sería la media de precisión de todas las clases para la obtención de la precisión general del modelo.

- **Average Velocity Error (AVE)**

La evaluación de los sistemas de seguimiento también se han tenido en cuenta por lo que se calcula una métrica como es el **AVE** para saber de que manera se estima la velocidad de los objetos, pudiendo obtenerla tanto por clase como por la media de todas estas. Esta métrica se calcula como el error de velocidad absoluto en 2D trabajando en **BEV**.

Este apartado del evaluador ha sido realizado principalmente por Miguel Antunes García en su TFG [14] de forma que al unirlo al generador de groundtruth, se ha conseguido un funcionamiento básico para la capa de percepción del **AD DevKit**.

Capítulo 7

Resultados obtenidos

Ninguna investigación humana puede ser llamada ciencia real si no puede demostrarse matemáticamente.

Leonardo da Vinci

Este capítulo muestra los resultados de los diferentes modelos y algoritmos presentados para la detección 3D con **LiDAR** sobre: datasets, el simulador CARLA y el vehículo T4AC.

Las métricas de tiempo de todos los modelos han sido realizadas sobre un ordenador con un procesador AMD Ryzen 3700X y una tarjeta gráfica NVIDIA RTX 2060 Super.

Para la visualización de los resultados sobre CARLA y sobre el vehículo T4AC en el campus de la Universidad de Alcalá, se presenta un vídeo en <https://youtu.be/9vLnA27dmns> con en el desarrollo realizado sobre la arquitectura del proyecto Techs4AgeCar.

7.1 Análisis sobre datasets

Los modelos explicados en el capítulo 4.2 se evalúan en este apartado, cada uno en el dataset donde han sido entrenados: SECOND, PointPillars, PointRCNN y PV-RCNN en KITTI, y CBGS en nuScenes, para mostrar de esta manera la precisión de dichos modelos.

Para la evaluación de ambos modelos se han descargado las versiones completas de KITTI y nuScenes junto con los modelos y sus pesos, analizando en cada uno las métricas utilizadas en su respectivo dataset.

7.1.1 Análisis cuantitativo en Kitti

La evaluación sobre el dataset KITTI consta de los modelos: SECOND, PointPillars, PointRCNNy PV-RCNN. Dichos modelos se evalúan en los benchmark de detección, orientación, detección 3D y **BEV**, tanto como análisis general del modelo como análisis por clase en cada uno de los modelos.

KITTI requiere de un **IoU** mínimo del 70 % para dar por correcta una detección con la clase coche, mientras que para los ciclistas y peatones solo se requiere de un **IoU** del 50 %. Es necesario tener en cuenta que en este dataset se utilizan 3 dificultades diferentes, donde en la evaluación fácil se utilizan los objetos con un máximo de 15 % de oclusión, en la evaluación moderada un máximo del 30 % y en la evaluación difícil un máximo del 50 %.

El cálculo del AP para los benchmark de detección 2D, vista de pájaro y detección 3D, se realiza a partir del área bajo la curva de precision-recall, construida con 40 límites para su mayor precisión en la evaluación.

$$AOS = \frac{1}{40} \sum_{r \in 0, 0.25, \dots, 1} \max_{\bar{r}: \bar{r} \geq r} s(\bar{r})$$

$$\text{recall: } r = \frac{TP}{TP + FN}$$

$$s(r) = \frac{1}{|\mathcal{D}(r)|} \sum_{i \in \mathcal{D}(r)} \frac{1 + \cos \Delta_\theta^{(i)}}{2} \delta_i$$

Mientras que para la estimación de la orientación se utiliza la métrica Average Orientation Similarity (AOS) con un valor que oscila entre 0 y 1, siendo 1 la orientación perfecta.

Benchmark		Fácil	Moderado	Difícil
Coche	Detección	95.61 %	75.39 %	77.47 %
	Vista de pájaro	84.62 %	65.57 %	63.14 %
	Detección 3D	74.15 %	54.27 %	50.98 %
	Orientación	95.58 %	75.31 %	77.31 %
Peatón	Detección	68.12 %	63.66 %	60.34 %
	Vista de pájaro	10.14 %	9.62 %	8.55 %
	Detección 3D	5.57 %	5.09 %	4.49 %
	Orientación	63.55 %	58.45 %	55.06 %
Ciclista	Detección	91.14 %	64.77 %	61.99 %
	Vista de pájaro	67.30 %	43.51 %	41.26 %
	Detección 3D	54.98 %	34.98 %	33.29 %
	Orientación	90.99 %	64.59 %	61.77 %

Tabla 7.1: Análisis por clase de SECOND en KITTI.

Benchmark		Fácil	Moderado	Difícil
Coche	Detección	95.54 %	74.76 %	75.24 %
	Vista de pájaro	87.12 %	67.08 %	64.68 %
	Detección 3D	78.07 %	57.58 %	52.85 %
	Orientación	95.52 %	74.67 %	75.06 %
Peatón	Detección	66.39 %	61.58 %	58.21 %
	Vista de pájaro	24.56 %	23.77 %	21.33 %
	Detección 3D	15.86 %	15.03 %	13.47 %
	Orientación	45.76 %	42.35 %	39.46 %
Ciclista	Detección	88.41 %	60.70 %	57.32 %
	Vista de pájaro	76.76 %	48.92 %	46.30 %
	Detección 3D	68.06 %	43.23 %	40.46 %
	Orientación	87.81 %	59.64 %	56.26 %

Tabla 7.2: Análisis por clase de PointPillars en KITTI.

Benchmark		Fácil	Moderado	Difícil
Coche	Detección	96.51 %	78.63 %	78.68 %
	Vista de pájaro	93.26 %	75.47 %	75.46 %
	Detección 3D	91.71 %	69.82 %	69.54 %
	Orientación	96.49 %	78.59 %	78.60 %
Peatón	Detección	74.73 %	66.59 %	61.16 %
	Vista de pájaro	64.49 %	58.17 %	51.48 %
	Detección 3D	60.53 %	54.28 %	47.50 %
	Orientación	71.76 %	63.17 %	57.71 %
Ciclista	Detección	96.91 %	66.66 %	63.89 %
	Vista de pájaro	92.35 %	62.41 %	59.39 %
	Detección 3D	88.98 %	61.01 %	56.88 %
	Orientación	96.82 %	66.23 %	63.45 %

Tabla 7.3: Análisis por clase de PointRCNN en KITTI.

Benchmark		Fácil	Moderado	Difícil
Coche	Detección	97.21 %	77.30 %	77.69 %
	Vista de pájaro	92.48 %	73.67 %	74.08 %
	Detección 3D	89.46 %	69.74 %	70.02 %
	Orientación	97.17 %	77.19 %	77.49 %
Peatón	Detección	46.47 %	46.87 %	47.41 %
	Vista de pájaro	32.67 %	32.47 %	31.59 %
	Detección 3D	29.42 %	29.07 %	27.87 %
	Orientación	41.55 %	41.21 %	41.47 %
Ciclista	Detección	89.72 %	64.60 %	62.31 %
	Vista de pájaro	85.62 %	56.86 %	53.10 %
	Detección 3D	80.93 %	53.25 %	49.52 %
	Orientación	88.62 %	63.66 %	61.40 %

Tabla 7.4: Análisis por clase de PV-RCNN en KITTI.

Las clases de peatón y ciclista, como se puede ver principalmente en los modelos SECOND y PointPillars, al ser valuados sobre KITTI obtienen una precisión muy baja, esto es debido a que dichas clases son detectadas con muy pocos puntos de la nube de puntos correspondiente, por lo que no es muy preciso en dichas clases. Para evaluar de forma más significativa y comparar los diferentes modelos se evalúan las tareas de detección 3D y BEV con un IoU de 0.7 y 0.5 en coches, y para el caso de peatones y ciclistas de 0.5 y 0.25.

Modelo	Benchmark	Min. IoU	Fácil	Moderado	Difícil	Velocidad
SECOND	Detección	0.7 - 0.5	84.96 %	67.94 %	66.6 %	18.59 Hz
	Vista de pájaro	0.7 - 0.5	54.02 %	39.57 %	37.65 %	
		0.5 - 0.25	86.40 %	70.29 %	68.72 %	
	Detección 3D	0.7 - 0.5	44.90 %	31.45 %	29.59 %	
		0.5 - 0.25	86.11 %	69.75 %	67.81 %	
	Orientación	0.7 - 0.5	83.37 %	66.12 %	64.71 %	
PointPillars	Detección	0.7 - 0.5	83.45 %	65.68 %	63.59 %	37.29 Hz
	Vista de pájaro	0.7 - 0.5	62.81 %	46.59 %	44.10 %	
		0.5 - 0.25	85.83 %	67.86 %	66.45 %	
	Detección 3D	0.7 - 0.5	54.00 %	38.61 %	35.59 %	
		0.5 - 0.25	85.85 %	67.66 %	65.47 %	
	Orientación	0.7 - 0.5	76.36 %	58.89 %	56.92 %	
PointRCNN	Detección	0.7 - 0.5	89.38 %	70.63 %	67.91 %	8.62 Hz
	Vista de pájaro	0.7 - 0.5	83.37 %	65.02 %	62.11 %	
		0.5 - 0.25	91.32 %	72.79 %	70.10 %	
	Detección 3D	0.7 - 0.5	80.41 %	61.70 %	57.97 %	
		0.5 - 0.25	91.27 %	72.73 %	70.01 %	
	Orientación	0.7 - 0.5	88.36 %	69.33 %	66.59 %	
PV-RCNN	Detección	0.7 - 0.5	77.8 %	62.92 %	62.47 %	5.39 Hz
	Vista de pájaro	0.7 - 0.5	86.10 %	54.33 %	52.92 %	
		0.5 - 0.25	78.23 %	63.24 %	63.61 %	
	Detección 3D	0.7 - 0.5	66.60 %	50.69 %	49.14 %	
		0.5 - 0.25	78.06 %	62.87 %	63.16 %	
	Orientación	0.7 - 0.5	75.78 %	60.69 %	60.12 %	

Tabla 7.5: Comparativa de los modelos entrenados sobre KITTI.

Tras la obtención de la comparativa cuantitativa de los modelos en al tabla 7.5 se observa como la mejor precisión se obtiene utilizando el modelo PointRCNN y la mayor velocidad de inferencia con el modelo PointPillars.

7.1.2 Análisis cuantitativo en nuScenes

La evaluación sobre el dataset nuScenes consta únicamente del modelo CBGS, pero este modelo se utiliza con dos backbone diferentes: uno basado en SECOND y otro en PointPillars.

Los modelos entrenados sobre nuScenes se evalúan únicamente sobre el benchmark de detección 3D, dicha evaluación consta no solo del AP, como realiza KITTI, sino que también utiliza las siguientes métricas:

- **Average Translation Error (ATE)**: Distancia euclídea en BEV medido en metros
- **Average Scale Error (ASE)**: Calculado como $1 - \text{IoU}$ tras alinear el centro y la orientación
- **Average Orientation Error (AOE)**: Ángulo más pequeño entre la predicción y el groundtruth medido en radianes

- **Average Velocity Error:** Error de la velocidad absoluta en m/s
- **Average Attribute Error (AAE):** Calculado como $1 - acc$, donde acc es la precisión de la clasificación de atributos

Para la evaluación general del modelo se define el parámetro nuScenes Detección Score (NDS) que indica la precisión respecto de todas las métricas calculadas del modelo.

$$NDS = \frac{1}{2} - \frac{mATE + mASE + mAOE + mATE + mAAE}{10} + \frac{mAP}{2}$$

Con este método de evaluación general se otorga 5 veces la importancia del resto de métricas al AP, al considerarse en nuScenes que es la métrica más importante.

Tipo de objeto	AP	ATE	ASE	AOE	AVE	AAE
Coche	0.82	0.18	0.15	0.9	0.26	0.20
Camión	0.52	0.34	0.19	0.06	0.21	0.24
Bus	0.67	0.35	0.18	0.04	0.38	0.26
Tráiler	0.37	0.52	0.21	0.28	0.18	0.18
Vehículo de construcción	0.15	0.75	0.45	0.78	0.12	0.34
Peatón	0.78	0.16	0.28	0.39	0.24	0.09
Motocicleta	0.43	0.22	0.23	0.33	0.48	0.29
Bicicleta	0.17	0.18	0.26	0.33	0.23	0.02
Cono de tráfico	0.58	0.17	0.33	nan	nan	nan
Barrera	0.59	0.26	0.28	0.06	nan	nan

Tabla 7.6: Análisis por clase de CBGS SECOND Multihead en nuScenes.

Tipo de objeto	AP	ATE	ASE	AOE	AVE	AAE
Coche	0.81	0.19	0.15	0.12	0.28	0.21
Camión	0.50	0.35	0.19	0.09	0.22	0.24
Bus	0.64	0.37	0.18	0.05	0.44	0.29
Tráiler	0.35	0.61	0.21	0.39	0.18	0.16
Vehículo de construcción	0.12	0.76	0.45	0.77	0.12	0.33
Peatón	0.72	0.17	0.28	0.39	0.25	0.09
Motocicleta	0.29	0.23	0.25	0.45	0.58	0.27
Bicicleta	0.06	0.19	0.27	0.50	0.25	0.04
Cono de tráfico	0.47	0.18	0.33	nan	nan	nan
Barrera	0.50	0.34	0.29	0.07	nan	nan

Tabla 7.7: Análisis por clase de CBGS PointPillars Multihead en nuScenes.

Al utilizar el modelo CBGS para la mejora del sistema de detección en el vehículo T4AC que utiliza el modelo PointPillars, se muestran los resultados del modelo PointPillars proporcionado por nuScenes

como baseline para su benchmark de detección. Estos resultados son recogidos del propio ranking de detección al ser una versión modificada para su uso en nuScenes, que usa 10 barridos del LiDAR para la inferencia de las velocidades, se ajusta a las características de intensidad del LiDAR y realiza una detección en los 360°.

Tipo de objeto	AP	ATE	ASE	AOE	AVE	AAE
Coche	0.68	0.28	0.16	0.20	0.24	0.36
Camión	0.23	0.50	0.23	0.18	0.26	0.41
Bus	0.28	0.56	0.20	0.25	0.42	0.34
Tráiler	0.23	0.89	0.20	0.83	0.20	0.21
Vehículo de construcción	0.04	0.89	0.49	1.26	0.11	0.15
Peatón	0.60	0.28	0.31	0.37	0.25	0.16
Motocicleta	0.27	0.36	0.29	0.79	0.63	0.64
Bicicleta	0.01	0.31	0.32	0.54	0.43	0.68
Cono de tráfico	0.31	0.40	0.39	nan	nan	nan
Barrera	0.39	0.71	0.30	0.08	nan	nan

Tabla 7.8: Análisis por clase de PointPillars en nuScenes.

Modelo	Métrica	Resultado	Velocidad
SECOND Multihead (CBGS)	mAP	0.5066	9.18 Hz
	mATE	0.3126	
	mASE	0.2552	
	mAOE	0.2625	
	mAVE	0.2616	
	mAAE	0.2031	
	NDS	0.6238	
PointPillars Multihead (CBGS)	mAP	0.4474	12.84 Hz
	mATE	0.3379	
	mASE	0.2598	
	mAOE	0.3156	
	mAVE	0.2886	
	mAAE	0.2025	
	NDS	0.5832	
PointPillars	mAP	0.3050	37.29 Hz
	mATE	0.5169	
	mASE	0.2900	
	mAOE	0.4950	
	mAVE	0.3163	
	mAAE	0.3675	
	NDS	0.4539	

Tabla 7.9: Comparativa de los modelos entrenados sobre nuScenes.

El modelo PointPillars es claramente superado en nuScenes por los modelos basados en CBGS, por lo que se ve la mejora en precisión que el nuevo sistema de percepción va a recibir.

7.1.3 Análisis adicionales

Tras el estudio de la precisión y el rendimiento de los modelos, se deciden realizar diferentes estudios de los modelos sobre ambos datasets para: evaluar todos los modelos sobre el mismo dataset, tratar de reducir el tiempo de computo y aumentar la precisión del modelo CBGS.

7.1.3.1 Transferencia de modelos basados en Kitti a nuScenes

La evaluación realizada en KITTI para la detección 3D se aplica únicamente en la parte frontal del vehículo para que las cámaras sean capaces de detectar todos los objetos, por ello los modelos entrenados sobre este dataset han sido entrenados para que su detección se ajuste únicamente a la parte frontal.

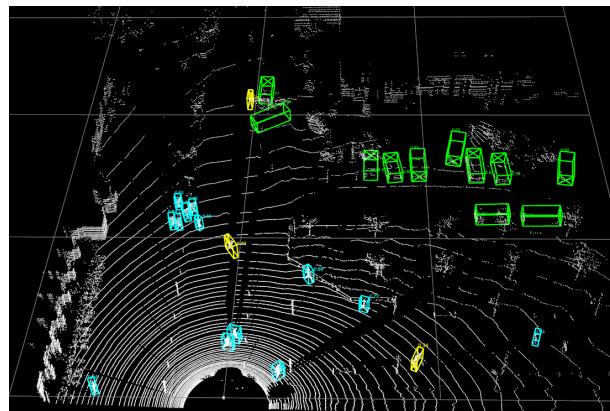


Figura 7.1: Modelo PointPillars sobre KITTI.

Con los modelos basados en Deep Learning se ha modificado el entrada de la red para que permita una detección en 360° sin necesidad de un reentrenamiento, todo ello con una buena precisión. El problema es que para el uso de estos modelos en 360° de la mejor forma, sería necesaria la información de todo el entorno del vehículo para el entrenamiento de los modelos, cosa que no se puede hacer con KITTI.

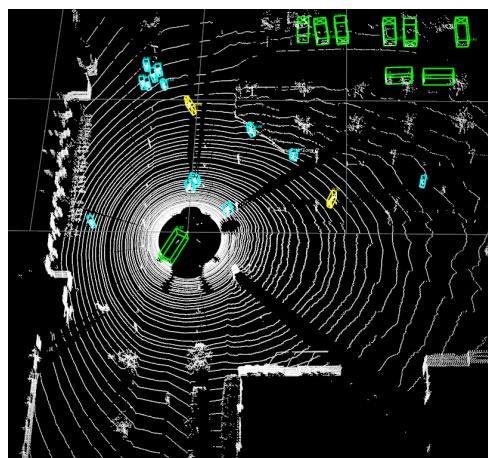


Figura 7.2: Modelo PointPillars sobre KITTI con detección 360°.

La evaluación de todos los modelos sobre el mismo dataset sería lo más conveniente, pero al necesitar un modelo 360° para la implementación en el vehículo T4AC, se necesitaría trabajar sobre nuScenes. Para ello se modifican los datos de entrada junto con el pipeline del modelo para poder correr y entrenar los modelos de KITTI sobre nuScenes.



Figura 7.3: Modelo PointPillars sobre nuScenes con detección 360°.

El problema del entrenamiento sobre nuScenes es la cantidad de clases que tiene y que el modelo debe de ser capaz de detectar. El modelo sin reentrenar no funciona de forma correcta ya que no tiene los mismos niveles de intensidad del LiDAR además de que nuScenes utiliza un LiDAR de 32 haces en vez de 64 como se tiene en KITTI.

Tras el reentrenamiento probando con múltiples configuraciones de parámetros y de capas congeladas, se llega al resultado de que solo se produce un aprendizaje para la clase coche, ya que esta es la más abundante en el dataset, mientras que el resto no terminan de funcionar o funcionan de forma peor, como sería el caso de los peatones que no son detectados al tener la mitad de puntos que el dataset sobre el que fue entrenado, además de ser confundidos con conos de tráfico. Por lo que tanto se concluye que debido a las pobres detecciones obtenidas y el uso de un único barrido del LiDAR, lo que se traduce en una incapacidad para la inferencia de las velocidades de los objetos, los modelos propuestos sobre KITTI en nuScenes no se entrena convenientemente.

7.1.3.2 Número de nubes de puntos de entrada en modelos evaluados sobre nuScenes

En el dataset nuScenes se recomienda el uso de múltiples barridos del LiDAR, para de esta manera obtener una mayor nube de puntos aprovechando su tasa de 20 Hz y para poder detectar las velocidades de los objetos del entorno, en concreto se recomienda un uso de 10 barridos.

Basados en el principio de que a partir de cada uno de los véxeles se extraen las características, se decide estudiar la ganancia en rendimiento de los modelos CBGS al utilizar menos barridos, lo cual a su vez disminuirá la precisión del modelo.




Figura 7.4: Análisis del rendimiento de los modelos basados en CBGS según el número de barridos.

La figura 7.4 muestra el rendimiento sobre todo el dataset de nuScenes, mostrando la mediana, cuartiles y deciles de la velocidad de inferencia de los modelos. Se puede ver de esta manera que a partir del uso único de 3 barridos se consigue una mejora en el rendimiento, mientras que con el aumento hasta 10, la velocidad de inferencia no se mejora. Por otra parte revisando los deciles del rendimiento se observa que únicamente PointPillars Multihead consigue un rendimiento siempre superior a los 10 Hz, requisito indispensable para la implementación el proyecto Techs4AgeCar.

Barridos	mATE	mASE	mAOE	mAVE	mAAE	mAP	NDS
1	0.34	0.26	0.53	1.56	0.33	0.35	0.43
2	0.33	0.26	0.33	0.82	0.22	0.43	0.52
3	0.32	0.26	0.29	0.54	0.21	0.47	0.57
4	0.32	0.26	0.28	0.43	0.21	0.49	0.60
5	0.32	0.26	0.27	0.36	0.20	0.50	0.61
6	0.31	0.26	0.26	0.33	0.20	0.50	0.62
7	0.31	0.26	0.26	0.30	0.21	0.51	0.62
8	0.31	0.25	0.26	0.28	0.21	0.51	0.62
9	0.31	0.25	0.27	0.27	0.24	0.51	0.62
10	0.31	0.26	0.26	0.26	0.20	0.51	0.62

Tabla 7.10: Análisis de la precisión de SECOND Multihead según el número de barridos.

Barridos	mATE	mASE	mAOE	mAVE	mAAE	mAP	NDS
1	0.35	0.27	0.63	1.74	0.33	0.31	0.39
2	0.36	0.26	0.42	0.89	0.23	0.36	0.47
3	0.35	0.26	0.37	0.61	0.21	0.39	0.52
4	0.35	0.26	0.34	0.47	0.21	0.41	0.54
5	0.34	0.26	0.34	0.39	0.20	0.42	0.56
6	0.34	0.26	0.33	0.36	0.20	0.43	0.57

Continua en la próxima página

Tabla 7.11 – Continua en la página anterior

Barridos	mATE	mASE	mAOE	mAVE	mAAE	mAP	NDS
7	0.34	0.26	0.33	0.33	0.20	0.44	0.57
8	0.34	0.26	0.33	0.31	0.20	0.44	0.58
9	0.34	0.26	0.32	0.30	0.20	0.45	0.58
10	0.34	0.26	0.32	0.29	0.20	0.45	0.58

Tabla 7.11: Análisis de la precisión de PointPillars Multihead según el número de barridos.

El uso de 2 barridos con SECOND Multihead no supera en precisión a PointPillars Multihead con los 10 barridos por lo que este modelo sería descartado. Por otra parte en el caso de PointPillars Multihead sería recomendable el uso de 8 barridos en vez de 10 ya que la precisión no se ve apenas reducida, mientras que el rendimiento consigue una mejora de poco más del 4%, que aunque sea poco puede definir en un caso extremo si una nube de puntos es analizada o no por la velocidad de inferencia del modelo.

7.1.3.3 Tamaño del voxel en modelos basados en redes neuronales

Basándose en múltiples papers que utilizan la reducción del tamaño del voxel para el aumento de la precisión a costa del rendimiento, como ocurre con el modelo PointPillars+ [60] junto con otras técnicas, se decide entrenar el modelo PointPillars Multihead ya que es el utilizado actualmente en el proyecto Techs4AgeCar y permite usar un tamaño de voxel menor. De esta forma se espera que mejore la precisión del modelo, a la vez que se reduce la distancia de detección, la cual puede empeorar ya que se trabaja con un LiDAR en el vehículo T4AC de 16 haces.

Modelo	Tamaño de voxel	Tamaño de la nube de puntos	NDS
Modelo base	[0.2, 0.2, 8.0]	[102.4, 102.4, 8.0]	0.5832
Modelo base	[0.2, 0.1, 8.0]	[102.4, 51.2, 8.0]	0.2391
Modelo base + 5 epochs	[0.2, 0.1, 8.0]	[102.4, 51.2, 8.0]	0.3550

Tabla 7.12: Análisis de la precisión de PointPillars Multihead según el tamaño del voxel.

Al utilizar el modelo base de PointPillars Multihead reduciendo el tamaño de voxel para que se centre el análisis de la escena principalmente en la parte frontal y trasera del vehículo, se obtiene una precisión mucho menor, la cual no es utilizable de la misma manera que disminuyendo el número de barridos. Se ha reentrenado la red con 5 iteraciones para mejorar la precisión, tras esto se observa una mejora sustancial en la precisión de las detecciones del modelo. Como se ha visto, el problema puede encontrarse en el ajuste de los tamaños de los objetos a detectar en función del tamaño de los voxels del modelo base. La solución sería el entrenamiento de la red de nuevo para solucionar este problema, pero para cada iteración en el entrenamiento de esta red en nuScenes han sido necesarias entre 10 y 12 horas, por lo que resulta inviable con el hardware que se dispone.

7.2 Análisis sobre el simulador CARLA

El análisis de los modelos en los datasets sobre los que han sido entrenados solo muestra la precisión dentro de estos. Con datos provenientes de otras fuentes como sería el simulador CARLA, se analiza cómo de buenos son estos modelos en otros entornos para su posterior implementación en el vehículo T4AC el cual incorpora un [LiDAR](#) diferente al utilizado en los datasets. En los resultados obtenidos se ha simulado un vehículo con un [LiDAR](#) de 32 haces con una velocidad de barrido de 20 Hz.

Parámetro	Valor
Posición	[0, 0, 1.95] m
Distancia	50 m
Haces	32
Puntos por segundo	320000
Campo de visión	2°/-26.8°

Tabla 7.13: Parámetros del LiDAR en CARLA.

7.2.1 Análisis cualitativo del modelo clásico en CARLA

El estudio realizado en el capítulo 3 desemboca en la implementación en un sistema basado en técnicas clásicas que fue presentado en el capítulo 5.2.2. Dicho sistema ha sido construido como un nodo de [ROS](#) en C++ que tiene de entrada la nube de puntos del simulador y publica las detecciones. Este sistema ha sido probado en múltiples escenarios para su análisis cualitativo.




Figura 7.5: Modelo clásico en CARLA.

La velocidad de inferencia de este sistema es de 13.14 milisegundos de media, teniendo como funciones más demandantes: la aplicación del algoritmo [RANSAC](#) 3D con 9.57 milisegundos y la función de clustering basada en KD-tree con 2.14 milisegundos, esto resulta en un sistema con una capacidad de inferencia de 76 Hz.

El funcionamiento de este algoritmo como se ve en la figura 7.5 es bastante bueno, con pocos falsos positivos. El mayor problema que tiene dicho algoritmo es la incapacidad de detectar otro tipo de objeto que no sean coches, ya que si tienen que ser detectados los peatones, aparecerían problemas de muchos falsos positivos con farolas, semáforos, etc. La diferenciación de cada objeto en función de su clase no es

posible en este método ya que aunque se analizase el tamaño de los objetos se encontrarían muchos fallos en función del número de puntos incidentes sobre cada objeto, ya que farolas, arbustos, conos, semáforos y peatones serían incluidos en el mismo grupo.

7.2.2 Análisis cualitativo de Pointpillars Multihead en CARLA

El modelo finalmente implementado en el proyecto ha sido PointPillars Multihead, este modelo es probado en simulación antes de su prueba en el vehículo T4AC. Uno de los problemas principales que se encuentran con el uso en simulación es la intensidad simulada del LiDAR, como se explica en el capítulo 5.2.1, esto provoca que se use una intensidad fija de 0 en todos los puntos.

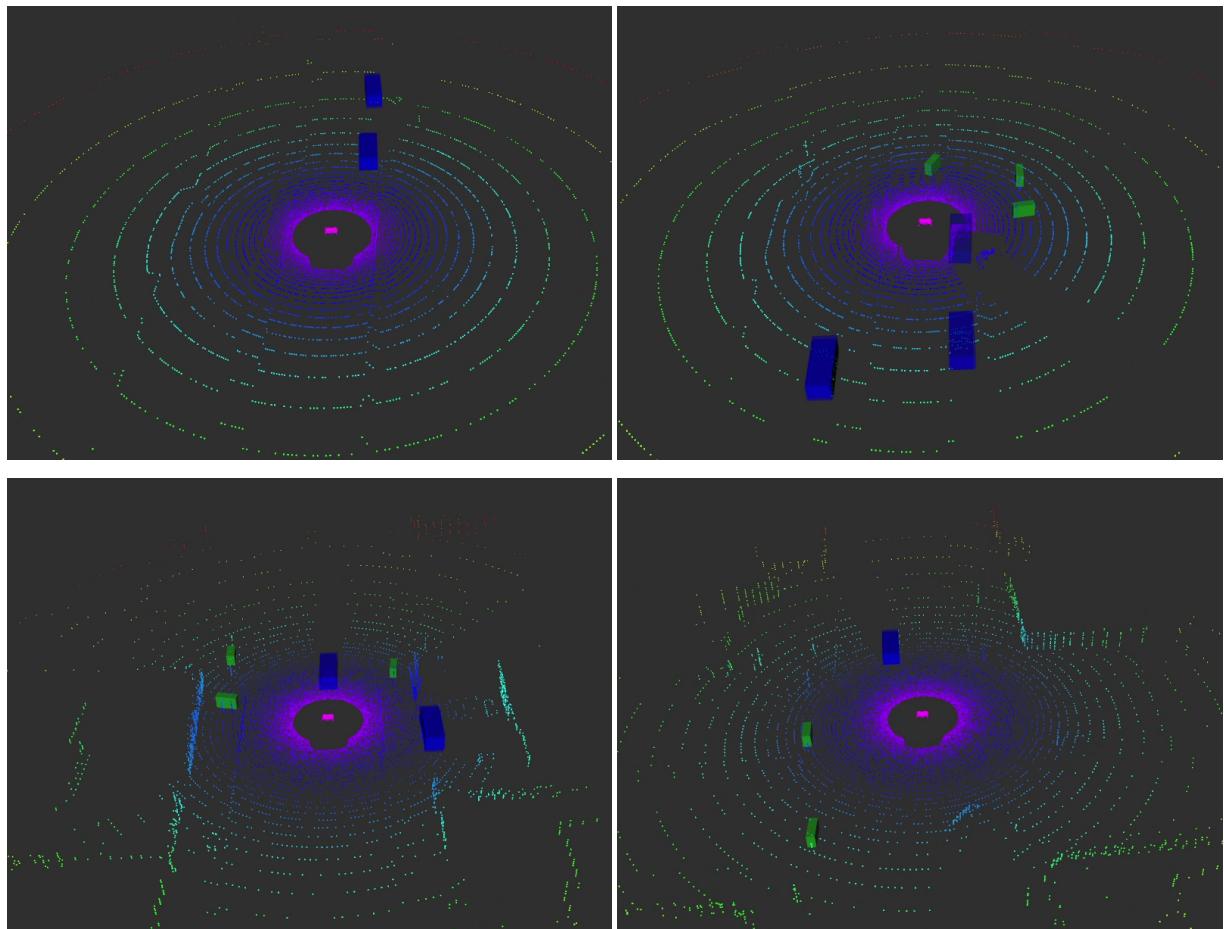


Figura 7.6: PointPillars Multihead en CARLA.

Las pruebas se han desarrollado sobre un mapa creado dentro del grupo RobeSafe que simula la Universidad de Alcalá, en el que se ha colaborado, y en un mapa proporcionado por CARLA. Este modelo ya no solo ajusta mejor las bounding boxes de los coches sino que detecta a los peatones del escenario respecto del modelo clásico.

Aún obteniendo estos resultados tan buenos hay que tener en cuenta que la intensidad no se utiliza, por lo que la asociación de objetos entre barridos es más difícil. Durante la implementación de dicho modelo se ha detectado un fallo en CARLA en el que el frame del LiDAR se encuentra vibrando, lo cual es el culpable de la mala inferencia de velocidad obtenida, por lo que ha sido reportado dicho error. Se observa además que debido a este problema del simulador, se obtiene una precisión mucho mejor con el vehículo parado o a velocidades bajas.

7.2.2.1 Comparativa con PointPillars en CARLA

Para ver la mejora en precisión de la implementación del modelo PointPillars Multihead sobre la arquitectura del proyecto Techs4AgeCar respecto de la anterior implementación de PointPillars se realiza el siguiente análisis cualitativo sobre CARLA, en el que se muestran las mismas escenas que las vistas en la figura 7.6

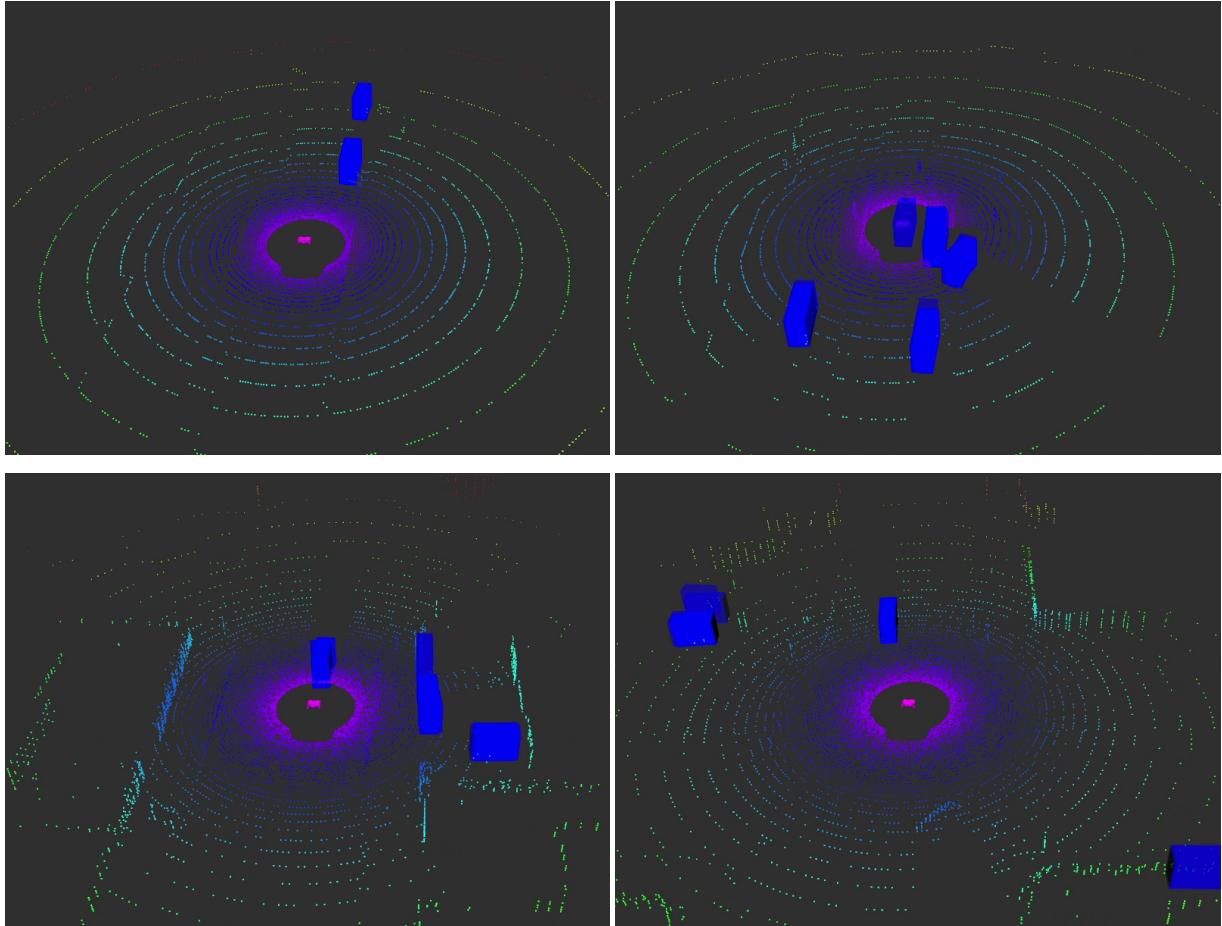


Figura 7.7: PointPillars en CARLA.

La implementación actual no solo mejora como se ve claramente en la precisión de las detecciones de los coches al producir menos falsos positivos, sino que ahora también se detectar peatones, cosa que en la anterior implementación esto no era posible.

7.2.3 Análisis cuantitativo de Pointpillars Multihead en CARLA

Haciendo uso del [AD DevKit](#) desarrollado en este TFG, se evalúa el modelo PointPillars Multihead. Este kit de evaluación es capaz de evaluar las clases definidas en [ROS](#) por CARLA, como son: peatón, bicicleta, coche, camión, barrera, señal u otro vehículo, dichas clases no coinciden directamente con las detectadas por el modelo por lo que se pueden reducir las clases detectadas. El mayor problema surge cuando se ve que CARLA identifica todos los vehículos que no son peatones como coches y además se ha observado que al grabar un rosbag con toda la información del entorno sobre la que evaluar, [ROS](#) no es capaz de guardar toda esta información en tiempo real, lo cual produce que las marcas de tiempo se encuentren parcialmente desplazadas. Esto impide la asociación con los peatones al tener un [IoU](#) muy pequeño o nulo por la diferencia entre los tiempos de la información de los sensores y de los objetos del entorno.

El [AD DevKit](#) para la generación de los datos de evaluación utiliza un rosbag que contiene la información de los sensores y del entorno necesaria, con esto se obtiene el groundtruth con el que se evalúa el modelo. Para ello se han utilizado dos rosbag creados en el grupo RobeSafe que son usados para la evaluación cualitativa y ambos rosbag son de 30 segundos aproximadamente. Al utilizar grabaciones de tan corta duración se obtiene métricas diferentes pero que no se ven afectados apena del problema de [ROS](#) con los retrasos en las marcas de tiempo.

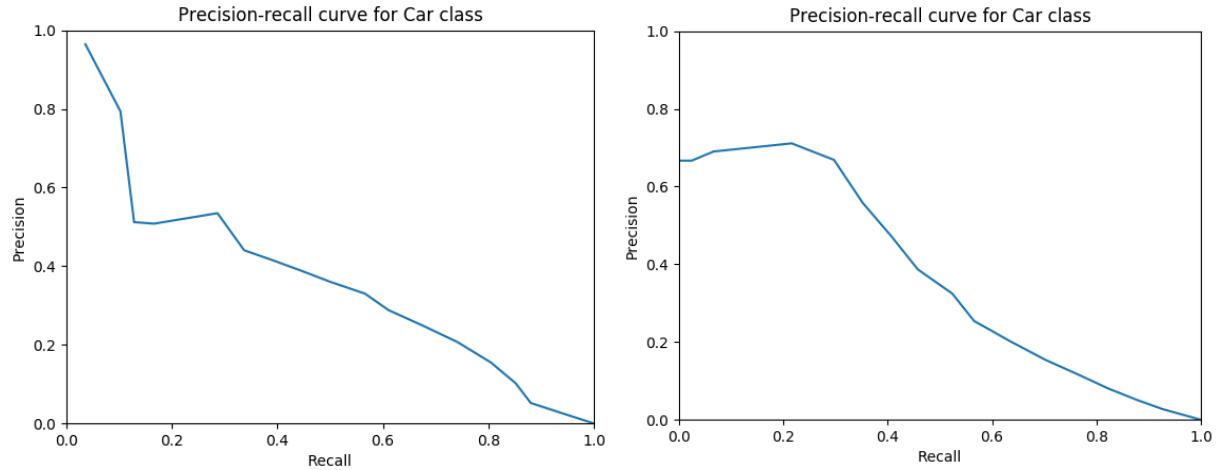


Figura 7.8: Curvas de precision-recall para la clase coche de PointPillars Multihead en CARLA.

AP	mIoU	mAVE
0.34	0.49	1.49

AP	mIoU	mAVE
0.37	0.48	0.79

Tabla 7.14: Métricas para la clase coche de PointPillars Multihead en CARLA.

Con estas métricas se obtiene una precisión aproximada de la clase coche, la cual es el principal objeto a detectar que se va a utilizar en el sistema que usa el modelo PointPillars Multihead. Este es por tanto el rendimiento actual del [AD DevKit](#) para la evaluación de objetos 3D debido a las limitaciones con [ROS](#) y CARLA.

7.3 Análisis sobre el vehículo T4AC

Tras una evaluación en CARLA de la implementación realizada, se evalúa en el vehículo T4AC la precisión del modelo implementado para realizar la detección 3D con [LiDAR](#). Teniendo en cuenta que el modelo se ejecuta en el portátil de a bordo del vehículo, se espera un rendimiento muy similar al obtenido previamente.

El análisis por tanto se produce en el campus de la Universidad de Alcalá donde diversos coches aparecen en ambos sentidos, se producen adelantamientos y aparecen gran cantidad de árboles lo cual puede producir múltiples falsos positivos.

7.3.1 Análisis cualitativo de Pointpillars Multihead sobre el vehículo T4AC

Al no poder evaluar de forma cuantitativa la precisión, se analizan de forma cualitativa los resultados obtenidos de la prueba con la nueva implementación en el vehículo T4AC.

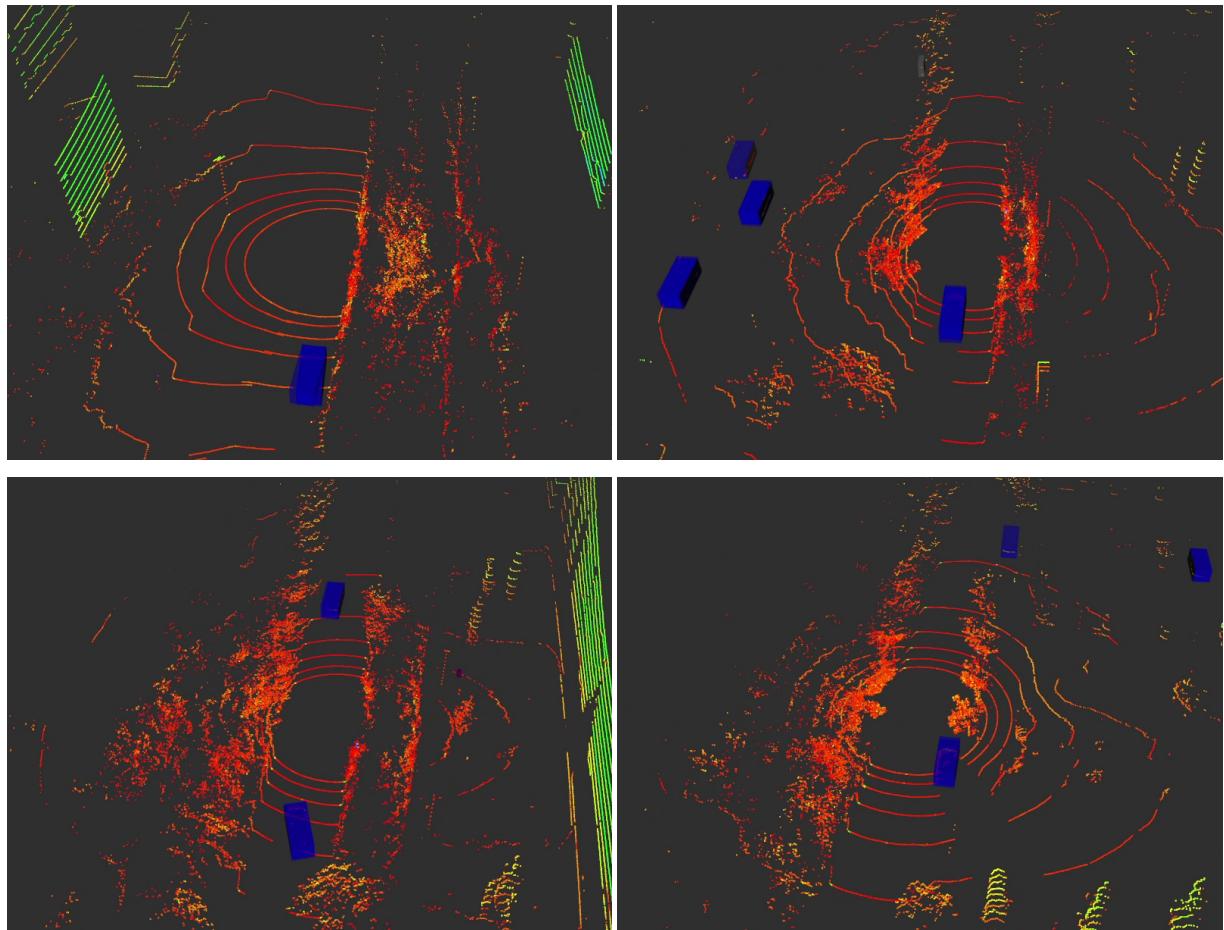


Figura 7.9: PointPillars Multihead en el vehículo T4AC.

Tras el ajuste para la detección de únicamente ciertas clases, se puede observar una precisión muy buena donde todos los coches cercanos al propio vehículo son detectados, incluso en situaciones donde hay coches con muy pocos puntos al ser ocultos por múltiples árboles, el sistema es capaz de detectarlos. Aún trabajando en un sistema real donde hay muchos puntos de colisión con árboles, con los ajustes realizados no se obtienen apenas falsos positivos lo cual es un gran beneficio para su uso en otras capas del proyecto Techs4AgeCar, aunque la detección de objetos pequeños como conos o peatones sigue produciendo falsos positivos debido a que se tiene la mitad de puntos en la nube respecto de las nubes de puntos utilizadas en el entrenamiento del modelo.

7.3.1.1 Comparativa con PointPillars sobre el vehículo T4AC

El mismo recorrido con el sistema que integra el modelo PointPillars Multihead ha sido integrado en el anterior sistema del proyecto que incorpora el modelo Pointpillars, de esta manera se pueden observar las mejoras que el nuevo sistema implementado en este TFG ha aportado al proyecto del grupo RobeSafe. Para ello se muestran en la figura 7.10 los mismos instantes de tiempo que en la figura 7.9 para de esta manera resaltar la mejora en la precisión del nuevo sistema de detección.




Figura 7.10: PointPillars en el vehículo T4AC.

La ventaja que se tenía antes con este modelo es la ejecución sobre la NVIDIA Jetson AGX Xavier incorporada en el vehículo T4AC, lo cual aligeraba la carga de trabajo del portátil que se lleva a bordo. Pero de la misma manera que se veía en el simulador CARLA, con el sistema previo al implementado en este Trabajo Fin de Grado se obtenían multitud de falsos positivos, además de que no es capaz de detectar tantos vehículos en situaciones complejas como aquellos ocluidos parcialmente por árboles. Por lo que el trabajo de detección 3D con [LiDAR](#) de este TFG ha servido para mejorar el sistema de percepción del vehículo como ha quedado validado en múltiples escenarios.

7.3.2 Análisis cualitativo del sistema de fusión sensorial sobre el vehículo T4AC

Los sistemas de detección basados en [LiDAR](#) tienen el inconveniente de la cantidad de falsos positivos que producen al no tener la información suficiente para hallar los objetos del entorno de una forma sencilla, mientras que gracias a este sensor se consigue un ajuste muy bueno de las bounding boxes entorno a los objetos. Por otra parte los sistemas de detección basados en cámara monocular ofrecen un muy buen reconocimiento de los objetos en un entorno 2D, mientras que no son capaces de obtener detecciones 3D muy precisas.

Basado en estas características, se consiguen utilizar las detecciones 3D aproximadas provenientes del sistema basado en cámara, mientras que se aprovecha del sistema basado en [LiDAR](#) para su ajuste.

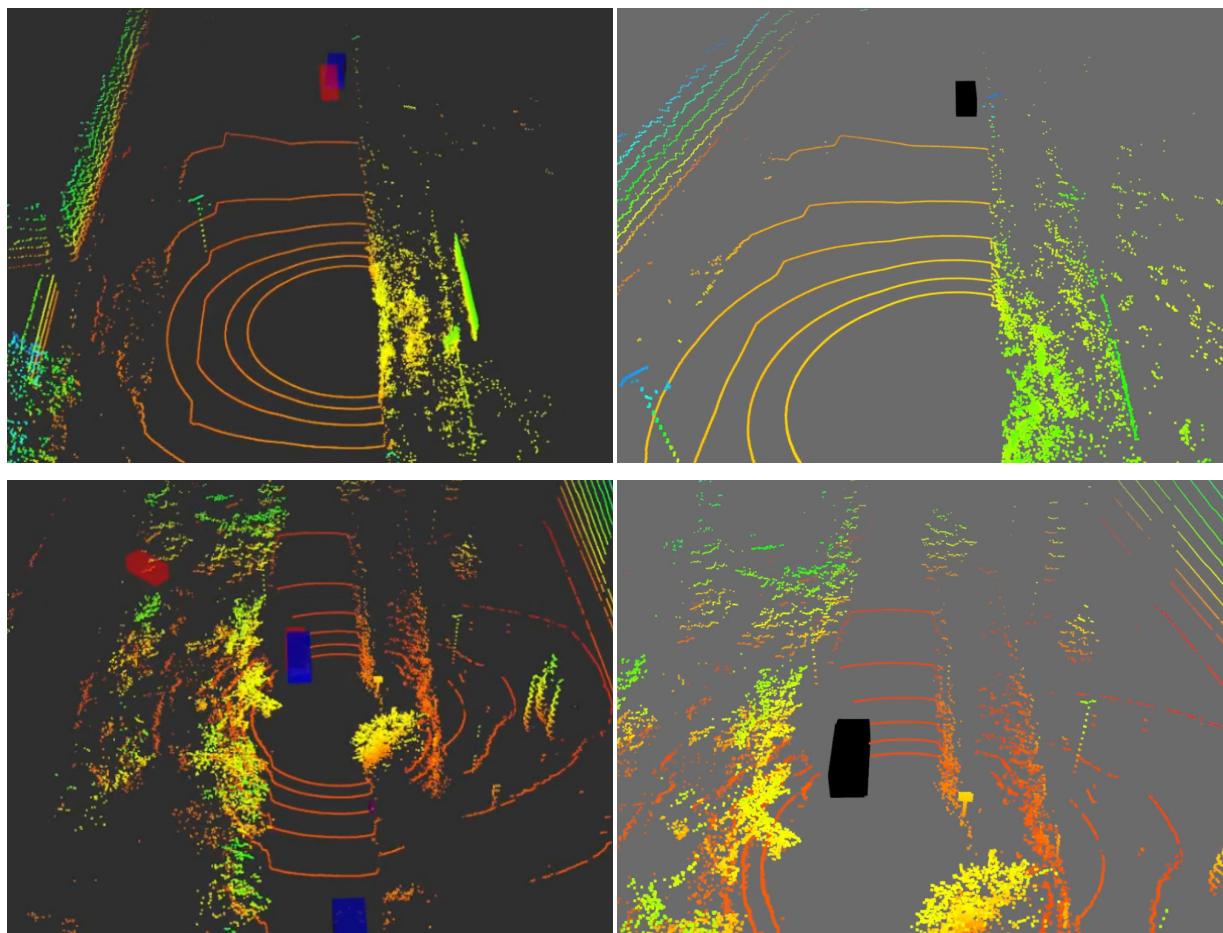


Figura 7.11: Fusión sensorial en el vehículo T4AC.

En la figura 7.11 se muestran las detecciones producidas por el sistema de fusión sensorial, donde en las imágenes de la izquierda se muestran las detecciones de los sistemas de cámara y [LiDAR](#), siendo las detecciones rojas aquellas producidas por la cámara y las detecciones azules las generadas por el sistema basado en [LiDAR](#). Por otra parte a la derecha se muestra el resultado de la fusión sensorial como detecciones de color negro.

Se puede observar como las detecciones de la cámara solo se encuentran en la parte frontal y las producidas por el [LiDAR](#) alrededor del vehículo, esto consigue un sistema donde se mejoran las detecciones frontales, ya que es necesario una detección en ambos sistemas sobre un objeto para darse como correcta dicha detección.

En cuanto a la velocidad de inferencia para el modelo CBGS, ésta es de 8.68 Hz en el portátil de abordo del vehículo T4AC, que consta de una tarjeta gráfica GTX 1070 Mobile. Dicho sistema sustituye al basado en PointPillars ejecutado sobre una NVIDIA Jetson AGX Xavier, que obtiene una velocidad de 7.3 Hz.

Capítulo 8

Conclusiones y trabajos futuros

La verdadera felicidad radica en la finalización del trabajo utilizando tu propio cerebro y habilidades.

Soichiro Honda

Como finalización del Trabajo Fin de Grado se va a recapitular el trabajo realizado para ofrecer así unas conclusiones y mostrar el trabajo futuro que se va a realizar como continuación al estudio, implementación y desarrollo de todo lo descrito en este TFG.

8.1 Conclusiones

El objetivo principal de este Trabajo Fin de Grado, ha sido el estudio de técnicas clásicas y basadas en Deep Learning de detección con [LiDAR](#). Tras esto se implementa el mejor sistema encontrado, el modelo CBGS, para que en el proyecto Techs4AgeCar del grupo RobeSafe se mejore el sistema de detección con [LiDAR](#) para el vehículo real T4AC.

Antes de abordar el estudio y el desarrollo de las técnicas, ha sido necesario aprender a utilizar herramientas como [ROS](#), Docker y CARLA que son utilizadas en el proyecto, para así poder comprender el funcionamiento del sistema de conducción completo actual y ayudar a mejorarlo.

Se han estudiado múltiples técnicas como la voxelización, [RANSAC](#) 3D o KD-tree para la aplicación en modelos clásicos. Con todo esto se ha construido un modelo de detección 3D basado en [LiDAR](#) a partir de únicamente técnicas clásicas, programado en C++ como un nodo de ROS para así poder utilizar dicho modelo en CARLA.

Tras esto se han analizado diferentes datasets como Kitti, nuScenes y Waymo, además de los modelos [SOTA](#) que más adelante han sido evaluados. Con dicho estudio se ha implementado en el proyecto Techs4AgeCar un sistema de detección 3D con [LiDAR](#) basado en el modelo CBGS con un backbone cambiado al de PointPillars.

Con esto se habría terminado la base del TFG, tal y como se definió en el anteproyecto, pero no se ha dejado aquí, en conjunto con Carlos Gómez Huélamo y Miguel Antunes García se ha diseñado un sistema de fusión sensorial que mejora las detecciones 3D haciendo uso de las detección provenientes de la cámara y el [LiDAR](#). Y eso no ha sido todo, ya que al finalizar esta fase se ha desarrollado una versión preliminar de lo que será la capa de percepción del [AD DevKit](#) para permitir la evaluación de arquitecturas de navegación en CARLA de una forma holística.

Este trabajo ha conseguido alcanzar todos los objetivos propuestos en términos teóricos y prácticos, y se ha llevado más lejos realizando un sistema de fusión sensorial y construyendo un kit de evaluación sobre CARLA, para de esta manera obtener todo el conocimiento posible a través de la elaboración de este Trabajo Fin de Grado, pensando en todo momento en aportar un valor con el trabajo realizado al grupo de investigación RobeSafe.

8.2 Trabajos futuros

Con el conocimiento obtenido tras este TFG junto con el estudio en los años previos en temas de inteligencia artificial y de fusión sensorial, se pretende continuar trabajando con sistemas de percepción pero no solo limitados al [LiDAR](#), sino que se pretende realizar un estudio e implementación de métodos de fusión sensorial entre cámara y [LiDAR](#), fijándose principalmente en aquellos métodos de middle-fusion.

De forma paralela a este trabajo se continuará trabajando con el [AD DevKit](#) para solucionar los problemas actuales con [ROS](#) y CARLA, además de la inclusión de nuevas métricas y la evaluación completa de forma online, todo ello para continuar contribuyendo a este proyecto.

Pero sobre todo se espera seguir formándose entorno a tecnologías [LiDAR](#) para llegar a ser una persona a la que consultar dudas en lo que respecta a este sensor en el grupo RobeSafe, para que de esta manera pueda aplicar todo el conocimiento obtenido y poder aportar ideas de uso y mejorar los sistemas basados en este tipo de tecnologías.

Bibliografía

- [1] L. Liu, S. Lu, R. Zhong, B. Wu, Y. Yao, Q. Zhang, and W. Shi, “Computing systems for autonomous driving: State of the art and challenges,” *IEEE Internet of Things Journal*, vol. 8, no. 8, pp. 6469–6486, 2021.
- [2] “Automated vehicles for safety,” Tech. Rep., 2018. [Online]. Available: <https://www.nhtsa.gov/technology-innovation/automated-vehicles-safety>
- [3] “How self-driving cars work: Sensor systems,” Tech. Rep., 2021. [Online]. Available: <https://www.udacity.com/blog/2021/03/how-self-driving-cars-work-sensor-systems.html>
- [4] Y. Zhang, J. Ran, X. Chen, K. Fang, and H. Chen, “Observation of the inverse, zero and normal doppler effect in configurable transmission lines,” in *2015 IEEE 4th Asia-Pacific Conference on Antennas and Propagation (APCAP)*, 2015, pp. 229–230.
- [5] “Hdl-64e, high definition real-time 3d lidar,” Velodyne Lidar. [Online]. Available: <https://velodynelidar.com/products/hdl-64e/>
- [6] A. M. Wallace, A. Halimi, and G. S. Buller, “Full waveform lidar for adverse weather conditions,” *IEEE Transactions on Vehicular Technology*, vol. 69, no. 7, pp. 7064–7077, 2020.
- [7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [8] A. H. Lang, S. Vora, H. Caesar, L. Zhou, J. Yang, and O. Beijbom, “Pointpillars: Fast encoders for object detection from point clouds,” in *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 12689–12697.
- [9] F. Lotfi, V. Ajallooeian, and H. D. Taghirad, “Robust object tracking based on recurrent neural networks,” in *2018 6th RSI International Conference on Robotics and Mechatronics (IcRoM)*, 2018, pp. 507–511.
- [10] S. Wang, Y. Sun, C. Liu, and M. Liu, “Pointtracknet: An end-to-end network for 3-d object detection and tracking from point clouds,” *IEEE Robotics and Automation Letters*, vol. 5, no. 2, pp. 3206–3212, 2020.
- [11] B. Zhu, Z. Jiang, X. Zhou, Z. Li, and G. Yu, “Class-balanced grouping and sampling for point cloud 3d object detection,” *CoRR*, vol. abs/1908.09492, 2019. [Online]. Available: <http://arxiv.org/abs/1908.09492>

- [12] T.-L. Kim, J.-S. Lee, and T.-H. Park, “Fusing lidar, radar, and camera using extended kalman filter for estimating the forward position of vehicles,” in *2019 IEEE International Conference on Cybernetics and Intelligent Systems (CIS) and IEEE Conference on Robotics, Automation and Mechatronics (RAM)*, 2019, pp. 374–379.
- [13] J. del Egido Sierra, “Detección del entorno 360° de un vehículo autónomo mediante lidar aplicando técnicas deep learning,” Trabajo de Fin de Master, UAH Politécnica, 2020.
- [14] M. Antunes, “Sistema de visión estereo aplicado a la detección y seguimiento de objetos en conducción autónoma,” Trabajo de Fin de Grado, UAH Politécnica, 2021.
- [15] M. A. Fischler and R. C. Bolles, “Random sample consensus: A paradigm for model fitting with applications to image analysis and automated cartography,” *Commun. ACM*, vol. 24, no. 6, pp. 381–395, Jun. 1981. [Online]. Available: <https://doi.org/10.1145/358669.358692>
- [16] J. L. Bentley, “Multidimensional binary search trees used for associative searching,” *Commun. ACM*, vol. 18, no. 9, pp. 509–517, Sep. 1975. [Online]. Available: <https://doi.org/10.1145/361002.361007>
- [17] W. Hou, D. Li, C. Xu, H. Zhang, and T. Li, “An advanced k nearest neighbor classification algorithm based on kd-tree,” in *2018 IEEE International Conference of Safety Produce Informatization (IICSPI)*, 2018, pp. 902–905.
- [18] Y. Cao, X. Zhang, B. Duan, W. Zhao, and H. Wang, “An improved method to build the kd tree based on presorted results,” in *2020 IEEE 11th International Conference on Software Engineering and Service Science (ICSESS)*, 2020, pp. 71–75.
- [19] L. Hu, S. Nooshabadi, and M. Ahmadi, “Massively parallel kd-tree construction and nearest neighbor search algorithms,” in *2015 IEEE International Symposium on Circuits and Systems (ISCAS)*, 2015, pp. 2752–2755.
- [20] J. Geyer, Y. Kassahun, M. Mahmudi, X. Ricou, R. Durgesh, A. S. Chung, L. Hauswald, V. H. Pham, M. Mühllegg, S. Dorn, T. Fernandez, M. Jänicke, S. Mirashi, C. Savani, M. Sturm, O. Vorobiov, M. Oelker, S. Garreis, and P. Schuberth, “A2d2: Audi autonomous driving dataset,” 2020.
- [21] M.-F. Chang, J. Lambert, P. Sangkloy, J. Singh, S. Bak, A. Hartnett, D. Wang, P. Carr, S. Lucey, D. Ramanan, and J. Hays, “Argoverse: 3d tracking and forecasting with rich maps,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.
- [22] M. Cordts, M. Omran, S. Ramos, T. Rehfeld, M. Enzweiler, R. Benenson, U. Franke, S. Roth, and B. Schiele, “The cityscapes dataset for semantic urban scene understanding,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2016.
- [23] A. Geiger, P. Lenz, and R. Urtasun, “Are we ready for autonomous driving? the kitti vision benchmark suite,” in *2012 IEEE Conference on Computer Vision and Pattern Recognition*, 2012, pp. 3354–3361.
- [24] J. Houston, G. Zuidhof, L. Bergamini, Y. Ye, L. Chen, A. Jain, S. Omari, V. Iglovikov, and P. Ondruska, “One thousand and one hours: Self-driving motion prediction dataset,” 2020.
- [25] H. Caesar, V. Bankiti, A. H. Lang, S. Vora, V. E. Liong, Q. Xu, A. Krishnan, Y. Pan, G. Baldan, and O. Beijbom, “nuscenes: A multimodal dataset for autonomous driving,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.

- [26] P. Sun, H. Kretzschmar, X. Dotiwalla, A. Chouard, V. Patnaik, P. Tsui, J. Guo, Y. Zhou, Y. Chai, B. Caine, V. Vasudevan, W. Han, J. Ngiam, H. Zhao, A. Timofeev, S. Ettinger, M. Krivokon, A. Gao, A. Joshi, Y. Zhang, J. Shlens, Z. Chen, and D. Anguelov, “Scalability in perception for autonomous driving: Waymo open dataset,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- [27] J. Xie, M. Kiefel, M.-T. Sun, and A. Geiger, “Semantic instance annotation of street scenes by 3d to 2d label transfer,” in *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [28] “Waymo open dataset,” Waymo. [Online]. Available: <https://waymo.com/open>
- [29] S. Laboratory, “pykitti.” [Online]. Available: <https://github.com/utiasSTARS/pykitti>
- [30] Y. Yan, Y. Mao, and B. Li, “Second: Sparsely embedded convolutional detection,” *Sensors*, vol. 18, no. 10, 2018. [Online]. Available: <https://www.mdpi.com/1424-8220/18/10/3337>
- [31] Y. Zhou and O. Tuzel, “Voxelnet: End-to-end learning for point cloud based 3d object detection,” in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018, pp. 4490–4499.
- [32] “Sparseconvnet,” Facebook. [Online]. Available: <https://github.com/facebookresearch/SparseConvNet>
- [33] R. Girshick, “Fast r-cnn,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, December 2015.
- [34] S. Shi, X. Wang, and H. Li, “Pointrcnn: 3d object proposal generation and detection from point cloud,” in *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 770–779.
- [35] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, “Pointnet++: Deep hierarchical feature learning on point sets in a metric space,” 2017.
- [36] Z. Liang, M. Zhang, Z. Zhang, X. Zhao, and S. Pu, “Rangercnn: Towards fast and accurate 3d object detection with range image representation,” 2021.
- [37] S. Shi, C. Guo, L. Jiang, Z. Wang, J. Shi, X. Wang, and H. Li, “Pv-rcnn: Point-voxel feature set abstraction for 3d object detection,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020, pp. 10526–10535.
- [38] R. Q. Charles, H. Su, M. Kaichun, and L. J. Guibas, “Pointnet: Deep learning on point sets for 3d classification and segmentation,” in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 77–85.
- [39] O. D. Team, “Openpcdet: An open-source toolbox for 3d object detection from point clouds,” <https://github.com/open-mmlab/OpenPCDet>, 2020.
- [40] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, “Pytorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems 32*, H. Wallach, H. Larochelle, A. Beygelzimer, E. Fox, and R. Garnett, Eds. Curran Associates, Inc., 2019, pp. 8024–8035. [Online]. Available: <http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf>

- [41] S. Shi, Z. Wang, J. Shi, X. Wang, and H. Li, “From points to parts: 3d object detection from point cloud with part-aware and part-aggregation network,” 2020.
- [42] J. Deng, S. Shi, P. Li, W. Zhou, Y. Zhang, and H. Li, “Voxel r-cnn: Towards high performance voxel-based 3d object detection,” 2021.
- [43] C. Reading, A. Harakeh, J. Chae, and S. L. Waslander, “Categorical depth distribution network for monocular 3d object detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2021, pp. 8555–8564.
- [44] Stanford Artificial Intelligence Laboratory et al., “Robotic operating system.” [Online]. Available: <https://www.ros.org>
- [45] R. Community, “Ros introduction,” 2020. [Online]. Available: <http://wiki.ros.org/ROS/Introduction>
- [46] D. Merkel, “Docker: lightweight linux containers for consistent development and deployment,” *Linux journal*, vol. 2014, no. 239, p. 2, 2014.
- [47] W. Community, “Docker (software),” 2021. [Online]. Available: [https://es.wikipedia.org/wiki/Docker_\(software\)](https://es.wikipedia.org/wiki/Docker_(software))
- [48] D. Team, “Docker overview.” [Online]. Available: <https://docs.docker.com/get-started/overview/>
- [49] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, “CARLA: An open urban driving simulator,” in *Proceedings of the 1st Annual Conference on Robot Learning*, 2017, pp. 1–16.
- [50] Epic Games, “Unreal engine.” [Online]. Available: <https://www.unrealengine.com>
- [51] A. for Standarization of Automation and M. Systems, “Asam opendrive®.” [Online]. Available: <https://www.asam.net/standards/detail/opendrive/>
- [52] C. team, “Carla introduction.” [Online]. Available: https://carla.readthedocs.io/en/0.9.12/start_introduction/
- [53] C. Gómez-Huélamo, J. Del Egido, L. M. Bergasa, R. Barea, M. Ocaña, F. Arango, and R. Gutiérrez-Moreno, “Real-time bird? s eye view multi-object tracking system based on fast encoders for object detection,” in *2020 IEEE 23rd International Conference on Intelligent Transportation Systems (ITSC)*, 2020, pp. 1–6.
- [54] Ultralytics, “yolov5.” [Online]. Available: <https://github.com/ultralytics/yolov5>
- [55] A. Mousavian, D. Anguelov, J. Flynn, and J. Kosecka, “3d bounding box estimation using deep learning and geometry,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, July 2017.
- [56] J. F. A. Vargas, “Diseño de un sistema drive-by-wire para un vehiculo autónomo,” Trabajo de Fin de Master, UAH Politécnica, 2020.
- [57] D. Gehrig, M. Rüegg, M. Gehrig, J. Hidalgo-Carrió, and D. Scaramuzza, “Combining events and frames using recurrent asynchronous multimodal networks for monocular depth prediction,” *IEEE Robotics and Automation Letters*, vol. 6, no. 2, pp. 2822–2829, 2021.
- [58] J.-E. Deschaud, “Kitti-carla: a kitti-like dataset generated by carla simulator,” 2021.
- [59] J. del Egido Sierra, “A baseline for carla online ground-truth generation.” [Online]. Available: <https://github.com/JavierEgido/AB4COGT>

- [60] S. Vora, A. H. Lang, B. Helou, and O. Beijbom, “Pointpainting: Sequential fusion for 3d object detection,” 2020.

Apéndice A

Manual de usuario

Se presenta el manual de usuario de las implementaciones realizadas en este Trabajo Fin de Grado para su posterior replicación, fijando el uso principal sobre el proyecto Techs4AgeCar en el contenedor Docker que contiene toda la arquitectura del vehículo.

A.1 Sistema de detecciones basado en técnicas clásicas

El sistema de detección mediante el uso de técnicas clásicas presentado en el capítulo 5.2.2 se crea para su uso dentro del contenedor Docker del proyecto. Por ello se crea como un nodo para ROS vía rosbuild que utiliza las nubes de puntos proveídas por CARLA.

```
cd ~/t4ac_ws/src/t4ac_architecture/t4ac_perception_layer/detection/lidar/
git clone https://github.com/Javier-DlaP/3D_lidar_based_clustering.git

cd 3D_lidar_based_clustering/
cmake .
make

rosrun 3D_lidar_based_clustering subscriber
```

Al ejecutar dichos comandos dentro del contenedor Docker, este sistema publica bounding boxes 3D que pueden ser visualizadas en rviz tal y como se ve en la figura 7.5.

A.2 Muestra de nubes de puntos en KITTI

Para el estudio del dataset KITTI y como se guarda el groundtruth junto con las nubes de puntos como se ve en el capítulo 4.1.1.1 se crea un repositorio en el que se muestra en un entorno tridimensional los objetos del entorno sobre las nubes de puntos diferenciando las diferentes clases por colores.

```
git clone https://github.com/Javier-DlaP/Display_kitti_pcl_annotations.git

cd Display_kitti_pcl_annotations/
python display_pcl.py -f 0
```

Para su uso solo es necesario utilizar el flag 'frame' para indicar la nube de puntos a mostrar. En dicho repositorio se adjuntan 11 barridos para su estudio junto con su archivo *tracklet_labels.xml*.

A.3 Modelo de detecciones basado en Deep Learning

El sistema de detección 3D basado en el modelo CBGS (PointPillars Multihead) presentado en el capítulo 5.2.3 para su uso en el vehículo T4AC, e implementado dentro del contenedor Docker del proyecto Techs4AgeCar, se crea como un nodo de ROS vía rosplay que en el que se reutiliza y reestructura el repositorio creado para la detección de objetos 3D utilizando OpenPCDet.

```
cd ~/t4ac_ws/src/t4ac_architecture/t4ac_perception_layer/detection/lidar/
git clone https://github.com/RobeSafe-UAH/t4ac_opencdetc_ros.git

roslaunch t4ac_opencdetc_ros t4ac_opencdetc_ros.launch \
lidar_camera_fusion:=false multihead:=true
```

Tras la instalación dentro del contenedor del proyecto se puede ejecutar para inferir los objetos 3D del entorno junto con sus velocidades asociadas.

A.4 Sistema de detecciones mediante fusión sensorial

El funcionamiento del sistema de fusión sensorial como se explica en el capítulo 5.3 usa los sistemas de detección 3D basados en cámara y en LiDAR para construir un sistema de detección más robusto.

```
cd ~/t4ac_ws/src/t4ac_architecture/t4ac_config_layer/
git clone https://github.com/RobeSafe-UAH/t4ac_utils_ros.git
cd ~/t4ac_ws/src/t4ac_architecture/t4ac_perception_layer/detection/lidar/
git clone https://github.com/RobeSafe-UAH/t4ac_opencdetc_ros.git
cd ../camera/
git clone https://github.com/RobeSafe-UAH/t4ac_yolov5_ros.git
git clone https://github.com/RobeSafe-UAH/t4ac_3d_estimation_ros.git
cd ../sensor_fusion/
git clone https://github.com/RobeSafe-UAH/t4ac_sensor_fusion_ros.git

roslaunch t4ac_utils t4ac_config.launch perception:=true multihead:=true \
lidar_camera_fusion:=true
```

El uso de este sistema requiere de uso de gran parte de la arquitectura del proyecto que es necesario descargar para poder lanzar los diferentes nodos y obtener las detecciones provenientes de la fusión sensorial.

A.5 Uso del AD Devkit para la evaluación de la capa de percepción

El uso del AD DevKit para la evaluación de sistemas de percepción consta de múltiples pasos:

1. Obtención de un conjunto de datos

- (a) Correr el simulador CARLA

```
cd ~/carla/Dist/CARLA_Shipping_0.9.10.1/LinuxNoEditor/
./CarlaUE4.sh
```

- (b) Añadir vehículos y peatones con un comportamiento autónomo

```
cd ~/carla/PythonAPI/examples/
python spawn_npc.py
```

- (c) Lanzar el CARLA-ROS bridge

Bridge

Tras esto se abre una ventana con un vehículo a controlar y se elige si se controla manualmente o de forma automática.

- (d) Grabación del rosbag

Se graban únicamente los topics utilizados para reducir el retraso en las marcas de tiempo por parte de ROS.

```
rosbag record /carla/ego_vehicle/camera/rgb/front/camera_info \
/carla/ego_vehicle/camera/rgb/front/image_color \
/carla/ego_vehicle/lidar/lidar1/point_cloud \
/carla/ego_vehicle/odometry \
/carla/ego_vehicle/radar/front/radar_points \
/carla/objects \
/t4ac/localization/pose \
/tf
```

2. Generación del groundtruth

- (a) Descarga del AD DevKit

```
cd ~/t4ac_ws/src/t4ac_carla_simulator/
git clone https://github.com/RobeSafe-UAH/ad_devkit.git
```

- (b) Modificación del launcher

Dentro del repositorio descargado es necesario cambiar en el archivo *launch/ad_devkit.launch* la ruta en la que se encuentra guardado el rosbag recién creado, esta ruta es cambiada en el apartado *Rosbag* del launcher.

- (c) Ejecución del generador de groundtruth de forma online

```
roslaunch ad_devkit ad_devkit.launch
```

3. Evaluación del modelo

- (a) Descarga del sistema de ejemplo a evaluar

```
cd ~/t4ac_ws/src/t4ac_architecture/t4ac_perception_layer/
cd detection/lidar/
git clone https://github.com/RobeSafe-UAH/t4ac_openpcdet_ros.git
```

(b) Ejecución del modelo y creación del CSV con las detecciones

El sistema de percepción descargado es el desarrollado en este TFG en el cual se ha incluido la opción de generación de un CSV con las detecciones obtenidas, reutilizando el código realizado y pudiendo de esta manera automatizar más el proceso de evaluación dentro del proyecto.

```
cd ~/t4ac_ws/src/t4ac_architecture/t4ac_perception_layer/detection/  
cd lidar/t4ac_openpcdet_ros/src/  
python ad_devkit_CSV_creator.py
```

Dicho archivo ejecutado permite el uso en diferentes arquitecturas mediante el uso de diferentes flags, pero por defecto no es necesario realizar ningún ajuste en el contenedor del proyecto.

(c) Evaluación offline del modelo

```
cd ~/t4ac_ws/src/t4ac_carla_simulator/ad_devkit/src/  
cd perception/evaluator/  
python evaluate.py
```

Con todo esto se consiguen las curvas de precision-recall por clase además de las métricas de AP, mIoU y AVE, con las que se consigue una evaluación del modelo en función del rosbag grabado y de las características del escenario utilizado.

Apéndice B

Pliego de condiciones

Durante la realización de este trabajo se han utilizado diversos recursos hardware como software para su compleción.

B.1 Recursos hardware

El hardware utilizado en este Trabajo Fin de Grado consiste en:

- Ordenador personal con la capacidad suficiente para correr el simulador CARLA y los modelos de detección
 - AMD Ryzen 3700X
 - NVIDIA RTX 3060 Super
 - 32 GB de RAM DDR4 a 3200 MHz CL16
 - 500 GB de SSD NVME
 - 500 GB de SSD SATA
 - 1 TB de HDD
- Vehículo T4AC del grupo RobeSafe utilizado para recabar los datos utilizados en el análisis de los algoritmos

B.2 Recursos software

El software utilizado para el estudio e implementación del trabajo realizado ha sido el siguiente:

- Sistema operativo Ubuntu versión 18.04 LTS
- Docker
- Unreal Engine
- Simulador CARLA
- ROS

- Lenguaje C++
 - Roscpp
 - Point Cloud Library
- Lenguaje Python
 - Rospy
 - Pytorch
 - MayaVi
 - Numpy
 - OpenCV
- OpenPCDet
- Gestor de versiones Git
- Procesador de textos L^AT_EX

Apéndice C

Presupuesto

En este anexo se define el coste del trabajo completo presentado en este Trabajo Fin de Grado, en relación al hardware, software y coste de personal.

C.1 Coste de hardware y software

Los costes del hardware constan únicamente del valor del ordenador utilizado ya que al necesitar solo el vehículo T4AC para la extracción de datos se ha omitido su coste. Por otra parte, todo el software utilizado en el TFG ha sido Open Source por lo que no ha sido necesario ningún gasto.

Concepto		Precio
Hardware	Ordenador personal	1.600 €
	Vehículo T4AC	0 €
Software	Docker	0 €
	Unreal Engine	0 €
	CARLA	0 €
	Ubuntu 18.04	0 €
	OpenPCDet	0 €
TOTAL		1.600 €

Tabla C.1: Coste del hardware y software utilizado.

C.2 Coste de personal

Este Trabajo Fin de Grado ha tenido una duración de ocho meses, se ha comenzado a finales de diciembre de 2020 y terminado de redactar a finales de agosto. El tiempo dedicado ha sido diferentes en función del estado del TFG, mientras que en los primeros seis meses y medio se ha trabajado una media de doce horas semanales, mientras que los últimos dos meses y medio finales se ha trabajado seis horas diarias para terminar todo el trabajo. Asumiendo un precio de 20 euros la hora, este sería el desglose del gasto de personal:

Tarea	Tiempo transcurrido	Dedicación	Tiempo trabajado	Precio
Estudio de técnicas de detección e implementación de sistemas de detección	5,5 meses	12 horas/semana	287,5 horas	5.750 €
Desarrollo del AD DevKit	1 mes	6 horas/día	183 horas	3.660 €
Refinamiento del desarrollo, obtención de resultados y documentación	1,5 meses	6 horas/día	274,5 horas	5.490 €
TOTAL			745 horas	14.900 €

Tabla C.2: Coste del trabajo personal realizado.

C.3 Coste total

Por último se calcula el coste total de todo el trabajo realizado e ilustrado en este documento.

Concepto	Precio
Coste del hardware y software	1.600 €
Coste del personal	14.900 €
Coste bruto	16.500 €
IVA (21 %)	3.465 €
TOTAL	19.965 €

Tabla C.3: Coste total del TFG.

El coste estimado por tanto del Trabajo Fin de Grado asciende a la cantidad de 16.500 €, que incluyendo el IVA aumenta a 19.965 €.

Universidad de Alcalá
Escuela Politécnica Superior



ESCUELA POLITECNICA
SUPERIOR

